

Лекция 3. Условна вероятност, независимост и формула на Бейс

3.1 Условна вероятност

3.1.1 Въведение и интуиция

Когато наблюдаваме някакъв случаен експеримент, ние работим с предварително зададени вероятности. Но какво се случва, когато получим частична информация за резултата от експеримента? Нашите очаквания, и съответно вероятностите на събитията, се променят. За да формализираме това, въвеждаме понятието за условна вероятност.

Да разгледаме един съвсем прост и класически пример — хвърляне на правилно (симетрично) зарче. Множеството от възможни изходи е $\Omega = \{1, 2, 3, 4, 5, 6\}$. При липса на каквато и да е друга информация, вероятността да се падне което и да е число $i \in \Omega$ е точно една шеста:

$$\mathbb{P}(\{i\}) = \frac{1}{6}.$$

Представете си сега, че имате допълнителната информация, че се е паднало нечетно число. Нека обозначим събитието „паднало се е нечетно число“ с $A = \{1, 3, 5\}$. Тогава вероятностите за отделните изходи драстично се променят. Ясно е, че ако числото е нечетно, то не може да бъде 2. Следователно, вероятността да се е паднало 2 при положение, че A се е случило, е 0. От друга страна, възможностите остават само три (1, 3 и 5), и тъй като зарчето е симетрично, те са равновероятни. Следователно, вероятността да се е паднало 1 при условие, че е паднало нечетно число, е вече $1/3$.

Формално това може да се пресметне чрез отношението:

$$\mathbb{P}(\{i\} \mid A) = \frac{\mathbb{P}(\{i\} \cap A)}{\mathbb{P}(A)}$$

Например, ако $i = 1$, то $\{1\} \cap \{1, 3, 5\} = \{1\}$. Тогава $\mathbb{P}(\{1\} \cap A) = \frac{1}{6}$, а $\mathbb{P}(A) = \frac{3}{6} = \frac{1}{2}$. Резултатът е:

$$\mathbb{P}(\{1\} \mid A) = \frac{1/6}{1/2} = \frac{1}{3}.$$

Ако пък $i = 2$ (което е четно число), сечението $\{2\} \cap \{1, 3, 5\}$ е празното множество $\emptyset$, което има вероятност 0. В този случай условната вероятност е $\frac{0}{1/2} = 0$. Този прост пример нагледно илюстрира как появата на нова информация (че се е случило събитието A) преизчислява нашите вероятности.

3.1.2 Формална дефиниция

★ **Дефиниция 3.1 (условна вероятност).** Нека е дадено вероятностно пространство $(\Omega, \mathcal{A}, \mathbb{P})$ и събитие $A \in \mathcal{A}$ такава, че $\mathbb{P}(A) > 0$. Условна вероятност на събитието B при условие A наричаме

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

† **Допълнение 3.2 (Верижно правило).** От дефиницията непосредствено следва $\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B | A)$, а с индукция — общият вид за n събития:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \mathbb{P}(A_2 | A_1) \mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right),$$

при условие че $\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) > 0$. Това е стандартният инструмент за последователни експерименти: теглене без връщане, поредица от проверки и т.н. Ако събитията са независими в съвкупност, всички условни вероятности се заменят с безусловни и произведението се свежда до $\prod_i \mathbb{P}(A_i)$.

Изискването $\mathbb{P}(A) > 0$ е необходимо, за да можем да извършим делението. Ако събитието A има нулева вероятност (мярка 0), в определени случаи (като при формулата за пълната вероятност) за удобство можем да приемем съответното претеглено събираемо за нула, за да не усложняваме записите, макар че строго погледнато самата условна вероятност не е дефинирана. Елементарните дробни за условна вероятност по-долу винаги се разбират само при положителна вероятност на условното събитие или атом.

Важно е да се отбележи, че функцията $B \mapsto \mathbb{P}(B | A)$ сама по себе си задава нова вероятностна мярка върху същото измеримо пространство $(\Omega, \mathcal{A})$. Тя притежава всички свойства на една класическа вероятност.

▷ **Пример 3.3 (Тото 6 от 49).** За да видим как частичната информация променя вероятностите, продължаваме примера с Тото 6 от 49 от предходната лекция. Имате пуснат фиш с една конкретна шесторка, например $\{1, 2, 3, 4, 5, 6\}$. Нека обозначим нашата шесторка с W_1 . Вероятността тя да бъде изтеглена първоначално е:

$$\mathbb{P}(W_1) = \frac{1}{\binom{49}{6}} = \frac{1}{13\,983\,816} \approx \frac{1}{N}$$

където с N сме обозначили общия брой възможни шесторки.

Представете си, че докато сте слушали тегленето по радиото, сте чули само част от числата и знаете, че в печелившата шесторка със сигурност присъстват числата 1 и 2. Нека това събитие да го наречем A . Търсим новата (условна) вероятност вашата шесторка W_1 да е печеливша: $\mathbb{P}(W_1 | A)$.

Тъй като вашата шесторка $W_1 = \{1, 2, 3, 4, 5, 6\}$ съдържа числата 1 и 2, то събитието W_1 е подмножество на събитието A . Тогава сечението $W_1 \cap A$ е просто W_1 . По дефиниция 3.1 за условна вероятност:

$$\mathbb{P}(W_1 | A) = \frac{\mathbb{P}(W_1 \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(W_1)}{\mathbb{P}(A)}$$

Вероятността на събитието A (да се изтеглят 1 и 2) може да се намери чрез комбинаторика. Ние вече сме фиксирали двете числа (1 и 2), така че остава да изберем останалите 4 числа от възможните 47. Броят на шесторките, съдържащи 1 и 2, е $\binom{47}{4}$. Следователно $\mathbb{P}(A) = \frac{\binom{47}{4}}{\binom{49}{6}}$. Като заместим в условната вероятност:

$$\mathbb{P}(W_1 | A) = \frac{1/\binom{49}{6}}{\binom{47}{4}/\binom{49}{6}} = \frac{1}{\binom{47}{4}}$$

Стойността $\binom{47}{4}$ е около 178 000. Виждаме как при наличието само на тази малка частична информация вероятността за печалба се увеличава драстично — от порядъка на 1 към 14 милиона на 1 към 178 хиляди.

3.1.3 Прост модел за времето (Марковски вериги)

Условните вероятности са в основата на стохастични процеси като Марковските вериги, които моделират системи, чието бъдещо състояние зависи само от настоящето. Нека разгледаме един изключително опростен модел за прогноза на времето, при който дните могат да бъдат само два вида: „дъжд“ (0) и „слънце“ (1). Можем да зададем модела чрез условни вероятности, или така наречените преходни вероятности (стохастична матрица):

$$\begin{aligned}\mathbb{P}(\text{утре е дъжд} \mid \text{днес е дъжд}) &= p_1 \\ \mathbb{P}(\text{утре е слънце} \mid \text{днес е дъжд}) &= 1 - p_1 \\ \mathbb{P}(\text{утре е слънце} \mid \text{днес е слънце}) &= p_2 \\ \mathbb{P}(\text{утре е дъжд} \mid \text{днес е слънце}) &= 1 - p_2\end{aligned}$$

Тук вероятностите за времето утре се преизчисляват при условие какво е времето днес. Ако пространството на елементарните събития за два последователни дни се зададе като декартово произведение $\{0, 1\} \times \{0, 1\}$, то (при $\mathbb{P}(\text{днес е } 0) > 0$) p_1 е всъщност условната вероятност $\mathbb{P}(\text{утре е } 0 \mid \text{днес е } 0) = \frac{\mathbb{P}(\{0,0\})}{\mathbb{P}(\{0,0\} \cup \{0,1\})}$. Този пример илюстрира, че често на практика ние директно моделираме и задаваме условните вероятности за дадена система.

▷ **Пример 3.4 (Гласоподаватели).** Друг интересен пример е свързан със социологически проучвания и избори. Нека имаме общо гласоподаватели, от които:

- N_1 гласуват за Партия 1.
- N_2 гласуват за Партия 2.

Нека измежду тях имаме определен брой млади гласоподаватели:

- m_1 млади гласуват за Партия 1 ($m_1 \leq N_1$).
- m_2 млади гласуват за Партия 2 ($m_2 \leq N_2$).

Редакторско уточнение: приемаме $N_1 + N_2 > 0$ и $m_1 + m_2 > 0$; второто условие е точно $\mathbb{P}(M) > 0$, необходимо за следващото условно отношение.

Ако изберем случаен човек от цялата популация, вероятността събитието A_1 („човекът гласува за Партия 1“) да се случи е:

$$\mathbb{P}(A_1) = \frac{N_1}{N_1 + N_2}$$

Ако обаче имаме информацията, че случайно избраният човек е млад (събитие M), каква е условната вероятност той да е гласувал за Партия 1? Младите хора, гласуващи за Партия 1, са подмножество на всички млади хора. Следователно:

$$\mathbb{P}(A_1 \mid M) = \frac{\mathbb{P}(A_1 \cap M)}{\mathbb{P}(M)} = \frac{\frac{m_1}{N_1 + N_2}}{\frac{m_1 + m_2}{N_1 + N_2}} = \frac{m_1}{m_1 + m_2}$$

Забележете, че в крайния резултат $\frac{m_1}{m_1 + m_2}$ изобщо не участват N_1 и N_2 . Тази пропорция може да бъде коренно различна от общата пропорция $N_1/(N_1 + N_2)$. Този пример нагледно показва защо при статистически анализи трябва внимателно да се работи с условни вероятности, когато се ограничаваме до някакво подмножество (например определена възрастова група).

3.2 Независимост на събития

3.2.1 Независимост на две събития

Понятието за независимост е директно свързано с условната вероятност.

★ **Дефиниция 3.5 (независими събития).** Две събития A и B се наричат *независими* (ще го бележим понякога с $A \perp B$), ако вероятността на тяхното сечение е равна на произведението от индивидуалните им вероятности:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Защо това се нарича независимост? Съгласно дефиниция 3.5, ако приемем, че $\mathbb{P}(A) > 0$, можем да пресметнем условната вероятност на B при условие A :

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(A)} = \mathbb{P}(B)$$

Това означава, че информацията за настъпването на събитието A не променя по никакъв начин първоначалната вероятност на събитието B . Събитието A не носи никаква допълнителна информация за B .

Ако $\mathbb{P}(A) = 0$, то сечението им автоматично има нулева вероятност, и равенството $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ е тривиално изпълнено ($0 = 0 \cdot \mathbb{P}(B)$).

Твърдение 3.6 (Независимост се пренася върху допълненията). Ако $A \perp B$, то и $A \perp B^c$.

Доказателство. Разбиваме A по B и допълнението му:

$$\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A)(1 - \mathbb{P}(B)) = \mathbb{P}(A)\mathbb{P}(B^c).$$

□

Това е дребно наглед твърдение, но точно то стои зад пресмятането с тотализатора по-долу, където преминаваме от събитията A_i към допълненията им A_i^c .

Забележка 3.7 (Несъвместими не значи независими). Двете понятия често се бъркат, а всъщност са почти противоположни. Ако A и B са *несъвместими* ($A \cap B = \emptyset$) и двете имат положителна вероятност, то

$$\mathbb{P}(A \cap B) = 0 \neq \mathbb{P}(A)\mathbb{P}(B),$$

тоест те са *зависими*. И това е разбираемо: щом знаем, че е настъпило A , знаем със сигурност, че B не е настъпило — настъпването на едното носи максимална информация за другото. Независимостта означава точно обратното: че едното не носи никаква информация за другото.

3.2.2 Независимост в съвкупност

Често се налага да работим с повече от две събития, за които знаем (или допускаме в модела си), че са независими. Ако събитията са независими, вероятността на сеченията им се пресмята изключително лесно чрез произведения, което значително опростява изчисленията.

Дефиниция 3.8 (независимост в съвкупност на събития). Събитията $A_1, A_2, \dots, A_n$ се наричат *независими в съвкупност*, ако за всяко подмножество от индекси $I \subseteq \{1, 2, \dots, n\}$ с поне два елемента е изпълнено:

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i).$$

Например, ако имаме три събития A_1, A_2, A_3 , трябва да проверим четирите възможни подмножества от индекси с поне 2 елемента: $\{1, 2\}$, $\{1, 3\}$, $\{2, 3\}$ и $\{1, 2, 3\}$. Това означава, че трябва да са изпълнени едновременно следните условия:

$$\begin{aligned}\mathbb{P}(A_1 \cap A_2) &= \mathbb{P}(A_1)\mathbb{P}(A_2) \\ \mathbb{P}(A_1 \cap A_3) &= \mathbb{P}(A_1)\mathbb{P}(A_3) \\ \mathbb{P}(A_2 \cap A_3) &= \mathbb{P}(A_2)\mathbb{P}(A_3) \\ \mathbb{P}(A_1 \cap A_2 \cap A_3) &= \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3)\end{aligned}$$

Полезна интуиция дава пресмятането на лице на правоъгълник: лицето е произведението от дължините на двете му страни a и b . Тук страните са съответните „мерки“, а правоъгълникът е „сечението“. Тази хубава структура съществува само защото дължината и ширината на правоъгълника са ортогонални (независими) една спрямо друга.

† **Допълнение 3.9 (Двойната независимост не влече независимост в съвкупност).** Условието за *всички* подмножества в дефиниция 3.8 не е излишно. Хвърляме два правилни зара и полагаме

$$A_1 = \{\text{първият е нечетен}\}, \quad A_2 = \{\text{вторият е нечетен}\}, \quad A_3 = \{\text{сумата е нечетна}\}.$$

Всяко от трите има вероятност $\frac{1}{2}$, и всяка двойка е независима: $\mathbb{P}(A_i \cap A_j) = \frac{1}{4}$ за $i \neq j$. Но трите заедно не са: сумата е нечетна точно когато точно един от заровете е нечетен, тоест $A_1 \cap A_2 \cap A_3 = \emptyset$ и

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = 0 \neq \frac{1}{8} = \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3).$$

Затова проверката на двойките не е достатъчна.

3.2.3 Приложение: Еднакви тиражи в Тотото

Нека се върнем към реалния казус от първата лекция, възникнал в България през 2009 г., когато в два последователни тиража на Тото 6 от 49 се паднаха едни и същи числа. Хората тогава са се запитали: каква е вероятността за подобно нещо в историята на тотализатора? Нека имаме 10 000 тиража. Търсим вероятността на събитието A : „паднали са се еднакви числа в поне два последователни тиража от общо 10 000 тиража“. Можем да дефинираме A_i като събитието „шесторката на i -тия тираж съпада с шесторката на $(i+1)$ -вия тираж“. Тогава събитието A е обединението на тези събития за i от 1 до 9999:

$$A = \bigcup_{i=1}^{9999} A_i$$

Изчисляването на вероятност на голямо обединение е трудно и би изисквало сложния принцип на включване и изключване. Много по-лесно е, когато работим с независими събития и техните сечения. Ето защо преминаваме към допълнението на A , използвайки формулите на Де Морган:

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c) = 1 - \mathbb{P}\left(\left(\bigcup_{i=1}^{9999} A_i\right)^c\right) = 1 - \mathbb{P}\left(\bigcap_{i=1}^{9999} A_i^c\right)$$

Събитията A_i^c означават, че i -тият и $(i+1)$ -вият тираж *не* съвпадат. За следващата оценка допускаме независимостта в съвкупност от дефиниция 3.8 за събитията A_i ; тази независимост не е проверена в лекцията. При това допускане и техните допълнения A_i^c са независими в съвкупност и вероятността на сечението се разпада на произведение:

$$\mathbb{P}(A) = 1 - \prod_{i=1}^{9999} \mathbb{P}(A_i^c)$$

Тъй като правилата на играта не се променят с времето, вероятностите $\mathbb{P}(A_i^c)$ са едни и същи за всички $1 \leq i \leq 9999$. Тоест $\mathbb{P}(A_i^c) = \mathbb{P}(A_1^c)$. Тогава получаваме:

$$\mathbb{P}(A) = 1 - (\mathbb{P}(A_1^c))^{9999}$$

Тъй като $\mathbb{P}(A_1)$ е $1/N$ (където $N \approx 14$ милиона), то $\mathbb{P}(A_1^c) = 1 - 1/N$. Така формулата става:

$$\mathbb{P}(A) = 1 - \left(1 - \frac{1}{N}\right)^{9999}$$

Това приближение се пресмята лесно дори на ум, като се използва $(1-x)^n \approx 1 - nx$ за малки x . В лекцията стойността е дадена по памет като „около 1 към 1000“ за България.¹ Тотализатори обаче има и в съседните държави, и по целия свят, така че има много повече възможности някъде да се наблюдава подобно съвпадение. Затова оценката не е толкова малка, че сама по себе си да предизвика наистина сериозно съмнение.

3.3 Пълна група от събития и Формула за пълната вероятност

3.3.1 Пълна група от събития (Хипотези)

Когато разглеждаме някакво множество от елементарни събития Ω , често е много естествено то да се раздели на групи въз основа на определена характеристика. Например, клиентите в магазин могат да се разделят на „жени“ и „мъже“. Гласоподавателите могат да се разделят на гласуващи за Партия 1, Партия 2, ..., Партия N и негласуващи.

Дефиниция 3.10 (пълна група от събития). Казваме, че събитията $H_1, H_2, \dots, H_n$ (или изброимо безкрайно много $H_1, H_2, \dots$) образуват *пълна група от събития*, ако:

1. Те са взаимно изключващи се (непресичащи се): $H_i \cap H_j = \emptyset$ за $i \neq j$.
2. Те изчерпват цялото пространство: $\bigcup_i H_i = \Omega$.

Често тези събития H_i се наричат **хипотези**, тъй като при наблюдаване на някакво следствие (данни), ние се питаме от коя точно хипотеза е породено то.


¹При $N = 13\,983\,816$ записаната по-горе формула дава $1 - (1 - 1/N)^{9999} \approx 0,0007148$, тоест приблизително 1 към 1399.

3.3.2 Формула за пълната вероятност

★ **Теорема 3.11 (Формула за пълната вероятност).** Нека е дадено вероятностно пространство $(\Omega, \mathcal{A}, \mathbb{P})$, нека $H_1, H_2, \dots, H_n$ е пълна група от събития по дефиниция 3.10 и нека A е някакво събитие. Тогава:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \cap H_i) = \sum_{\substack{1 \leq i \leq n \\ \mathbb{P}(H_i) > 0}} \mathbb{P}(A | H_i) \mathbb{P}(H_i).$$

Във втората сума участват само хипотезите с положителна вероятност — само за тях условните вероятности са дефинирани. Хипотезите с вероятност нула не допринасят към първата сума, защото тогава $\mathbb{P}(A \cap H_i) = 0$.



Фигура 1: Формулата за пълната вероятност. Хипотезите H_i разрязват Ω на непресичащи се парчета, а събитието A пресича няколко от тях. Тогава A е обединение на парчетата $A \cap H_i$, които също не се пресичат — затова вероятностите им просто се събират. Формулата на Бейс обръща въпроса: като знаем, че се е случило A , каква част от него лежи в H_i ?

Ако имаме изброимо безкрайно много хипотези, сумата просто продължава до безкрайност.

Доказателство. Тъй като $A = A \cap \Omega$, а $\Omega = \bigcup_{i=1}^n H_i$, по дистрибутивния закон имаме:

$$A = A \cap \left(\bigcup_{i=1}^n H_i \right) = \bigcup_{i=1}^n (A \cap H_i)$$

Тъй като H_i са взаимно изключващи се, сеченията $A \cap H_i$ също са взаимно изключващи се. Следователно вероятността на тяхното обединение е сумата от вероятностите им:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \cap H_i)$$

За индексите с $\mathbb{P}(H_i) > 0$ прилагаме дефиниция 3.1 и получаваме $\mathbb{P}(A \cap H_i) = \mathbb{P}(A | H_i) \mathbb{P}(H_i)$. Ако $\mathbb{P}(H_i) = 0$, тогава $\mathbb{P}(A \cap H_i) = 0$; такъв индекс не участва във втората сума и не въвеждаме недефинирана дроб $\mathbb{P}(A | H_i)$. □

▷ **Пример 3.12 (Болнична смъртност).** Представете си човек, който влиза в тежко състояние в болница. Каква е вероятността човекът да почине (събитие A)? Често тази обща статистика липсва или е трудна за намиране директно, но лесно може да се изведе. Нека H_i са различните възможни тежки болести (хипотези). От медицинската статистика лекарите знаят честотата (вероятността) човек да се разболее от съответната болест $\mathbb{P}(H_i)$, както и смъртността при всяка болест $\mathbb{P}(A | H_i)$. Тогава общата вероятност се пресмята лесно чрез формулата от теорема 3.11, сумирайки по всички болести. *Редакторско уточнение:* тук H_i трябва да са класове от една

предварително зададена медицинска класификация, които са взаимно изключващи се и изчерпват всички тежки състояния. Ако изброените болести не покриват всички случаи, добавяме клас H_{other} („други“). За всеки клас, чиято условна смъртност се използва, приемаме $\mathbb{P}(H_i) > 0$. Тогава общата вероятност се пресмята лесно чрез формулата от теорема 3.11, сумирайки по всички класове.

3.4 Формула на Бейс

Формулата на Бейс (от името на Томас Бейс) е едно от най-важните твърдения в теорията на вероятностите, стоящо в основата на Бейсовата статистика и машинното самообучение. Тя отговаря на въпроса: *как да обновим вероятностите на нашите хипотези H_k , след като сме наблюдавали събитие (данни) A ?*

★ **Теорема 3.13 (Формула на Бейс).** Нека $H_1, H_2, \dots$ е пълна група от събития по дефиниция 3.10, нека A е събитие с $\mathbb{P}(A) > 0$ и нека $\mathbb{P}(H_k) > 0$. Тогава вероятността на хипотезата H_k при условие A е:

$$\mathbb{P}(H_k | A) = \frac{\mathbb{P}(A | H_k)\mathbb{P}(H_k)}{\sum_{i: \mathbb{P}(H_i) > 0} \mathbb{P}(A | H_i)\mathbb{P}(H_i)}.$$

Доказателство. По дефиниция 3.1 за условна вероятност:

$$\mathbb{P}(H_k | A) = \frac{\mathbb{P}(H_k \cap A)}{\mathbb{P}(A)}$$

Чрез условната вероятност числителят може да се запише като $\mathbb{P}(H_k \cap A) = \mathbb{P}(A | H_k)\mathbb{P}(H_k)$. Знаменателят $\mathbb{P}(A)$ се замества с разложението му от теорема 3.11. С това формулата е доказана. $\square$

3.4.1 Отношение между хипотези и обновяване на вероятностите

Пресмятането на знаменателя във формулата на Бейс често пъти е компютърно много тежко (особено ако преминем към непрекъснати разпределения, където сумата става интеграл). Затова в практиката често се разглежда съотношението между две хипотези.

Ако разгледаме две хипотези H_k и H_i при наличие на данни D , имаме:

$$\frac{\mathbb{P}(H_k | D)}{\mathbb{P}(H_i | D)} = \frac{\frac{\mathbb{P}(D|H_k)\mathbb{P}(H_k)}{\mathbb{P}(D)}}{\frac{\mathbb{P}(D|H_i)\mathbb{P}(H_i)}{\mathbb{P}(D)}} = \frac{\mathbb{P}(D | H_k)}{\mathbb{P}(D | H_i)} \cdot \frac{\mathbb{P}(H_k)}{\mathbb{P}(H_i)}$$

Това ни показва как апостериорното (обновеното) съотношение на хипотезите се получава чрез умножаване на априорното (първоначалното) им съотношение $\frac{\mathbb{P}(H_k)}{\mathbb{P}(H_i)}$ с фактора $\frac{\mathbb{P}(D|H_k)}{\mathbb{P}(D|H_i)}$. Това напълно елиминира трудната за пресмятане вероятност $\mathbb{P}(D)$ от знаменателя.

▷ **Пример 3.14 (Честна или измамна монета?).** Човек твърди, че хвърля честна монета.

- H_1 : монетата е честна (шанс за ези 1/2).
- H_2 : монетата е нечестна (за простота да допуснем, че шансът за ези е точно 1/3).

Вие имате голямо доверие на този човек, затова вашето априорно (първоначално) субективно вярване е $\mathbb{P}(H_1) = 0,99$ и $\mathbb{P}(H_2) = 0,01$. Априорното съотношение е:

$$\frac{\mathbb{P}(H_1)}{\mathbb{P}(H_2)} = \frac{0,99}{0,01} = 99$$

Сега хвърляте монетата 100 пъти и събирате данни D : паднали са се 30 езита. Използвайки биномно разпределение, условните вероятности за тези данни са:

$$\begin{aligned}\mathbb{P}(D | H_1) &= \binom{100}{30} \left(\frac{1}{2}\right)^{30} \left(\frac{1}{2}\right)^{70} \\ \mathbb{P}(D | H_2) &= \binom{100}{30} \left(\frac{1}{3}\right)^{30} \left(\frac{2}{3}\right)^{70}\end{aligned}$$

Как се променя нашето съотношение след наблюдаването на данните D ?

$$\frac{\mathbb{P}(H_1 | D)}{\mathbb{P}(H_2 | D)} = \frac{\mathbb{P}(D | H_1)}{\mathbb{P}(D | H_2)} \cdot \frac{\mathbb{P}(H_1)}{\mathbb{P}(H_2)} = \frac{\mathbb{P}(D | H_1)}{\mathbb{P}(D | H_2)} \cdot 99$$

Ако се пресметне точното отношение на биномните вероятности, крайният резултат се оказва приблизително 0,03. Тоест, въпреки първоначалното ви огромно доверие (съотношение 99 : 1 в полза на H_1), след тези експериментални данни нещата се обръщат напълно: вероятността монетата да е честна става много по-малка от вероятността да е нечестна. Тъй като H_1 и H_2 образуват пълна група, лесно може да се пресметнат самите вероятности от $\mathbb{P}(H_1 | D) + \mathbb{P}(H_2 | D) = 1$.

► **Пример 3.15 (Тестове на летището (COVID или тероризъм)).** Да си представим, че на летището е въведена система за бързо тестване (аларма) за COVID инфектирани (или пък терористи). Нека събитието H_1 означава, че човекът е инфектиран, а H_2 — че е здрав. В общата популация болните са много рядко срещани, да кажем 1%:

$$\mathbb{P}(H_1) = 0,01, \quad \mathbb{P}(H_2) = 0,99$$

Тестът (алармата B) работи отлично и хваща почти всички инфектирани — с вероятност 99%:

$$\mathbb{P}(B | H_1) = 0,99$$

Ако човекът е здрав, тестът правилно не звъни с вероятност 80%. Следователно тестът гречи (дава фалшива аларма за здрав човек) с вероятност 20%:

$$\mathbb{P}(B | H_2) = 0,20$$

Вие сте охрана и алармата B току-що звънна за даден човек. Каква е вероятността той наистина да е инфектиран? Търсим $\mathbb{P}(H_1 | B)$. По формулата на Бейс:

$$\begin{aligned}\mathbb{P}(H_1 | B) &= \frac{\mathbb{P}(B | H_1)\mathbb{P}(H_1)}{\mathbb{P}(B | H_1)\mathbb{P}(H_1) + \mathbb{P}(B | H_2)\mathbb{P}(H_2)} \\ &= \frac{0,99 \times 0,01}{0,99 \times 0,01 + 0,20 \times 0,99} \\ &= \frac{0,0099}{0,0099 + 0,1980} \\ &= \frac{0,0099}{0,2079} \\ &\approx \frac{1}{21}\end{aligned}$$

Резултатът е поразителен: въпреки че тестът засича правилно 99% от истинските болни, вероятността човекът, за когото е звъннала алармата, реално да е болен, е едва 1 към 21 (под 5%). Причината е, че търсеното събитие в генералната популация е много рядко (0,01), а фалшиво положителните резултати (0,20) сред масовата част от хората (0,99) създават огромен брой „фалшиви аларми“, които заглушават истинските. Това илюстрира защо прилагането на подобни системи в реалността изисква изключително висока специфичност на теста, когато търсим нещо много рядко срещано.

† **Допълнение 3.16 (Независимост и условие; пълна вероятност с непрекъснат параметър).** Две неща за независимостта, които не са очевидни и се появяват редовно в задачи, плюс вариантът на формулата за пълната вероятност, при който хипотезите са неизброимо много.

1. Две по две независими не значи независими в съвкупност. Независимостта на n събития изисква произведението да се разпада за *всяко* подмножество, не само за двойките. Класическият пример е с два симетрични зара:

$$A = \{\text{първият е четен}\}, \quad B = \{\text{вторият е четен}\}, \quad C = \{\text{сборът е четен}\}.$$

Тук $\mathbb{P}(A) = \mathbb{P}(B) = \frac{1}{2}$, а сборът е четен точно когато четностите съвпадат, тоест $C = (A \cap B) \cup (A^c \cap B^c)$ и $\mathbb{P}(C) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$. Проверяваме двойките: $\mathbb{P}(A \cap B) = \frac{1}{4}$; освен това $A \cap C = A \cap B$ (ако първият е четен и сборът е четен, то и вторият е четен), значи $\mathbb{P}(A \cap C) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C)$, и аналогично за $B \cap C$. Трите са независими две по две. Но

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A \cap B) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C),$$

защото $A \cap B \subseteq C$: кои да е две от трите събития определят третото еднозначно.

2. Независимостта не се запазва при условие. Казваме, че A и B са *условно независими при C* , ако $\mathbb{P}(C) > 0$ и $\mathbb{P}(A \cap B \mid C) = \mathbb{P}(A \mid C)\mathbb{P}(B \mid C)$. Това е *различно* свойство от независимостта на A и B — нито едното не влече другото. В същия пример A и B са независими, но при условие C :

$$\mathbb{P}(A \mid C) = \mathbb{P}(B \mid C) = \frac{1/4}{1/2} = \frac{1}{2}, \quad \mathbb{P}(A \cap B \mid C) = \frac{1/4}{1/2} = \frac{1}{2} \neq \frac{1}{4}.$$

При дадено C имаме $A \iff B$ — двете стават *напълно* зависими. Интуицията: знанието, че сборът е четен, превръща всяко сведение за единия зар в сведение за другия. Обратното също се случва — условието може да *създаде* независимост между зависими събития.

3. Пълна вероятност по непрекъснат параметър. Формула 3.11 разбива Ω по изброима пълна група $\{H_i\}$. Ако вместо това условието е стойността на непрекъснатата случайна величина Θ с плътност f_Θ , сумата се заменя с интеграл:

$$\mathbb{P}(A) = \int_{-\infty}^{\infty} \mathbb{P}(A \mid \Theta = \theta) f_\Theta(\theta) d\theta.$$

Тук $\{\Theta = \theta\}$ има вероятност нула, така че $\mathbb{P}(A \mid \Theta = \theta)$ не се дефинира чрез елементарната дроб от дефиниция 3.1. При съществуване на регулярна условна вероятност (например при подходяща съвместна плътност) този запис означава избрана версия на регулярната условна вероятност, дефинирана за $\mathbb{P}_\Theta$ -почти всяко θ , и тогава интегралната формула е валидна. Стойностите върху множество от $\mathbb{P}_\Theta$ -мерка нула не влияят на интеграла; не се приема универсална точкова гранична стойност без допълнителна хипотеза. Същото тълкуване важи за записи от

вида $\mathbb{E}[Y \mid X = x]$: те се отнасят до посочена версия и са твърдения почти навсякъде, освен ако изрично не е фиксирана точкова версия.

Редакторско уточнение: ако $X_1, \dots, X_n$ са интегрируеми еднакво разпределени независими величини и $S_n = \sum_{j=1}^n X_j$, симетрията дава

$$\mathbb{E}[X_1 \mid S_n] = \frac{S_n}{n} \quad \text{почти сигурно.}$$

Записът $\mathbb{E}[X_1 \mid S_n = t]$ е допустим само за избрана регулярна условна версия и се разбира $\mathbb{P}_{S_n}$ -почти навсякъде по t ; при непрекъснат S_n отделното събитие $\{S_n = t\}$ обикновено има вероятност нула.

Пример (монета с неизвестна вероятност). Нека $p \sim U(0, 1)$ и при дадено p хвърляме монетата n пъти независимо, така че броят езита е $S_n \sim \text{Bi}(n, p)$. Тогава

$$\mathbb{P}(S_n = k) = \int_0^1 \binom{n}{k} p^k (1-p)^{n-k} dp = \binom{n}{k} \frac{k! (n-k)!}{(n+1)!} = \frac{n!}{(n+1)!} = \frac{1}{n+1},$$

за всяко $k = 0, 1, \dots, n$: броят езита е *равномерен* върху $\{0, 1, \dots, n\}$. Резултатът е изненадващ — усредняването по p изравнява напълно биномния профил.

Оттук се получава и *правилото за наследяване на Лаплас*. Съвместната вероятност е

$$\mathbb{P}(S_n = k, \text{ следващото е ези}) = \int_0^1 \binom{n}{k} p^{k+1} (1-p)^{n-k} dp = \binom{n}{k} \frac{(k+1)! (n-k)!}{(n+2)!},$$

и след деление на $\mathbb{P}(S_n = k) = \frac{1}{n+1}$:

$$\mathbb{P}(\text{следващото е ези} \mid S_n = k) = \frac{k+1}{n+2}.$$

При $k = n$ това клони към 1, но никога не го достига — колкото и езита да сме видели, остава съмнение; а при $k = 0$ дава $\frac{1}{n+2} > 0$ вместо нула. Точно затова правилото се използва като изглаждане на честоти, при които някой изход още не се е случвал.

3.5 Задачи

1. Докажете, че ако събитията $A_1, \dots, A_n$ са независими в съвкупност, то и допълненията $A_1^c, \dots, A_n^c$ са независими в съвкупност.
2. В примера с монетата е получено

$$\frac{\mathbb{P}(H_1 \mid D)}{\mathbb{P}(H_2 \mid D)} \approx 0,03, \quad \mathbb{P}(H_1 \mid D) + \mathbb{P}(H_2 \mid D) = 1.$$

Пресметнете поотделно двете условни вероятности.