

Лекция 7. Теорема на Поасон. Хипергеометрично разпределение, ковариация и корелация

7.1 Гранични теореми и приближения

7.1.1 Теорема на Поасон (Поасоново приближение)

Досега разглеждахме Поасоновата случайна величина като модел, дефиниран чрез своите вероятности. За разлика от биномното разпределение, при което имаме ясен експериментален модел (хвърляне на монета или повтаряеми опити с два изхода), Поасоновото разпределение често възниква като граничен случай или като добро приближение на други разпределения.

Преди да формулираме основната теорема, нека припомним едно много полезно твърдение, свързано с пораждащите функции. Нека имаме редица от целочислени неотрицателни случайни величини X_n и съответните им пораждащи функции $G_{X_n}(s)$. Нека X е също целочислена неотрицателна случайна величина с пораждаща функция $G_X(s)$. Ако за всяко s от дефиниционното множество имаме сходимост на пораждащите функции $\lim_{n \rightarrow \infty} G_{X_n}(s) = G_X(s)$, то за всяко цяло $k \geq 0$ е изпълнено и сходимост на самите вероятности:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \mathbb{P}(X = k)$$

Това твърдение ни позволява чрез граница на функции да идентифицираме граница на вероятности, което много често е технически значително по-лесно от директното доказване на сходимост на самите вероятности.

Ще използваме този факт, за да докажем една от важните ранни теореми в теорията на вероятностите, а именно Теоремата на Поасон. Тя илюстрира как един теоретичен резултат може да ни даде основание за полезни практически приближения.

★ **Теорема 7.1 (на Поасон).** Нека за всяко $n \geq 1$ е дадена случайна величина X_n , която има биомно разпределение $X_n \sim \text{Bi}(n, p_n)$. Т.е. имаме редица от биомни случайни величини с нарастващ брой експерименти n и променяща се вероятност за успех p_n . Нека освен това границата на произведението np_n е положително число:

$$\lim_{n \rightarrow \infty} np_n = \lambda > 0$$

Тогава за всяко $k \geq 0$, границата на вероятностите X_n да е равно на k е равна на вероятността Поасонова случайна величина с параметър λ да е равна на k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

Грубо казано, ако броят експерименти по вероятността за успех се стабилизира до някакво число λ , сложните биомни вероятности се сходят към много по-лесно изчислимите Поасоновы вероятности.

Доказателство (за частен случай). Няма да доказваме теоремата в пълната ѝ общност. За да предадем основната интуиция, ще разгледаме по-простия случай, при който не просто границата е λ , а самото произведение е точно равно на λ за всички достатъчно големи n . Т.е. нека

$\lambda = np_n$, откъдето $p_n = \frac{\lambda}{n}$ за достатъчно големи n (крайният брой начални членове може да се избере с допустими параметри и не влияе на границата).

Пораждащата функция на биномната случайна величина X_n е:

$$G_{X_n}(s) = (1 - p_n + p_n s)^n$$

Замествайки $p_n = \frac{\lambda}{n}$, получаваме:

$$G_{X_n}(s) = \left(1 - \frac{\lambda}{n} + \frac{\lambda}{n}s\right)^n = \left(1 + \frac{\lambda(s-1)}{n}\right)^n$$

Като използваме основното свойство на експоненциалната функция като граница, намираме:

$$\lim_{n \rightarrow \infty} G_{X_n}(s) = \lim_{n \rightarrow \infty} \left(1 + \frac{\lambda(s-1)}{n}\right)^n = e^{\lambda(s-1)}$$

Получената граница $e^{\lambda(s-1)}$ е точно пораждащата функция на Поасонова случайна величина $X \sim \text{Po}(\lambda)$. Благодарение на споменатото по-горе твърдение, това доказва, че $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}$.

□

7.1.2 Практическо приложение: приближение на Поасон

В практиката тази теорема не се използва толкова като строга граница (понеже на практика разполагаме с едно конкретно n), колкото като рецепта за приближение. Сложният израз за биномната вероятност $\binom{n}{k} p^k (1-p)^{n-k}$ изисква пресмятането на големи факториели и високи степени.

Ако разполагаме със случайна величина $Y \sim \text{Bi}(n, p)$, където n е достатъчно голямо, а p е достатъчно малко, можем да използваме приближението:

$$\mathbb{P}(Y = k) \approx \frac{\lambda^k}{k!} e^{-\lambda}, \quad \text{където } \lambda = np$$

Квалификация на рецептата: Условието $n \geq 100$ и $np \leq 20$ само по себе си не гарантира малка грешка (например допуска $p = 0,2$). Приближението е евристично подходящо, когато p е малко, а за конкретна употреба близостта трябва да се преценява по изрично зададен критерий за грешка (например пълната вариация); тези две прагови условия не са универсална гаранция. *Редакторско допълнение:* Една стандартна количествена проверка е оценката на Le Cam

$$d_{\text{TV}}(\text{Bi}(n, p), \text{Po}(np)) \leq 2np^2,$$

която дава достатъчно условие за малка грешка именно когато np^2 е малко.

† **Допълнение 7.2 (Прореждане на Поасонов поток).** Теоремата на Поасон казва как Поасоновото разпределение *възниква*. Следващото свойство обяснява защо то е толкова устойчиво: веднъж появило се, то оцелява при случайно филтриране.

Постановка. Нека $N \sim \text{Po}(\lambda)$ брой постъпилите за някакъв период обекти (обаждания, посетители, частици, дефекти). Всеки от тези N обекта, независимо от останалите и независимо от самото N , се маркира с вероятност p и се пропуска с вероятност $q = 1 - p$. Означаваме

$$M = \text{броят маркирани}, \quad K = N - M = \text{броят немаркирани}.$$


Казваме, че M се получава чрез **прореждане** на N с вероятност p .

Твърдение. При тази постановка

$$M \sim \text{Po}(\lambda p), \quad K \sim \text{Po}(\lambda q),$$

и освен това M и K са *независими*.

всяка точка независимо: маркира се с вероятност p , пропуска се с вероятност q



Фигура 1: Прореждането нагледно. Всяка точка от Поасоновия поток си хвърля собствена монета и слиза в един от двата изходни потока. И двата изходни потока пак са Поасоновы, с параметри λp и λq , и — това е изненадата — са независими един от друг.

Доказателство. Ако знаем, че са постъпили точно n обекта, маркирането е схема на Бернули с n опита, тоест $\mathbb{P}(M = j \mid N = n) = \binom{n}{j} p^j q^{n-j}$. Събитието $\{M = j, K = k\}$ изисква $N = j + k$, така че


$$\mathbb{P}(M = j, K = k) = \mathbb{P}(N = j + k) \mathbb{P}(M = j \mid N = j + k) = e^{-\lambda} \frac{\lambda^{j+k}}{(j+k)!} \binom{j+k}{j} p^j q^k.$$

Биномният коефициент съкращава $(j+k)!$, а $e^{-\lambda} = e^{-\lambda p} e^{-\lambda q}$ и $\lambda^{j+k} = \lambda^j \lambda^k$ се разцепват по същата граница:

$$\mathbb{P}(M = j, K = k) = \underbrace{e^{-\lambda p} \frac{(\lambda p)^j}{j!}}_{\text{Po}(\lambda p)} \cdot \underbrace{e^{-\lambda q} \frac{(\lambda q)^k}{k!}}_{\text{Po}(\lambda q)}.$$

Сумирайки по всички k (втората скоба е Поасоново разпределение и се сумира до 1), получаваме $\mathbb{P}(M = j) = e^{-\lambda p} (\lambda p)^j / j!$, тоест $M \sim \text{Po}(\lambda p)$; аналогично за K . А след като съвместната вероятност се разпадна точно на произведение от двете маргинални, M и K са независими по дискретния критерий за независимост, въведен по-рано за дискретни случайни величини. $\square$

Защо независимостта е изненадваща. Сравнете с фиксиран брой опити. Ако $N = n$ е *константа*, то $M \sim \text{Bi}(n, p)$ и $K = n - M$: знаейки M , знаем K напълно — при $0 < p < 1$ двата брояча са неизродени и имат корелация -1 . При $p = 0$ или $p = 1$ корелацията не е дефинирана поради нулева дисперсия на единия брояч. Единствената промяна тук е, че самото N е случайно, и то точно Поасоново. Тази допълнителна случайност разсейва връзката до пълна независимост.



Фигура 2: Съвместното разпределение на двата брояча при $\lambda = 6$, $p = 1/3$. Площта на кръгчето е пропорционална на $\mathbb{P}(M = j, K = k)$ (мащабирано отделно във всеки панел). Вляво броят обекти е фиксиран на 6 и масата стои върху правата $j + k = 6$: щом знаем едното, знаем и другото. Вдясно броят е $\text{Po}(6)$ и масата се разстила в правоъгълно петно, чиито редове са пропорционални помежду си — точно това означава независимост.

Пример. В онлайн магазин влизат $N \sim \text{Po}(20)$ посетители на час и всеки независимо прави поръчка с вероятност $p = 0,15$. Тогава броят поръчки за часа е $M \sim \text{Po}(3)$, а броят посетители без поръчка е $K \sim \text{Po}(17)$, и двата са независими. Оттук веднага:

- $\mathbb{E}M = 3$ поръчки на час и $\mathbb{D}M = 3$ — забележете, че това *не* е $20 \cdot 0,15 \cdot 0,85 = 2,55$, колкото би било при точно 20 посетители; случайността в броя посетители добавя своя дял;
- $\mathbb{P}(\text{никаква поръчка за часа}) = e^{-3} \approx 0,0498$;
- ако в даден час сме преброили 25 посетители без поръчка (при очаквани 17), това *не* променя разпределението на броя поръчки за същия час — той си остава $\text{Po}(3)$.

Последното е практическото острие: двата потока могат да се моделират и прогнозират поотделно, все едно нямат общ източник.

Само Поасоновото има това свойство. Нека $0 < p < 1$. Ако N е произволна целочислена неотрицателна величина, прореждането ѝ дава независими M и K само когато N е Поасоново (включително изродения случай $\lambda = 0$, тоест $N \equiv 0$). При $p = 0$ или $p = 1$ един от двата брояча е тъждествено нула и независимостта е тривиална за всяко N . Вижда се с поражащи функции: понеже $\mathbb{E}[s^M t^K] = \mathbb{E}[(ps + qt)^N] = G_N(ps + qt)$, независимостта означава $G_N(ps + qt) = G_N(ps + q) G_N(p + qt)$ за всички $s, t \in [0, 1]$. Полагайки $a = ps$, $b = qt$ и пускайки поотделно $b = 0$ и $a = 0$, това се свежда до $H(a + b) = H(a)H(b)$ за подходящо нормирана непрекъсната H , чието единствено решение е експонентата. Значи $G_N(s) = e^{\lambda(s-1)}$, тоест $N \sim \text{Po}(\lambda)$.

7.2 Хипергеометрично разпределение

Последното конкретно разпределение от фундаменталните дискретни случайни величини, което ще разгледаме, е хипергеометричното разпределение. За разлика от Поасоновото, то е директно обвързано с един много ясен физически и комбинаторен модел на извличане без връщане.

Дефиниция 7.3 (хипергеометричен модел). Казваме, че X има хипергеометрично разпределение с параметри N , M и n (записваме $X \sim \text{HG}(N, M, n)$), ако X описва следния процес: Имаме общо N на брой обекта (например продукти в партида). От тях точно M са „маркирани“ (или „дефектни“), а останалите $N - M$ са немаркирани (или здрави). Ние изтегляме случайно n на брой обекта от тези N без връщане. Случайната величина X представлява броят на изтеглените маркирани обекти измежду тези n обекта.

Естествените параметрични ограничения са цели числа $N \geq 1$ и $0 \leq M, n \leq N$. Това разпределение намира огромно приложение в качествения контрол, където искаме да оценим каква пропорция от огромна партида стоки са дефектни, използвайки само малка извадка от тях.

Твърдение 7.4. Нека $X \sim \text{HG}(N, M, n)$ при цели числа $N \geq 1$ и $0 \leq M, n \leq N$. Тогава:

а) Вероятностното разпределение на X се задава с:

$$\mathbb{P}(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

където k удовлетворява естествените ограничения $\max\{0, n - N + M\} \leq k \leq \min\{M, n\}$.

б) Математическото очакване е:

$$\mathbb{E}X = n \frac{M}{N}$$

в) При $N > 1$ дисперсията е:

$$\mathbb{D}X = n \frac{M}{N} \frac{N-M}{N} \frac{N-n}{N-1}$$

При единствен обект ($N = 1$) извадката е детерминирана и поотделно е $\mathbb{D}X = 0$; горната формула не се използва, тъй като съдържа $N - 1$ в знаменателя.

Доказателство. За а): Формулата следва от класическата вероятност. Всички възможни начини да изтеглим n обекта от N са $\binom{N}{n}$. За да изтеглим точно k маркирани, трябва да изберем k обекта от наличните M маркирани (това става по $\binom{M}{k}$ начина) и останалите $n - k$ обекта да изберем от наличните $N - M$ немаркирани (това става по $\binom{N-M}{n-k}$ начина). Границите за k гарантират, че не избираме повече маркирани, отколкото съществуват или отколкото теглим ($k \leq \min(M, n)$), както и че няма как да изтеглим отрицателен брой обекти или повече немаркирани, отколкото съществуват.

За б): Това свойство има скрита линейна структура, която изключително улеснява пресмятането на очакването. Дефинираме индикаторни случайни величини X_j за всяко $j \in \{1, \dots, n\}$ по следния начин:

$$X_j = \begin{cases} 1, & \text{ако } j\text{-тият изтеглен обект е маркиран} \\ 0, & \text{ако не е маркиран} \end{cases}$$

Ясно е, че общият брой маркирани обекти X е просто сумата на тези индикатори:

$$X = \sum_{j=1}^n X_j$$

Тъй като математическото очакване винаги е линейно (независимо дали събираемите са независими или не), можем да запишем:

$$\mathbb{E}X = \mathbb{E}\left(\sum_{j=1}^n X_j\right) = \sum_{j=1}^n \mathbb{E}X_j$$

Всяко X_j е Бернулиева случайна величина $X_j \sim \text{Ber}(p_j)$, където p_j е вероятността j -тият изтеглен обект да е маркиран. Поради пълната симетрия на модела (няма значение дали теглите първи или j -ти, преди да сте видели резултатите от останалите тегления, вероятността е една и съща), вероятността на коя да е позиция да се падне маркиран обект е точно пропорцията на маркираните обекти в началото, а именно $p_j = \frac{M}{N}$. Следователно, $\mathbb{E}X_j = p_j = \frac{M}{N}$. Замествайки обратно в сумата, получаваме:

$$\mathbb{E}X = \sum_{j=1}^n \frac{M}{N} = n \frac{M}{N}$$

За v): Тук вече не можем да съберем дисперсиите наум, защото случайните величини X_j не са независими (изтеглянето на маркиран обект на първо теглене променя вероятностите за следващите тегления, тъй като тегленето е без връщане). Затова дисперсията на сумата не е просто сума от дисперсиите, а включва и ковариационните членове. Формулата се дава наготово.

□

▷ **Пример 7.5 (Цветни маркери).** Имаме 8 маркера, от които 4 са цветни и 4 са черни. Т.е. $N = 8, M = 4$. Теглим $n = 3$ маркера на случаен принцип. Броят цветни маркери, които сме изтеглили сред тези три, се описва с хипергеометричната случайна величина $X \sim \text{HG}(8, 4, 3)$.

† **Допълнение 7.6 (Хипергеометрично към биномно).** Ако популацията е голяма, а извадката — малка, тегленето без връщане почти не се различава от теглене с връщане. Формално: ако $N \rightarrow \infty$ и $M \rightarrow \infty$ така, че $M/N \rightarrow p$, а n е фиксирано, то

$$\mathbb{P}(X = k) \longrightarrow \binom{n}{k} p^k (1-p)^{n-k},$$

тоест $\text{HG}(N, M, n)$ клони към $\text{Bi}(n, p)$. Причината е, че при огромна популация изваждането на няколко обекта практически не променя дела на маркираните, така че отделните тегления стават почти независими. Това оправдава практиката в анкети и контрол на качеството да се смята с биомно разпределение, макар че извадката е без връщане.

7.3 Съвместни разпределения

Досега разглеждахме случайните величини изолирано. Често пъти обаче искаме да описваме сложни модели с повече от една случайна характеристика. Например, искаме да изследваме както разхода на един клиент в магазина, така и неговия пол. Затова трябва да въведем понятия за съвместна работа с две или повече случайни величини. За удобство на записва ще разглеждаме двойки (X, Y) , но концепциите се обобщават за произволен краен брой.

7.3.1 Съвместни дискретни разпределения

Дефиниция 7.7. Нека X и Y са две дискретни случайни величини, дефинирани върху едно и също вероятностно пространство. Под **съвместно разпределение** на X и Y разбираме съвкупността от всички вероятности:

$$p_{i,j} = \mathbb{P}(X = x_i, Y = y_j)$$

за всички възможни стойности x_i на X и y_j на Y . Обикновено това се представя във формата на таблица, където редовете отговарят на възможните стойности на X , а колоните — на възможните стойности на Y . Всяка клетка (i, j) съдържа вероятността двете събития да настъпят едновременно. Сумата на всички числа (клетки) в тази таблица е равна на 1.

Маргинални разпределения: Ако съберем всички вероятности по даден ред (фиксирайки $X = x_i$ и сумирайки по всички възможни стойности на Y), по формулата за пълната вероятност получаваме *маргиналното разпределение* на X :

$$\mathbb{P}(X = x_i) = \sum_j \mathbb{P}(X = x_i, Y = y_j) = \sum_j p_{i,j}$$

Това е просто индивидуалното разпределение на X , такова каквото би било, ако въобще не се интересуваме от Y . Аналогично, сумирайки по колони, получаваме маргиналното разпределение на Y :

$$\mathbb{P}(Y = y_j) = \sum_i \mathbb{P}(X = x_i, Y = y_j) = \sum_i p_{i,j}$$

► **Пример 7.8.** Хвърляме два стандартни зара (номерирани от 1 до 6). Дефинираме две случайни величини:

- X : броят на хвърлените шестици (възможни стойности: 0, 1, 2);
- Y : броят на хвърлените единици (възможни стойности: 0, 1, 2).

Нека попълним таблицата на съвместното им разпределение. Общият брой възможни изходи при хвърляне на два зара е $6 \times 6 = 36$.

- $\mathbb{P}(X = 0, Y = 0)$: Търсим вероятността да няма нито една шестица и нито една единица. Значи и двата зара трябва да покажат числа между 2 и 5 (общо 4 възможности за всеки зар). Вероятността е $\frac{4 \times 4}{36} = \frac{16}{36}$.
- $\mathbb{P}(X = 1, Y = 0)$: Търсим една шестица и нула единици. За първия зар имаме шестица, а за втория число от 2 до 5 (4 възможности). Или обратното. Общо $2 \times 4 = 8$ възможности. Вероятността е $\frac{8}{36}$.
- $\mathbb{P}(X = 0, Y = 1)$: По симетрия (една единица и нула шестици), вероятността също е $\frac{8}{36}$.
- $\mathbb{P}(X = 1, Y = 1)$: Една шестица и една единица. Вариантите са (6,1) и (1,6). Вероятността е $\frac{2}{36}$.
- $\mathbb{P}(X = 2, Y = 0)$: Две шестици, вероятност $\frac{1}{36}$.
- $\mathbb{P}(X = 0, Y = 2)$: Две единици, вероятност $\frac{1}{36}$.
- Всички останали комбинации (напр. $X = 2, Y = 1$) са невъзможни (не може да имаме общо повече от 2 зара), така че вероятността им е 0.

Сумата от всички вероятности в таблицата е $\frac{16+8+8+2+1+1}{36} = \frac{36}{36} = 1$.

Ако изчислим маргиналното разпределение на X чрез сумиране по редовете, получаваме:

$$\mathbb{P}(X = 0) = \frac{16 + 8 + 1}{36} = \frac{25}{36}$$

$$\mathbb{P}(X = 1) = \frac{8 + 2}{36} = \frac{10}{36}$$

$$\mathbb{P}(X = 2) = \frac{1}{36}$$

Което е точно очакваното биномно разпределение за броя на успехите (падане на шестлица, $p = 1/6$) при 2 опита.

7.3.2 Съвместна функция на разпределение (Joint CDF)

Дефиниция 7.9. Нека X и Y са две произволни случайни величини (дискретни или непрекъснати). Тогава **съвместна функция на разпределение** (или кумулативна функция) на X и Y е функцията $F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$, зададена като:

$$F_{X,Y}(x, y) := \mathbb{P}(X < x, Y < y) \quad \forall (x, y) \in \mathbb{R}^2$$

Геометрично, ако разглеждаме стойностите на X и Y като координати на двумерен вектор в равнината, $F_{X,Y}(x, y)$ е вероятността този случаен вектор да попадне в безкрайния правоъгълник на югозапад от точката (x, y) (строго по-малко от x по хоризонтала и строго по-малко от y по вертикала).

Твърдение 7.10 (Маргинални функции от съвместната). От съвместната функция на разпределение се възстановяват маргиналните:

$$F_{X,Y}(x, \infty) = F_X(x), \quad F_{X,Y}(\infty, y) = F_Y(y), \quad F_{X,Y}(\infty, \infty) = 1.$$

Възстановяването става, като заместим съответно другата координата с безкрайност. Понеже събитието $\{Y < \infty\}$ е достоверно (вероятност 1), то сечението на $\{X < x\}$ с достоверно събитие не променя вероятността:

$$F_{X,Y}(x, \infty) = \mathbb{P}(X < x, Y < \infty) = \mathbb{P}(X < x) = F_X(x)$$

Аналогично:

$$F_{X,Y}(\infty, y) = F_Y(y)$$

Очевидно е също, че $F_{X,Y}(\infty, \infty) = \mathbb{P}(X < \infty, Y < \infty) = 1$.

★ **Теорема 7.11 (Критерий за независимост).** Две случайни величини X и Y са независими тогава и само тогава, когато съвместната им функция на разпределение се разпада на произведение от маргиналните им функции на разпределение за всяка точка (x, y) :

$$F_{X,Y}(x, y) = F_X(x)F_Y(y) \quad \forall (x, y) \in \mathbb{R}^2.$$

Това е най-общият критерий за независимост. За дискретни разпределения обикновено се ползва еквивалентният и по-интуитивен критерий с вероятности в конкретни точки: $\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$.

Забележка 7.12 (Сума на независими величини и зависимост). Ако случайните величини X и Y са независими и стандартно нормално разпределени ($N(0, 1)$), а Z зависи от Y , следва ли, че $X + Y$ е независимо от Z ?

Не — и контрапримерът е елементарен. Нека $Y = Z$. Тогава сумата $X + Y$ е всъщност $X + Z$, което очевидно зависи директно от Z . Може да има специфични случаи на независимост, но в общия случай $X + Y$ и Z са зависими.

7.4 Ковариация и корелация

След като дефинирахме какво означава две случайни величини да са независими във вероятностен смисъл, преминаваме към изследването на конкретни видове зависимости. Понякога знаем, че две величини са зависими, но искаме да измерим силата и посоката на тяхната *линейна* зависимост. Търсим да отговорим на въпроса доколко Y може да се представи като линейна функция на X , т.е. $Y \approx aX + b$.

7.4.1 Ковариация

Първата стъпка към дефиниране на такава мярка е ковариацията. За да изолираме отместванията на разпределенията по реалната права, ние първо ги центрираме, като изваждаме техните математически очаквания. Ако дефинираме центрирани случайни величини $\tilde{X} = X - \mathbb{E}X$ и $\tilde{Y} = Y - \mathbb{E}Y$, то е очевидно, че тяхното очакване е 0 ($\mathbb{E}\tilde{X} = 0$).

Дефиниция 7.13. Ковариация на X и Y се нарича математическото очакване на произведението на техните центрирани версии, когато $\mathbb{E}X$, $\mathbb{E}Y$ и абсолютното очакване на това произведение са крайни (например при $\mathbb{E}[X^2], \mathbb{E}[Y^2] < \infty$):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}[\tilde{X}\tilde{Y}]$$

Ковариацията може да се изчислява и по алтернативна формула, която се извежда директно чрез разкриване на скобите и използване на линейността на математическото очакване:

$$\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}X\mathbb{E}Y$$

Следствие 7.14. Ако X и Y са независими и съответните очаквания са крайни (например имат крайни втори моменти), то математическото очакване на произведението им се разпада на произведение от очакванията им ($\mathbb{E}[XY] = \mathbb{E}X\mathbb{E}Y$). Следователно, при независими случайни величини ковариацията е точно 0. Важно е да се отбележи, че обратното не е вярно — нулева ковариация означава само липса на линейна зависимост, но величините може да са свързани чрез по-сложна, нелинейна функция.

Твърдение 7.15 (Дисперсия на сума). За произволни случайни величини с крайни дисперсии

$$\mathbb{D}(aX + bY) = a^2\mathbb{D}X + b^2\mathbb{D}Y + 2ab \operatorname{cov}(X, Y),$$

и по-общо

$$\mathbb{D}\left(\sum_{j=1}^n X_j\right) = \sum_{j=1}^n \mathbb{D}X_j + 2 \sum_{i < j} \operatorname{cov}(X_i, X_j).$$

Доказателство. Достатъчно е да разкрием квадрата под очакването. Полагаме $\tilde{X} = X - \mathbb{E}X$ и $\tilde{Y} = Y - \mathbb{E}Y$; тогава $aX + bY$ има центрирана част $a\tilde{X} + b\tilde{Y}$ и

$$\mathbb{D}(aX + bY) = \mathbb{E}[(a\tilde{X} + b\tilde{Y})^2] = a^2\mathbb{E}\tilde{X}^2 + b^2\mathbb{E}\tilde{Y}^2 + 2ab\mathbb{E}[\tilde{X}\tilde{Y}],$$

което е точно търсеното. Общият случай се получава по същия начин: при повдигане на $\sum_j \tilde{X}_j$ на квадрат диагоналните членове дават дисперсиите, а всяка недиагонална двойка се появява два пъти и дава $2 \operatorname{cov}(X_i, X_j)$. $\square$

Ако величините са независими в съвкупност, всички ковариации се нулират и се връщаме към адитивността на дисперсията от лекция 5. Точно тези „ковариационни членове“ *се появяват* при хипергеометричното разпределение, където изтеглянията не са независими; в нетривиалния случай $0 < M < N$ те са отрицателни. За $N > 1$ и $1 \leq n \leq N$ множителят е $\frac{N-n}{N-1} \leq 1$, като е строго по-малък от 1 само когато $n > 1$; при $1 < n < N$ това дава действително свиване на дисперсията (а при $n = 0$ самата дисперсия е нула).

Недостатък на ковариацията: Ако умножим случайните величини по константа, например 10 пъти, тяхната ковариация ще се увеличи 100 пъти: $\operatorname{cov}(10X, 10Y) = 100 \operatorname{cov}(X, Y)$. Това математическо мащабиране променя стойността на мярката, въпреки че линейната структура на зависимостта между величините реално не се е променила.

7.4.2 Коефициент на корелация

За да компенсирате ефекта от мащабирането, ние не само центрираме случайните величини, но ги и *нормираме*, разделяйки ги на корен квадратен от техните дисперсии (т.е. на стандартните им отклонения).

Дефиниция 7.16. Коефициент на корелация $\rho(X, Y)$ между две случайни величини с крайни и строго положителни дисперсии $\mathbb{D}X$ и $\mathbb{D}Y$ се дефинира като:

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\mathbb{D}X}\sqrt{\mathbb{D}Y}}$$


Ако дефинираме центрираните и нормирани случайни величини — за които тук използваме символ с кръгче, за да не се смесват нито с центрираните $\tilde{X}, \tilde{Y}$ от предишния раздел, нито с $\bar{X}$ за средно в други статистически контексти — като:

$$X^\circ = \frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}}, \quad Y^\circ = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}}$$

може лесно да се провери, че $\mathbb{E}X^\circ = 0$ и $\mathbb{D}X^\circ = 1$. В тези термини, коефициентът на корелация е просто очакването на тяхното произведение:

$$\rho(X, Y) = \mathbb{E}[X^\circ Y^\circ]$$

Коефициентът на корелация е безразмерна величина. Ако пресметнем корелацията на $(10X, 10Y)$, множителят 100 се появява както в числителя (ковариацията), така и в знаменателя (от корените на дисперсиите), и се съкращава. Следователно мащабирането не променя корелацията.



Фигура 3: Какво измерва ρ : доколко облакът от точки се притиска към една права. Знакът показва посоката на наклона, а големината — плътността на прилягането. Крайните стойности ± 1 се достигат само когато точките лежат *точно* върху права — това е съдържанието на теорема 7.17. Средният панел предупреждава: $\rho \approx 0$ означава липса на *линейна* връзка, а не независимост.

★ **Теорема 7.17 (Граници на корелацията).** За случайни величини с крайни и строго положителни дисперсии $0 < \mathbb{D}X, \mathbb{D}Y < \infty$ е вярно, че:

$$|\rho(X, Y)| \leq 1.$$

Това е вероятностната форма на *неравенството на Коши – Буняковски* (в литературата и като неравенство на Коши – Шварц). Връзката с геометрията е пряка: ковариацията играе ролята на скалярно произведение, стандартните отклонения — на дължини, а коефициентът на корелация — на косинус от ъгъла между двата вектора, откъдето и границите ± 1 .

Доказателство. Ще използваме очевидния факт, че квадратът на всяка случайна величина е неотрицателен, следователно и очакването му е неотрицателно:

$$0 \leq \mathbb{E}[(X^\circ \pm Y^\circ)^2]$$

Разкриваме скобите, ползвайки линейността на очакването:

$$0 \leq \mathbb{E}[(X^\circ)^2 \pm 2X^\circ Y^\circ + (Y^\circ)^2] = \mathbb{E}(X^\circ)^2 \pm 2\mathbb{E}[X^\circ Y^\circ] + \mathbb{E}(Y^\circ)^2$$

Тъй като X° и Y° имат нулеви очаквания, техните дисперсии съвпадат с очакването на квадратите им: $\mathbb{E}(X^\circ)^2 = \mathbb{D}X^\circ = 1$ и $\mathbb{E}(Y^\circ)^2 = \mathbb{D}Y^\circ = 1$. Заместваме това заедно с дефиницията за $\rho(X, Y) = \mathbb{E}[X^\circ Y^\circ]$ и получаваме:

$$0 \leq 1 \pm 2\rho(X, Y) + 1 = 2 \pm 2\rho(X, Y)$$

Следователно $1 \pm \rho(X, Y) \geq 0$, откъдето правим извода, че $|\rho(X, Y)| \leq 1$. $\square$

Следващата теорема обяснява точно какво ни казва коефициентът на корелация и кога той достига своите екстремални стойности ± 1 .

★ **Теорема 7.18 (Критерий за линейна зависимост).** Нека X и Y са случайни величини с $0 < \mathbb{D}X, \mathbb{D}Y < \infty$. Тогава между тях има строго линейна зависимост от вида $Y = aX + b$ почти сигурно (за някакви константи $a \neq 0$ и b) тогава и само тогава, когато $|\rho(X, Y)| = 1$.

Доказателство ($\implies$). Нека е дадено, че $Y = aX + b$ почти сигурно. Ще изразим връзката между нормираните величини Y° и X° .

$$Y^\circ = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}} = \frac{aX + b - (a\mathbb{E}X + b)}{\sqrt{\mathbb{D}Y}} = \frac{a}{\sqrt{\mathbb{D}Y}}(X - \mathbb{E}X)$$

Тъй като $\sqrt{\mathbb{D}X} = \frac{\sqrt{\mathbb{D}Y}}{|a|}$, следва че:

$$Y^\circ = \frac{a}{|a|} \frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}} = vX^\circ$$

където $v = \operatorname{sgn}(a) = \pm 1$. Така получихме връзката $Y^\circ = \pm X^\circ$. Сега пресмятаме коефициента на корелация:

$$\rho(X, Y) = \mathbb{E}[X^\circ Y^\circ] = \mathbb{E}[X^\circ(\pm X^\circ)] = \pm \mathbb{E}(X^\circ)^2 = \pm 1$$

Тъй като $\mathbb{E}(X^\circ)^2 = \mathbb{D}X^\circ = 1$. Това показва, че $|\rho(X, Y)| = 1$. $\square$

Доказателство ($\impliedby$). Нека сега е дадено, че $|\rho(X, Y)| = 1$. Ще разгледаме случая $\rho(X, Y) = 1$ (доказателството за $\rho = -1$ е аналогично). От предишното доказателство знаем, че:

$$\mathbb{E}[(X^\circ - Y^\circ)^2] = 2 - 2\rho(X, Y)$$

При $\rho(X, Y) = 1$, получаваме $\mathbb{E}[(X^\circ - Y^\circ)^2] = 0$. Тъй като интегрираме (търсим математическо очакване) на строго неотрицателна случайна величина и получаваме 0, това означава, че самата случайна величина е тъждествено равна на нула (с вероятност 1):

$$(X^\circ - Y^\circ)^2 = 0 \implies X^\circ = Y^\circ \text{ почти сигурно}$$

Заместваме дефинициите за центрирани и нормирани величини:

$$\frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}} = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}}$$

От това уравнение лесно можем да изразим Y като линейна функция на X :

$$Y = \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}}X - \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}}\mathbb{E}X + \mathbb{E}Y$$

Кое е точно от вида $Y = aX + b$ почти сигурно, където $a = \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}}$ и $b = \mathbb{E}Y - a\mathbb{E}X$. С това теоремата е доказана. $\square$

В заключение, коефициент на корелация близо до 1 (или -1) индикира силна права (или обратна) линейна зависимост между величините. Коефициент близо до 0 означава липса на линейна зависимост.

† **Допълнение 7.19 (Корелация на част с цялото; корелирани редици).** Дотук корелацията беше между две отделни величини. В задачите обаче почти винаги едната величина *участва* в другата — брой успехи срещу общ брой, едно събираемо срещу сумата, съседни членове на редица. Тези случаи се смятат наум, стига да се знаят следните няколко факта.

1. Ковариация на събираемо със сумата. При крайни и строго положителни дисперсии на независимите X и Y , от билинейността,

$$\text{cov}(X, X + Y) = \text{cov}(X, X) + \text{cov}(X, Y) = \mathbb{D}X + \text{cov}(X, Y),$$

а при $X \perp Y$ просто $\text{cov}(X, X + Y) = \mathbb{D}X$. Оттук, ако X и Y са независими,

$$\rho(X, X + Y) = \frac{\mathbb{D}X}{\sqrt{\mathbb{D}X}\sqrt{\mathbb{D}X + \mathbb{D}Y}} = \frac{\sigma_X}{\sqrt{\sigma_X^2 + \sigma_Y^2}}.$$

За еднакво разпределени X и Y с $0 < \mathbb{D}X = \mathbb{D}Y < \infty$ това е $\frac{1}{\sqrt{2}} \approx 0,707$ — *независимо от разпределението*. По-общо, за независими еднакво разпределени $X_1, \dots, X_n$ с $0 < \mathbb{D}X_1 < \infty$ и $S_n = X_1 + \dots + X_n$:

$$\rho(X_1, S_n) = \frac{\sigma^2}{\sigma \cdot \sigma \sqrt{n}} = \frac{1}{\sqrt{n}}.$$

Едно събираемо обяснява все по-малка част от сумата — точно затова средното се стабилизира.

2. Очакване на събираемо при фиксирана сума. Ако $X_1, \dots, X_n$ са независими, еднакво разпределени и интегрируеми, то симетрията дава условното очакване като случайна величина:

$$\mathbb{E}[X_1 | S_n] = \frac{S_n}{n} \quad \text{почти сигурно.}$$

Ако се използва означение с фиксирана стойност t , то трябва да се разбира като регулярна условна версия и равенството важи за $\mathbb{P}_{S_n}$ -почти всяко t . При непрекъснат случай $\mathbb{P}(S_n = t) = 0$, така че елементарното условно вероятностно отношение за отделната точка не е дефинирано. Например за $X_i \sim \text{Exp}(\lambda)$ (при $\lambda > 0$) може да се избере регулярна версия, за която $\mathbb{E}[X_1 | S_2 = t] = t/2$ за почти всяко t , но това не е твърдение за условяване върху събитие с положителна вероятност.

3. Два брояча при прореждане. Нека $\lambda > 0$, $0 < p < 1$, $N \sim \text{Po}(\lambda)$, а X и $Y = N - X$ са маркираните и немаркираните от допълнение 7.2, тоест $X \sim \text{Po}(\lambda p)$, $Y \sim \text{Po}(\lambda q)$ и $X \perp Y$. Тогава по точка 1

$$\text{cov}(N, X) = \text{cov}(X + Y, X) = \mathbb{D}X = \lambda p, \quad \rho(N, X) = \frac{\lambda p}{\sqrt{\lambda} \sqrt{\lambda p}} = \sqrt{p},$$

а обратната посока се смята пак чрез независимостта:

$$\mathbb{E}[N | X = k] = \mathbb{E}[X + Y | X = k] = k + \mathbb{E}Y = k + \lambda q.$$

Забележете, че $\rho(N, X) = \sqrt{p}$ не зависи от λ : колкото по-рядко се маркира, толкова по-слабо общият брой личи в маркираните.

4. Авторегресионна редица (модел с „памет“). Нека

$$D_1 = \varepsilon_1, \quad D_i = \rho D_{i-1} + \varepsilon_i \quad (i \geq 2),$$

където $\rho \in (0, 1)$, $\sigma^2 \in (0, \infty)$, а ε_i са независими с нулево очакване и дисперсия σ^2 . Това е стандартният начин да се моделира зависимост между *съседни* наблюдения (закъснения в мрежа, шум във времеви ред). Развивайки рекурсията, $D_i = \sum_{j=0}^{i-1} \rho^j \varepsilon_{i-j}$, откъдето събираемите са независими и

$$\mathbb{D}D_i = \sigma^2 \sum_{j=0}^{i-1} \rho^{2j} = \sigma^2 \frac{1 - \rho^{2i}}{1 - \rho^2} \xrightarrow{i \rightarrow \infty} \frac{\sigma^2}{1 - \rho^2}.$$

Тъй като $D_{i+k} = \rho^k D_i + (\text{членове с } \varepsilon_{i+1}, \dots, \varepsilon_{i+k})$, а те са независими от D_i ,

$$\text{cov}(D_i, D_{i+k}) = \rho^k \mathbb{D}D_i, \quad \text{и в установен режим} \quad \rho(D_i, D_{i+k}) = \rho^k.$$

Корелацията пада *геометрично* с разстоянието — оттам и името „памет“: параметърът ρ е точно корелацията между два съседни члена.

7.5 Задачи

1. За фиксирано k докажете директно границата от теоремата на Поасон:

$$\lim_{n \rightarrow \infty} \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}.$$

2. За $X \sim \text{HG}(N, M, n)$ при цели $N > 1$ и $0 \leq M, n \leq N$ докажете останената като техническо упражнение формула

$$\mathbb{D}X = n \frac{M}{N} \frac{N - M}{N} \frac{N - n}{N - 1}.$$

3. В примера с осемте маркера, четири от които са цветни, се теглят три маркера без връщане. Пресметнете вероятностите да бъдат изтеглени съответно 0, 1, 2 и 3 цветни маркера.
4. От дефиницията на съвместната функция на разпределение проверете

$$F_{X,Y}(x, \infty) = F_X(x), \quad F_{X,Y}(\infty, y) = F_Y(y).$$

5. Разкрийте скобите в дефиницията на ковариацията и докажете

$$\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}X \mathbb{E}Y.$$

Домашно 2. Нека X и Y са независими стандартно нормално разпределени случайни величини, а Z зависи от Y . Следва ли, че $X + Y$ е независимо от Z ? Разгледайте като контрапример случая $Y = Z$ и разпишете зависимостта. Решението е обсъдено в забележката към раздела за независимост.