

Лекция 8. Условно математическо очакване. Непрекъснати случайни величини

8.1 Условно математическо очакване

8.1.1 Мотивация и средноквадратично приближение

В много практически ситуации разполагаме със случайна величина X , която описва дадена числова характеристика (например приходи, разходи на клиент, време на работа на процесор и т.н.). Вече знаем, че обикновеното математическо очакване $\mathbb{E}X$ е числото, което най-добре характеризира X в средноквадратичен смисъл. В тази средноквадратична постановка приемаме $X \in L^2$ (следователно $\mathbb{E}X$ и $\mathbb{D}X$ са крайни) и търсим сред квадрат-интегрируемите приближения. Това означава, че дисперсията $\mathbb{D}X = \mathbb{E}(X - \mathbb{E}X)^2$ е минималното средноквадратично отклонение от произволна константа a :

$$\mathbb{D}X = \min_{a \in \mathbb{R}} \mathbb{E}(X - a)^2$$

Следователно, очакването е най-добрата константа за оценка на X , ако не разполагаме с никаква допълнителна информация.

Какво обаче се случва, ако разполагаме с допълнителна, наблюдаема случайна величина Y , която носи информация за X ? Например, ако X е разходът на клиент, а Y е неговият пол (мъж или жена), е логично да очакваме, че оценката ни за X може да се подобри, ако се съобразим с наблюдаваната стойност на Y . В такъв случай вече не търсим просто едно число a , което да минимизира средноквадратичната грешка, а функция $G(Y)$, зависеща от наблюдаваната стойност на Y . Целта ни е да намерим функция G , за която се достига следният минимум:

$$\min_{G: G(Y) \in L^2} \mathbb{E}(X - G(Y))^2$$

Нека разгледаме прост модел, в който Y е бинарна случайна величина, която разбива пространството от елементарни събития Ω на две части — събитието A (например клиентът е мъж) и неговото допълнение $\bar{A}$ или A^c (клиентът е жена). Можем да запишем Y чрез индикаторната функция $\mathbf{1}_A$:

$$Y = \mathbf{1}_A = \begin{cases} 1, & \text{ако се сбъдне } A \\ 0, & \text{ако се сбъдне } A^c \end{cases}$$

Нека вероятностите са съответно $\mathbb{P}(Y = 1) = \mathbb{P}(A) = p$ и $\mathbb{P}(Y = 0) = \mathbb{P}(A^c) = 1 - p = q$. За тази двуатомна сметка приемаме $0 < p < 1$, така че и двата атома имат положителна вероятност. Тъй като Y приема само две стойности, всяка възможна функция $G(Y)$ от нея е изключително проста и може да бъде записана като линейна комбинация от индикаторите на A и A^c с неизвестни константи $a, b \in \mathbb{R}$:

$$G(Y) = a\mathbf{1}_A + b\mathbf{1}_{A^c}$$

Тогава оптимизационната ни задача се свежда до минимизиране на функцията на две променливи $f(a, b)$:

$$\min_{a, b \in \mathbb{R}} \underbrace{\mathbb{E}(X - a\mathbf{1}_A - b\mathbf{1}_{A^c})^2}_{f(a, b)} = \min_{a, b \in \mathbb{R}} f(a, b)$$

Разкриваме скобите, като използваме свойствата на индикаторите, че $\mathbf{1}_A^2 = \mathbf{1}_A$ и че тяхното произведение $\mathbf{1}_A \mathbf{1}_{A^c} = 0$:

$$f(a, b) = \mathbb{E}[X^2 + a^2 \mathbf{1}_A + b^2 \mathbf{1}_{A^c} - 2aX\mathbf{1}_A - 2bX\mathbf{1}_{A^c}]$$

Вземайки предвид, че $\mathbb{E}\mathbf{1}_A = \mathbb{P}(A)$, диференцираме получената функция $f(a, b)$ спрямо променливите a и b , и приравняваме частните производни на нула, за да намерим минимума. При $0 < p < 1$ хесианът е положително определен:

$$0 = \frac{\partial f}{\partial a} = 2a\mathbb{P}(A) - 2\mathbb{E}[X\mathbf{1}_A] \implies a = \frac{\mathbb{E}[X\mathbf{1}_A]}{\mathbb{P}(A)} = \frac{\mathbb{E}[XY]}{\mathbb{P}(Y=1)}$$

$$0 = \frac{\partial f}{\partial b} = 2b\mathbb{P}(A^c) - 2\mathbb{E}[X\mathbf{1}_{A^c}] \implies b = \frac{\mathbb{E}[X\mathbf{1}_{A^c}]}{\mathbb{P}(A^c)} = \frac{\mathbb{E}[X(1-Y)]}{\mathbb{P}(Y=0)}$$

Полученият резултат е минимум (тъй като изразът представлява квадратична форма с положително определен хесиан). Функцията, за която се достига минимумът, отбелязваме с $G^*(Y)$:

$$G^*(Y) = \frac{\mathbb{E}[X\mathbf{1}_A]}{\mathbb{P}(A)} \mathbf{1}_A + \frac{\mathbb{E}[X\mathbf{1}_{A^c}]}{\mathbb{P}(A^c)} \mathbf{1}_{A^c} =: \mathbb{E}(X | Y)$$

Тази функция дефинира *условното математическо очакване* на X при условие Y . Вместо да използваме едно единствено число, вече използваме две различни стойности в зависимост от това каква стойност сме наблюдавали за Y . Ако клиентът е мъж, използваме оценката a , ако е жена — оценката b .

За да илюстрираме как условната вероятност естествено възниква в този контекст, нека приемем, че X също е бинарна случайна величина, например $X = \mathbf{1}_B$. Тогава $\mathbb{E}[X\mathbf{1}_A] = \mathbb{E}[\mathbf{1}_B \mathbf{1}_A] = \mathbb{P}(A \cap B)$. Замествайки във формулата, получаваме:

$$G^*(Y) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} \mathbf{1}_A + \frac{\mathbb{P}(A^c \cap B)}{\mathbb{P}(A^c)} \mathbf{1}_{A^c} = \mathbb{P}(B | A) \mathbf{1}_A + \mathbb{P}(B | A^c) \mathbf{1}_{A^c}$$

Виждаме, че коефициентите пред индикаторите са точно условните вероятности $\mathbb{P}(B | A)$ и $\mathbb{P}(B | A^c)$. При нулева вероятност на някой от двата атома съответният коефициент не се определя от отношение; стойността му може да се избере произволно, без да се промени случайната величина почти сигурно.

8.1.2 Дефиниция за дискретни случайни величини

Въз основа на изложената геометрична мотивация (като проекция в средноквадратичен смисъл), можем да дефинираме понятието формално за дискретни случайни величини. Нека X е интегрируема ($\mathbb{E}|X| < \infty$), а условните стойности се разглеждат само върху атоми с положителна вероятност; върху нулевите атоми една версия може да се зададе произволно.

★ **Дефиниция 8.1.** Нека X и Y са дискретни случайни величини и $\mathbb{P}(Y = y_j) > 0$. Условното математическо очакване на X при условие, че Y е приело конкретната стойност y_j , се дефинира като сума по всички възможни стойности на X с техните условни вероятности:

$$\mathbb{E}[X | Y = y_j] = \sum_i x_i \mathbb{P}(B_i | A_j)$$

където $B_i = \{X = x_i\}$ са възможните стойности на X , а $A_j = \{Y = y_j\}$.

Това е просто число (за дадено фиксирано събитие $Y = y_j$ с положителна вероятност). Ако обаче разглеждаме Y като случайна величина, можем да дефинираме *условното математическо очакване на X спрямо Y* (което бележим с $\mathbb{E}[X | Y]$) като нова дискретна случайна величина, чиято стойност зависи изцяло от това каква стойност ще приеме Y . При точково условие върху нулево събитие стойността не е канонична; общата регулярна условна версия е определена само почти навсякъде спрямо разпределението на Y :

$$\mathbb{E}[X | Y] = \sum_{j: \mathbb{P}(A_j) > 0} \mathbb{E}[X | Y = y_j] \mathbf{1}_{A_j}, \quad A_j = \{Y = y_j\}.$$

Твърдение 8.2. Ако X и Y са дискретни случайни величини, то $\mathbb{E}[X | Y]$ е също дискретна случайна величина. По атомите на Y тя има следното представяне:

$$\begin{array}{c|c|c|c|c} \mathbb{E}[X | Y] & \mathbb{E}[X | Y = y_1] & \dots & \mathbb{E}[X | Y = y_j] & \dots \\ \hline \mathbb{P} & p_1 = \mathbb{P}(A_1) & \dots & p_j = \mathbb{P}(A_j) & \dots \end{array}$$

Тази случайна величина изцяло се предопределя от стойностите на Y и приема съответната условна очаквана стойност със същата вероятност, с която Y приема стойността y_j . Ако различни атоми дават еднакви условни средни, техните вероятности се събират; така се получава обичайната таблица на разпределение на $\mathbb{E}[X | Y]$ като образ на разпределението на Y .

8.1.3 Свойства на условното математическо очакване

Условното очакване притежава серия от важни свойства, аналогични на обикновеното математическо очакване. Тук работим само с дискретни Y (както е в дефиницията по-горе), с положителни вероятности на разглежданите атоми. Прилагаме свойствата при съществуване на съответните крайни очаквания: X, Z са интегрируеми, а $f(X, Y)$ е интегрируема там, където се използва. Общата теория за непрекъснато Y изисква мярно-теоретично условно очакване или регулярна условна версия и не се развива тук.

Твърдение 8.3 (Свойства на условното математическо очакване). а) **Линейност:** $\mathbb{E}[aX + bZ | Y] = a\mathbb{E}[X | Y] + b\mathbb{E}[Z | Y]$.

б) **Независимост:** ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[X | Y] = \mathbb{E}X$.

в) **Детерминираност:** ако $X = f(Y)$, то $\mathbb{E}[X | Y] = X$.

г) **Повторно очакване (Закон за пълното математическо очакване):** $\mathbb{E}[\mathbb{E}[X | Y]] = \mathbb{E}X$.

д) **Изнасяне на функция от условието:** ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[f(X, Y) | Y = y_j] = \mathbb{E}[f(X, y_j)]$.

Доказателство. а) Използвайки дефиницията за индикаторно представяне:

$$\begin{aligned}\mathbb{E}[aX + bZ | Y] &= \sum_{j: \mathbb{P}(A_j) > 0} \frac{\mathbb{E}[(aX + bZ)\mathbf{1}_{A_j}]}{\mathbb{P}(A_j)} \mathbf{1}_{A_j} \\ &= a \sum_{j: \mathbb{P}(A_j) > 0} \frac{\mathbb{E}[X\mathbf{1}_{A_j}]}{\mathbb{P}(A_j)} \mathbf{1}_{A_j} + b \sum_{j: \mathbb{P}(A_j) > 0} \frac{\mathbb{E}[Z\mathbf{1}_{A_j}]}{\mathbb{P}(A_j)} \mathbf{1}_{A_j},\end{aligned}$$

което е точно $a\mathbb{E}[X | Y] + b\mathbb{E}[Z | Y]$.

б) Тъй като X и $\mathbf{1}_{A_j}$ са независими, то $\mathbb{E}[X\mathbf{1}_{A_j}] = \mathbb{E}X \cdot \mathbb{E}\mathbf{1}_{A_j} = \mathbb{E}X \cdot \mathbb{P}(A_j)$. Тогава в дефиниционната сума вероятностите $\mathbb{P}(A_j)$ се съкращават и остава $\mathbb{E}X \sum_j \mathbf{1}_{A_j} = \mathbb{E}X \cdot 1 = \mathbb{E}X$ (защото индикаторите на пълна група от събития се сумират до 1).

г) Прилагаме оператора $\mathbb{E}$ върху дефиниционната сума на $\mathbb{E}[X | Y]$:

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X | Y]] &= \mathbb{E} \left[\sum_{j: \mathbb{P}(A_j) > 0} \frac{\mathbb{E}[X\mathbf{1}_{A_j}]}{\mathbb{P}(A_j)} \mathbf{1}_{A_j} \right] = \sum_{j: \mathbb{P}(A_j) > 0} \frac{\mathbb{E}[X\mathbf{1}_{A_j}]}{\mathbb{P}(A_j)} \mathbb{E}\mathbf{1}_{A_j} \\ &= \sum_{j: \mathbb{P}(A_j) > 0} \mathbb{E}[X\mathbf{1}_{A_j}] = \mathbb{E} \left[\sum_{j: \mathbb{P}(A_j) > 0} X\mathbf{1}_{A_j} \right] = \mathbb{E}X\end{aligned}$$

□

Свойства в) и д) са непосредствени. За в): ако познавайки Y ние вече знаем с абсолютна точност стойността на X , то случайността отпада и най-добрата оценка е самото X . За д): тъй като в условието знаем, че $Y = y_j$, можем да заместим Y с тази константа в самата функция; а понеже X е независимо от Y , условието вече не носи информация за X и отпада напълно. Точно в този вид свойството се използва при пресмятане на суми със случаен брой събираеми.

Свойство б) има ясен смисъл: когато Y не носи информация за X , условното очакване съвпада с безусловното, защото най-доброто число за приближение на X (в средноквадратичен смисъл) остава просто нейното обикновено математическо очакване.

8.1.4 Условна дисперсия и формула за пълната дисперсия

★ **Дефиниция 8.4 (Условна дисперсия).** Нека X и Y са дискретни случайни величини с $\mathbb{E}[X^2] < \infty$. За всяка стойност y_j с $\mathbb{P}(Y = y_j) > 0$ дефинираме *условната дисперсия* на X при условие $Y = y_j$ чрез

$$\mathbb{D}(X | Y = y_j) := \mathbb{E}[(X - \mathbb{E}[X | Y = y_j])^2 | Y = y_j].$$

Условната дисперсия спрямо Y е случайната величина

$$\mathbb{D}(X | Y) = \sum_{j: \mathbb{P}(Y=y_j) > 0} \mathbb{D}(X | Y = y_j) \mathbf{1}_{\{Y=y_j\}}.$$

Както при обикновената дисперсия, за нея важи еквивалентният запис

$$\mathbb{D}(X | Y) = \mathbb{E}[X^2 | Y] - (\mathbb{E}[X | Y])^2.$$

Числото $\mathbb{D}(X \mid Y = y_j)$ измерва оставащата неопределеност в X , след като сме научили, че $Y = y_j$. Следователно $\mathbb{E}[\mathbb{D}(X \mid Y)]$ е средната *необяснена* дисперсия, а $\mathbb{D}(\mathbb{E}[X \mid Y])$ измерва колко се изменя условното средно между различните групи, определени от Y .

★ **Теорема 8.5 (Формула за пълната дисперсия).** Нека X и Y са дискретни случайни величини и $\mathbb{E}[X^2] < \infty$. Тогава

$$\mathbb{D}X = \mathbb{E}[\mathbb{D}(X \mid Y)] + \mathbb{D}(\mathbb{E}[X \mid Y]).$$

Доказателство. От алтернативната формула за условната дисперсия и закона за пълното математическо очакване, приложен към X^2 , получаваме

$$\begin{aligned}\mathbb{E}[\mathbb{D}(X \mid Y)] &= \mathbb{E}\left[\mathbb{E}[X^2 \mid Y] - (\mathbb{E}[X \mid Y])^2\right] \\ &= \mathbb{E}[X^2] - \mathbb{E}\left[(\mathbb{E}[X \mid Y])^2\right].\end{aligned}$$

От друга страна, прилагаме обикновената формула за дисперсия към случайната величина $\mathbb{E}[X \mid Y]$ и отново използваме пълното очакване:

$$\begin{aligned}\mathbb{D}(\mathbb{E}[X \mid Y]) &= \mathbb{E}\left[(\mathbb{E}[X \mid Y])^2\right] - (\mathbb{E}[\mathbb{E}[X \mid Y]])^2 \\ &= \mathbb{E}\left[(\mathbb{E}[X \mid Y])^2\right] - (\mathbb{E}X)^2.\end{aligned}$$

Като съберем двете равенства, междинните членове се съкращават и остава

$$\mathbb{E}[\mathbb{D}(X \mid Y)] + \mathbb{D}(\mathbb{E}[X \mid Y]) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{D}X.$$

□

† **Допълнение 8.6 (Сума със случаен брой събираеми).** Твърдението за произведение на пораждащи функции от лекция 6 изисква броят на събираемите да е *фиксиран*. Много често обаче самият брой е случаен: брой яйца, от които всяко се излюпва; брой клиенти, всеки с някаква сметка; брой пакети, всеки с някакъв размер. Тогава пораждащите функции не се умножават, а се *съставят*.

Постановка. Нека N е целочислена неотрицателна случайна величина, а $X_1, X_2, \dots$ са независими в съвкупност, еднакво разпределени, целочислени и неотрицателни, независими и от N . Полагаме

$$S_N = \sum_{j=1}^N X_j, \quad \text{като } S_0 = 0.$$

† **Твърдение 8.7.** При тази постановка пораждащата функция на S_N е композицията

$$g_{S_N}(s) = g_N(g_{X_1}(s)).$$

Доказателство. Разбиваме по стойностите на N и използваме независимостта му от събираемите:

$$g_{S_N}(s) = \mathbb{E}[s^{S_N}] = \sum_{n \geq 0} \mathbb{P}(N = n) \mathbb{E}[s^{X_1 + \dots + X_n}] = \sum_{n \geq 0} \mathbb{P}(N = n) (g_{X_1}(s))^n.$$

Последното равенство е точно твърдението за фиксирана сума от лекция 6, а дясната страна е g_N в точката $g_{X_1}(s)$. Композицията е коректна, защото $g_{X_1}(s) \in [0, 1]$ при $s \in [0, 1]$. $\square$

Следствия за моментите. Ако $\mathbb{E}N < \infty$ и $\mathbb{E}X_1 < \infty$, то условно на $N = n$ сумата има средно $n\mathbb{E}X_1$. Следователно

$$\mathbb{E}[S_N | N] = N\mathbb{E}X_1 \implies \mathbb{E}S_N = \mathbb{E}N \mathbb{E}X_1.$$

Това е твърдението на Уолд в разглежданата постановка. Ако освен това $\mathbb{E}[N^2] < \infty$ и $\mathbb{E}[X_1^2] < \infty$, условната дисперсия е

$$\mathbb{D}(S_N | N) = N\mathbb{D}X_1.$$

Прилагайки току-що доказаната формула за пълната дисперсия, получаваме

$$\begin{aligned} \mathbb{D}S_N &= \mathbb{E}[\mathbb{D}(S_N | N)] + \mathbb{D}(\mathbb{E}[S_N | N]) \\ &= \mathbb{E}[N\mathbb{D}X_1] + \mathbb{D}(N\mathbb{E}X_1) \\ &= \mathbb{E}N \mathbb{D}X_1 + \mathbb{D}N (\mathbb{E}X_1)^2. \end{aligned}$$

Приложение: прореждането на един ред. Нека $N \sim \text{Po}(\lambda)$ и нека всяко от N -те неща се маркира независимо с вероятност p , тоест $X_j \sim \text{Ber}(p)$ и S_N е броят на маркираните. Тогава $g_N(s) = e^{\lambda(s-1)}$ и $g_{X_1}(s) = q + ps$, откъдето

$$g_{S_N}(s) = e^{\lambda(q+ps-1)} = e^{\lambda p(s-1)}.$$

Следователно $S_N \sim \text{Po}(\lambda p)$ — резултатът от допълнението в лекция 7, получен с една композиция. Независимостта на маркираните от немаркираните не се вижда оттук; за нея е нужна съвместната пораждаща функция $\mathbb{E}[s^M t^K] = g_N(ps + qt)$.

▷ **Пример 8.8 (Смес от разпределения).** Условното математическо очакване е изключително полезно при т.нар. смеси (mixture distributions), където параметрите на дадено разпределение самите те са случайни величини. Нека разгледаме Бернулиева случайна величина $X \sim \text{Ber}(Y)$, чийто параметър на успеха е случайната величина Y :

$$Y = \begin{cases} \frac{2}{3}, & \text{с вероятност } p \\ \frac{1}{3}, & \text{с вероятност } 1 - p \end{cases}$$

Това означава, че първо теглим параметъра Y . Ако се падне $2/3$, тогава X е Бернулиева с вероятност за успех $2/3$. Ако Y е $1/3$, тогава X е Бернулиева с вероятност за успех $1/3$. Търсим пълната вероятност $\mathbb{P}(X = 1)$, която за индикаторна променлива напълно съвпада с нейното математическо очакване $\mathbb{E}X$. Използвайки свойството за повторно очакване $\mathbb{E}X = \mathbb{E}[\mathbb{E}[X | Y]]$, имаме:

$$\begin{aligned} \mathbb{E}[X | Y] &= \mathbb{E}\left[X | Y = \frac{2}{3}\right] \mathbf{1}_{\{Y=2/3\}} + \mathbb{E}\left[X | Y = \frac{1}{3}\right] \mathbf{1}_{\{Y=1/3\}} \\ &= \frac{2}{3} \mathbf{1}_{\{Y=2/3\}} + \frac{1}{3} \mathbf{1}_{\{Y=1/3\}} \end{aligned}$$

Вземайки безусловното математическо очакване от двете страни, получаваме крайната вероятност за успех:

$$\mathbb{P}(X = 1) = \mathbb{E}[\mathbb{E}[X | Y]] = \frac{2}{3} \mathbb{P}\left(Y = \frac{2}{3}\right) + \frac{1}{3} \mathbb{P}\left(Y = \frac{1}{3}\right) = \frac{2}{3}p + \frac{1}{3}(1 - p)$$

8.2 Условни разпределения

Аналогично на условното очакване, можем да дефинираме цялостното *условно разпределение* на една случайна величина спрямо друга.

Дефиниция 8.9. Нека X и Y са дискретни случайни величини. Условното разпределение на X при условие $Y = y_j$ (за всяка възможна стойност на Y с $\mathbb{P}(Y = y_j) > 0$) се задава чрез условните вероятности за всяка възможна стойност x_i :

$X Y = y_j$	x_1	x_2	$\dots$	x_i	$\dots$
$\mathbb{P}$	$\mathbb{P}(X = x_1 Y = y_j)$	$\dots$	$\dots$	$\mathbb{P}(X = x_i Y = y_j)$	$\dots$

Това на практика са изменените вероятности за X , които произтичат от допълнителната информация, че е настъпило събитието $Y = y_j$.

▷ **Пример 8.10.** Да разгледаме хвърляне на два зара. Нека Y е броят на падналите се шестници, а X е броят на падналите се единици. И двете случайни величини приемат стойности в множеството $\{0, 1, 2\}$. Съвместното им разпределение е зададено със следната таблица (известна от предходна лекция):

$Y \setminus X$	0	1	2
0	16/36	8/36	1/36
1	8/36	2/36	0
2	1/36	0	0

Искаме да намерим условното разпределение на X при условие, че $Y = 0$. Маргиналната вероятност за $Y = 0$ е $\mathbb{P}(Y = 0) = \frac{16}{36} + \frac{8}{36} + \frac{1}{36} = \frac{25}{36}$. За да намерим условните вероятности $\mathbb{P}(X = x_i | Y = 0)$, просто разделяме съвместната вероятност от таблицата на маргиналната вероятност:

$$\mathbb{P}(X = 0 | Y = 0) = \frac{16/36}{25/36} = \frac{16}{25}$$

$$\mathbb{P}(X = 1 | Y = 0) = \frac{8/36}{25/36} = \frac{8}{25}$$

$$\mathbb{P}(X = 2 | Y = 0) = \frac{1/36}{25/36} = \frac{1}{25}$$

Този резултат има напълно ясна интуиция. Ако знаем със сигурност, че $Y = 0$ (не се е паднала нито една шестлица), това е еквивалентно на това да хвърляме зарове само с по 5 стени (защото сме елиминирали напълно шестлицата). Възможните изходи от хвърлянето на два зара намаляват до $5^2 = 25$. Вероятността да не се падне единица е $(\frac{4}{5})^2 = \frac{16}{25}$, да се падне точно една единица е $2 \cdot \frac{1}{5} \cdot \frac{4}{5} = \frac{8}{25}$, а две единици - $(\frac{1}{5})^2 = \frac{1}{25}$.

8.3 Полиномно разпределение

Полиномното разпределение е естествено многомерно обобщение на биномното разпределение. Докато при биномното разпределение имаме само два възможни изхода (успех и неуспех), при полиномното разполагаме с $r \geq 1$ възможни изхода. Нека провеждаме n независими експеримента. Всеки експеримент може да завърши с един от r изхода. Съответните вероятности за тези изходи са $p_1, p_2, \dots, p_r$, като сумата им естествено е $\sum_{j=1}^r p_j = 1$.

Интересува ни съвместното разпределение на вектора от случайни величини $(X_1, X_2, \dots, X_r)$, където X_j е броят на настъпванията на изход j . Зададени са цели неотрицателни числа $k_1, k_2, \dots, k_r$, такива че сборът им дава общия брой експерименти: $k_1 + k_2 + \dots + k_r = n$. Вероятността да се получи точно тази конфигурация от резултати се пресмята по следната формула:

$$\mathbb{P}(X_1 = k_1, X_2 = k_2, \dots, X_r = k_r) = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} p_2^{k_2} \dots p_r^{k_r}$$

Тази формула се извежда аналогично на биномното разпределение. Вероятността за една конкретна наредба на тези изходи (т.е. конкретна последователност от n събития) е произведението $p_1^{k_1} \dots p_r^{k_r}$. Тъй като нас не ни интересува конкретният ред на настъпване на събитията, а само общият им брой, трябва да умножим по броя на всички възможни конфигурации, които водят до този краен резултат. Броят на начините да изберем k_1 места за първия изход е $\binom{n}{k_1}$. За останалите $n - k_1$ свободни места избираме k_2 места за втория изход, което може да стане по $\binom{n-k_1}{k_2}$ начина, и така нататък. Произведението от тези биномни коефициенти се опростява алгебрично до мултиномния коефициент:

$$\binom{n}{k_1} \binom{n-k_1}{k_2} \dots \binom{n-k_1-\dots-k_{r-1}}{k_r} = \frac{n!}{k_1! \dots k_r!}$$

Ако $r = 2$, получаваме класическото биномно разпределение, където $k_2 = n - k_1$ и $p_2 = 1 - p_1$.

8.4 Непрекъснати случайни величини

8.4.1 Въведение и мотивация

Досега разглеждахме дискретни случайни величини, които могат да приемат най-много изброимо множество от стойности. Има обаче много случайни характеристики от реалния живот (например температура, тепло, време на живот на процесор, приходи), които чисто теоретично могат да приемат неизброимо много стойности — всяка стойност от някакъв реален интервал.

От гледна точка на компютърното моделиране, неизброимостта е фикция — ние винаги съхраняваме данните с крайна точност (чрез тактовете на процесора). В такъв случай защо въобще са ни нужни непрекъснати случайни величини? Отговорът се крие в ефективността. Ако искаме да моделираме равномерна случайна величина в интервала $(0, 1)$ с много голяма точност (например 100 милиона възможни стойности), трябва да пазим масив със 100 милиона вероятности, въпреки че всички те са напълно еднакви. Много по-изчислително ефективно е да използваме една проста функция (плътност), която компактно да описва поведението на модела. Освен това, на практика изключително рядко се интересуваме от точната вероятност температурата да бъде съвършено равняваща се на дадено число с безкрайна точност (която вероятност клони към нула). Много по-често ни интересува вероятността стойността да попадне в даден диапазон.

8.4.2 Дефиниция и плътност на разпределение

Дефиниция 8.11 (Абсолютно непрекъснатата случайна величина). Случайната величина X се нарича непрекъснатата, ако съществува неотрицателна функция $f_X : \mathbb{R} \rightarrow [0, \infty)$, наричана *плътност на разпределение* (probability density function), такава че:

1. $f_X(x) \geq 0 \quad \forall x \in \mathbb{R}$
2. Лицето под цялата крива е единица: $\int_{-\infty}^{\infty} f_X(x) dx = 1$
3. За всеки две числа $a < b$ (включително $\pm\infty$) е изпълнено:

$$\mathbb{P}(X \in (a, b)) = \int_a^b f_X(x) dx$$

Графиката на функцията $f_X(x)$ ни показва къде случайните величини са по-склонни да приемат стойности. Лицето под графиката между точките a и b е точно равно на вероятността X да попадне в интервала (a, b) .

От свойствата на интеграла веднага следва, че вероятността X да приеме точно една конкретна стойност c е нула:

$$\mathbb{P}(X = c) = \int_c^c f_X(x) dx = 0$$

Поради това за непрекъснати случайни величини границите на интервала нямат никакво значение при пресмятане на вероятност:

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b)$$

▷ **Пример 8.12 (Редакторски пример: медицински застраховки).** Нека разходите за медицински застраховки в една фирма са зададени с модела $M = 100\,000 \cdot X$, където X е непрекъсната случайна величина с плътност:

$$f_X(x) = \begin{cases} 5(1-x)^4, & x \in (0, 1) \\ 0, & \text{иначе} \end{cases}$$

Тази плътност е нула за отрицателни стойности и за стойности по-големи от 1. В интервала $(0, 1)$ представлява намаляваща крива (започваща от стойност 5 при $x = 0$). Търсим вероятността разходите на фирмата да надвишат 10 000 единици:

$$\mathbb{P}(M > 10\,000) = \mathbb{P}(100\,000 \cdot X > 10\,000) = \mathbb{P}\left(X > \frac{1}{10}\right)$$

Тъй като X приема стойности само до 1, това се свежда до определен интеграл:

$$\mathbb{P}\left(\frac{1}{10} < X < 1\right) = \int_{1/10}^1 5(1-x)^4 dx$$

Този интеграл се решава изключително лесно и е равен на $\left(\frac{9}{10}\right)^5 \approx 0,59$. Вместо да пази огромен масив с дискретни вероятности за всяка възможна стотинка, фирмата използва компактна функция за оценка на риска.


8.4.3 Функция на разпределение

Функцията на разпределение $F_X(x)$ за непрекъсната случайна величина X се дефинира по обичайния начин като вероятността X да бъде по-малко от x :

$$F_X(x) = \mathbb{P}(X < x) = \int_{-\infty}^x f_X(y) dy \quad \forall x \in \mathbb{R}$$

Това представлява натрупване (акумулиране) на площта под плътността от минус безкрайност до текущата точка x . Диференциалът dy в този контекст трябва да се разбира като мярка. Ако плътността f_X е непрекъсната функция в дадена точка x_0 , то от основната теорема на интегралното смятане следва, че производната на функцията на разпределение е равна на плътността:

$$\left. \frac{dF_X}{dx} \right|_{x=x_0} = f_X(x_0) \quad \text{ако } f_X \text{ е непрекъсната в } x_0, \quad F'_X(x) = f_X(x) \quad \text{за почти всяко } x$$



Фигура 1: Непрекъснати аналог на стъпаловидната функция от фигурата в лекция 5. Горен е плътността f_X ; заштрихованата площ вляво от x_0 е $\mathbb{P}(X < x_0)$. Долу е функцията на разпределение F_X : нейната височина в x_0 е точно тази площ. Скоковете от дискретния случай са изгладени — F_X е непрекъсната, а наклонът ѝ почти навсякъде е стойността на плътността там (и е равен на нея във всяка точка на непрекъснатост на f_X).

Следователно, ако знаем плътността, чрез интегриране възстановяваме функцията на разпределение, а ако знаем функцията на разпределение, чрез диференциране възстановяваме плътността почти навсякъде (и точково там, където избраната плътност е непрекъсната).

8.5 Смяна на променливите при непрекъснати случайни величини

Често имаме даден модел със случайна величина X , но се интересуваме от някаква нейна трансформация $Y = g(X)$ (например ако X е приходът на клиент, Y може да бъде неговият разход за конкретни мероприятия, който зависи функционално от прихода). Искаме да намерим плътността на новата случайна величина Y .

Теорема 8.13. Нека X е непрекъсната случайна величина с плътност f_X и $\mathbb{P}(X \in I) = 1$ за интервал I . Нека $g : I \rightarrow g(I)$ е едно-към-едно C^1 -изображение, строго монотонно, с $g'(x) \neq 0$ на I (така че обратната функция е C^1 върху $g(I)$). Тогава $Y = g(X)$ е непрекъсната случайна величина и, почти навсякъде,

$$f_Y(y) = f_X(g^{-1}(y)) |(g^{-1}(y))'|$$

за $y \in g(I)$, а $f_Y(y) = 0$ извън образа $g(I)$.

† **Допълнение 8.14 (Защо е нужна строгата монотонност).** Без нея твърдението пропада напълно: трансформация на непрекъсната величина може да бъде дискретна. Нека X е произволна непрекъсната величина и $g(x) = \mathbf{1}_{\{x \geq 0\}}$. Тогава $Y = g(X)$ приема само стойностите 0 и 1, тоест $Y \sim \text{Ber}(\mathbb{P}(X \geq 0))$ — тя изобщо няма плътност. Монотонността гарантира, че g не „слепава“ цели интервали в една точка.

Доказателство. Търсим функция f_Y , която при интегриране над произволен интервал (a, b) да дава вероятността $\mathbb{P}(Y \in (a, b))$. Първо разглеждаме интервали, съдържащи се в $g(I)$; извън $g(I)$ плътността е нула. Разглеждаме първо случая, когато g е строго монотонно растяща ($g^\uparrow$).

$$\mathbb{P}(Y \in (a, b)) = \mathbb{P}(g(X) \in (a, b)) = \mathbb{P}(X \in (g^{-1}(a), g^{-1}(b)))$$

Тъй като познаваме плътността на X , тази вероятност е просто интеграл:

$$\mathbb{P}(Y \in (a, b)) = \int_{g^{-1}(a)}^{g^{-1}(b)} f_X(w) dw$$

За да превърнем границите на интегриране отново в a и b , правим субституцията $w = g^{-1}(v)$. Тогава диференциалът е $dw = (g^{-1}(v))' dv$. Границите на интегриране се променят от $g^{-1}(a)$ до $g^{-1}(b)$ съответно на a до b :

$$\int_a^b f_X(g^{-1}(v))(g^{-1}(v))' dv$$

Тъй като g е монотонно растяща функция, нейната обратна функция g^{-1} също е монотонно растяща, което означава, че производната $(g^{-1}(v))'$ е положителна, т.е. съвпада със своя модул. Нека сега разгледаме случая, когато g е строго монотонно намаляваща ($g^\downarrow$). Когато приложим g^{-1} към неравенството $a < g(X) < b$, посоките на неравенствата се обръщат, защото функцията обръща наредбата:

$$\mathbb{P}(g(X) \in (a, b)) = \mathbb{P}(X \in (g^{-1}(b), g^{-1}(a))) = \int_{g^{-1}(b)}^{g^{-1}(a)} f_X(w) dw$$

При същата субституция $w = g^{-1}(v)$ границите на интегриране стават от b до a . За да обърнем нормално интеграла да бъде от a до b , трябва да добавим знак минус:

$$- \int_a^b f_X(g^{-1}(v))(g^{-1}(v))' dv$$

Но тъй като g е монотонно намаляваща, $(g^{-1}(v))'$ е отрицателна функция, следователно $-(g^{-1}(v))' = |(g^{-1}(v))'|$. И в двата случая стигаме до един и същ обединен израз:

$$\int_a^b f_X(g^{-1}(v)) |(g^{-1}(v))'| dv$$

Тъй като вероятността $\mathbb{P}(Y \in (a, b))$ се пресмята чрез интеграл над интервала (a, b) от тази конкретна функция, то по дефиниция подинтегралната функция е именно търсената плътност на Y . $\square$

† **Допълнение 8.15 (Разпределение на максимум и минимум).** Теоремата по-горе изисква g да е монотонна функция на една величина. Две трансформации, които често се търсят в задачите, не са от този вид, но се намират по много по-лесен път — изобщо без интегриране. Нека $X_1, \dots, X_n$ са независими с функции на разпределение $F_1, \dots, F_n$ и нека

$$M = \max_j X_j, \quad m = \min_j X_j.$$

Ключът е, че събитията се преобразуват в сечения. Максимумът е под дадена стойност точно когато *всички* са под нея:

$$\{M < x\} = \bigcap_{j=1}^n \{X_j < x\} \implies F_M(x) = \prod_{j=1}^n F_j(x).$$

За минимума същият трик работи, но откъм *опашката*: минимумът е над дадена стойност точно когато *всички* са над нея.

$$\{m \geq x\} = \bigcap_{j=1}^n \{X_j \geq x\} \implies F_m(x) = 1 - \prod_{j=1}^n (1 - F_j(x)).$$

При еднакво разпределени величини това дава $F_M = F^n$ и $F_m = 1 - (1 - F)^n$, а след диференциране

$$f_M(x) = n F(x)^{n-1} f(x), \quad f_m(x) = n (1 - F(x))^{n-1} f(x).$$

Запомнящото се правило е: *максимумът се гледа през F , минимумът — през $1 - F$* . Ако човек тръгне да разписва $\{m < x\}$ като обединение, стига до формулата за включване и изключване и си усложнява живота без нужда.

Един частен случай заслужава внимание: ако $X_j \sim \text{Exp}(\lambda_j)$ са независими и $\lambda_j > 0$, то за $x \geq 0$

$$1 - F_m(x) = \prod_j e^{-\lambda_j x} = e^{-(\sum_j \lambda_j)x}, \quad F_m(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-(\sum_j \lambda_j)x}, & x \geq 0. \end{cases}$$

За $x < 0$ имаме $1 - F_m(x) = 1$, защото $m \geq 0$ почти сигурно. Следователно $m \sim \text{Exp}(\sum_j \lambda_j)$ — минимумът на независими експоненциални отново е експоненциален, с параметър сумата. (Максимумът не е.) Това е причината експоненциалният модел да е толкова удобен за „кой ще откаже пръв“: времето до първата повреда в система от независими компоненти пак е експоненциално.

Максимумът се появява и в лекция 12, където $X^* = \max_j X_j$ е оценката по максимално правдоподобие при $U(0, \theta)$; там $F_{X^*}(x) = (x/\theta)^n$ е точно горната формула.

8.6 Числени характеристики на непрекъснатите величини

8.6.1 Математическо очакване и дисперсия

По аналогичен начин на дискретните случайни величини, където математическото очакване се получаваше като сума от произведенията на стойностите с техните вероятности $\mathbb{E}X = \sum x_i p_i$,

при непрекъснатите величини сумата логично се заменя с интеграл (тъй като интегралът е граница на сума), а вероятностите преминават в плътност.

Дефиниция 8.16. Нека X е непрекъснатата случайна величина. Ако интегралът $\int_{-\infty}^{\infty} |x|f_X(x)dx < \infty$ е краен, то *математическото очакване* на X се дефинира като:

$$\mathbb{E}X = \int_{-\infty}^{\infty} xf_X(x)dx$$

От гледна точка на механиката, ако разглеждаме плътността $f_X(x)$ като разпределение на масата върху пръчка, очакването $\mathbb{E}X$ е точно центърът на тежестта на тази пръчка.

Дефиниция 8.17 (дисперсия на непрекъснатата случайна величина). Ако $\mathbb{E}X$ съществува и $\mathbb{E}[(X - \mathbb{E}X)^2] < \infty$, то *дисперсията* $\mathbb{D}X$ се дефинира като средноквадратичното отклонение от очакването:

$$\mathbb{D}X = \mathbb{E}(X - \mathbb{E}X)^2 = \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f_X(x) dx.$$

Ако искаме да пресметнем математическото очакване на функция от случайната величина $g(X)$ и $\int_{-\infty}^{\infty} |g(x)|f_X(x) dx < \infty$, не е необходимо първо да намираме плътността на $Y = g(X)$. Използваме директната формула (която се доказва строго чрез теория на мярката, но следва интуитивно от току-що доказаната теорема за смяна на променливите):

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f_X(x)dx$$

Твърдение 8.18 (Свойства на очакването и дисперсията). Следните свойства остават в сила, когато съответните величини са дефинирани (нека a, b, c са константи). За линейността е достатъчна интегрируемост на участващите величини; за $\mathbb{E}[XY]$ приемаме $X, Y \in L^1$ и независими, а за равенствата с дисперсии приемаме $X, Y \in L^2$:

- Очакване на константа: $\mathbb{E}c = c$
- Дисперсия на константа: $\mathbb{D}c = 0$
- Линейност на очакването: $\mathbb{E}(aX + b) = a\mathbb{E}X + b$ и $\mathbb{E}(aX + bY) = a\mathbb{E}X + b\mathbb{E}Y$
- Изместване на дисперсията: $\mathbb{D}(X + c) = \mathbb{D}X$
- Машабиране на дисперсията: $\mathbb{D}(aX) = a^2\mathbb{D}X$
- Независимост: Ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[XY] = \mathbb{E}X \cdot \mathbb{E}Y$ и $\mathbb{D}(X + Y) = \mathbb{D}X + \mathbb{D}Y$

8.6.2 Равномерно разпределение

Равномерното разпределение (Uniform distribution) е най-простият клас непрекъснати случайни величини. То се използва изключително често като априорно разпределение, когато нямаме никаква допълнителна информация или експертни познания за системата и искаме да избегнем субективизъм (т.е. стартираме на чисто).

Казваме, че X е равномерно разпределена в интервала $[a, b]$, където $a < b$ са крайни числа, ако плътността ѝ е постоянна в този интервал и нула извън него. За да бъде лицето под графиката на плътността равно на 1 (както изисква дефиницията), плътността трябва да е:

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & \text{иначе} \end{cases}$$

Лесно се проверява, че $\int_a^b \frac{1}{b-a} dx = \frac{1}{b-a} \cdot (b-a) = 1$. Нарича се равномерно, защото за подинтервали с еднаква дължина вероятността случайната величина да попадне в тях е напълно еднаква, без значение къде се намира подинтервалът в рамките на $[a, b]$.

Функцията на разпределение за равномерното разпределение се получава чрез директно интегриране:

$$F_X(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & x \in (a, b) \\ 1, & x \geq b \end{cases}$$

Ако $x \in (a, b)$, то $F_X(x) = \int_{-\infty}^x f_X(y) dy = \int_a^x \frac{1}{b-a} dy = \frac{x-a}{b-a}$. За $x \leq a$ интегралът е от 0, следователно 0. За $x \geq b$ плътността след b отново е 0, така че целият интеграл се свежда до площта над целия интервал $[a, b]$, която е 1.

8.7 Задачи

Следващите задачи са редакторско допълнение към лекцията.

1. Нека $Y = aX + b$, където $a \neq 0$. Използвайте теоремата за смяна на променливите, за да намерите плътността на Y чрез плътността на X .
2. Проверете от дефиницията, че функцията

$$f(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x), \quad a < b,$$

е плътност: тя е неотрицателна и интегралът ѝ върху реалната права е единица.