

## Лекция 12. Точкови оценки. Максимално правдоподобие и метод на моментите

### 12.1 Въведение в статистиката и концепцията за извадки

Започваме нашето занимание със статистиката — наука, която лежи в основата на вероятностите, използвайки техния фундамент за изграждането на апарат, техники и модели, чрез които можем да изучаваме явления около нас, за които имаме непълна или липсваща информация.

Какво означава това? Представете си, че имате някаква генерална съвкупност — например всички хора в дадена държава, всички клетки в организма, молекули или гласоподаватели. Искаме да изучим някакво тяхно свойство, като например средната височина на хората в България или пропорцията на мъжете и жените. Оказва се обаче, че изследването на всеки един обект от тази съвкупност е твърде скъпо и непрактично. Вместо да разпитваме всеки отделен човек (което би било непосилно), ние правим оценка за свойството на базата на *извадка* — подмножество от обектите, което избираме, за да разберем какво е разпределението на изследваната характеристика.

Самият избор на извадка не е тривиална задача. В историята има показателни примери за провали при съставянето ѝ. Един от тях е през 1936 г. за президентските избори в САЩ. Една компания прави опит да прогнозира изхода от изборите въз основа на много голяма извадка, набирайки я чрез телефонни указатели. По онова време обаче телефони са имали предимно по-богатите хора. Поради това извадката е имала систематично изкривяване (*bias*) към определена социална страта и прогнозата им се проваля. За разлика от тях, фирмата на Джордж Галъп с едва 4000 респонденти успява да прогнозира правилно, защото тяхната извадка е била представителна и подбрана напълно случайно, отразявайки реалната структура на обществото (включително както по-богати, така и по-бедни). В нашите разглеждания ние винаги ще предполагаме, че извадката се прави напълно случайно и е представителна за генералната съвкупност.

Тук „случайно“ е интуитивното описание на дизайн, а н.е.р.с.в. е отделно моделно допускане: случайният избор сам по себе си не гарантира независимост (например при извадка без връщане от крайна съвкупност).

#### 12.1.1 Математическа постановка

Имаме някаква случайна величина  $X$ , описваща интересуващото ни свойство (например височина, доход, глас за определен кандидат). Тя има функция на разпределение  $F_X(x) = \mathbb{P}(X \leq x)$ , а в случай на непрекъсната величина — и плътност  $f_X(x)$ .

Целта ни е, чрез извадка от  $n$  на брой наблюдения, да оценим тази функция на разпределение или нейната плътност. Приемаме като моделно допускане, че наблюденията  $X_1, X_2, \dots, X_n$  са *независими и еднакво разпределени случайни величини* (н.е.р.с.в.), като всяко  $X_j$  има същото разпределение като  $X$ :

$$\vec{X} = (X_1, X_2, \dots, X_n)$$

Това е концептуалната постановка. В практиката ние провеждаме експеримента или запитването и получаваме конкретни числови стойности  $x_1, x_2, \dots, x_n$ , които представляват реализацията на случайната величина  $\vec{X}$ . От тези числа, ние трябва да направим обосновано предположение за функцията на разпределение  $F_X(x)$  или за плътността  $f_X(x)$ . В тази лекция  $\bar{X}_n$  и  $\bar{X}_n^{(j)}$  означават

извадъчни моменти; това е локална конвенция и не се отнася до символите за стандартизирани величини в други части на книгата.

## 12.2 Точкови оценки

Ако нямаме никакви предварителни допускания за функцията на разпределение на  $X$ , задачата е много трудна. В класическата параметрична статистика ние стесняваме задачата, като допускаме, че  $X$  принадлежи на определен клас от случайни величини, параметризиран с даден параметър  $\theta$ .

Например:

- $X \sim \text{Ber}(p)$  — Бернулиево разпределение, където  $\theta = p$  (вероятността за успех, напр. гласуване за даден кандидат).
- $X \sim \text{Exp}(\lambda)$  — Експоненциално разпределение за време на живот на електронни компоненти, където  $\theta = \lambda$ .
- $X \sim N(\mu, \sigma^2)$  — Нормално разпределение, където параметърът е двумерен вектор  $\theta = (\mu, \sigma^2)$ .

По този начин, вместо да търсим произволна функция, нашата цел се свежда до това да намерим оценка  $\hat{\theta}$  за параметъра  $\theta$  въз основа на наблюденията. Това води до концепцията за *точкова оценка* (Point Estimator).

Точковата оценка  $\hat{\theta} = \hat{\theta}(\vec{X})$  е функция на случайния вектор от наблюденията, която ни служи като приближение за истинската, но неизвестна стойност на параметъра  $\theta$ . Тъй като всяка функция може формално да се разглежда като оценка, имаме нужда от методи за конструиране на оценки, които притежават оптимални свойства. Два от най-популярните метода са Методът на максималното правдоподобие (МПО) и Методът на моментите (ММО).

## 12.3 Метод на максималното правдоподобие (МПО)

Методът на максималното правдоподобие, или Maximum Likelihood Estimation (MLE), почива на една много интуитивна идея: от всички възможни стойности за параметъра  $\theta$  ние трябва да изберем тази, при която вероятността (или съвместната плътност) да наблюдаваме данните, които реално сме получили, е възможно най-голяма.

### 12.3.1 Дефиниция на функция на правдоподобие

Нека  $X$  е случайна величина от параметричен модел с параметър  $\theta \in \Theta$  и нека  $g_\theta$  означава нейната вероятностна маса (в дискретния случай) или плътност (в непрекъснатия случай). Имаме н.е.р.с.в. извадка  $\vec{X} = (X_1, X_2, \dots, X_n)$ .

★ **Дефиниция 12.1 (функция на правдоподобие).** Функция на правдоподобие за фиксирани наблюдавани данни  $\vec{x} = (x_1, \dots, x_n)$  наричаме функцията на параметъра  $L(\theta; \vec{x})$ :

$$L(\theta; \vec{x}) = \prod_{j=1}^n g_{\theta}(x_j), \quad \theta \in \Theta.$$

Тя използва pmf или плътност, а не функцията на разпределение. Независимостта дава факторизацията на съвместната pmf/плътност в това произведение.

За конкретна реализация на извадката  $\vec{x} = (x_1, \dots, x_n)$ , функцията на правдоподобие от дефиниция 12.1 е:

$$L(\theta; \vec{x}) = \prod_{j=1}^n g_{\theta}(x_j)$$

**Максимално правдоподобна оценка (МПО)**  $\hat{\theta}(\vec{x})$  е стойност на параметъра, която достига максимума:

$$\hat{\theta}(\vec{x}) \in \arg \max_{\theta \in \Theta} L(\theta; \vec{x}), \quad L(\hat{\theta}(\vec{x}); \vec{x}) = \sup_{\theta \in \Theta} L(\theta; \vec{x}).$$

Ако супремумът не се достига в  $\Theta$ , МПО не съществува за тези данни.

За удобство при пресмятанията, понеже логаритъмът е строго растяща функция, върху областта  $\{\theta \in \Theta : L(\theta; \vec{x}) > 0\}$  максимизирането на  $L$  е еквивалентно на максимизирането на:

$$\ln L(\theta; \vec{x}) = \sum_{j=1}^n \ln g_{\theta}(x_j)$$

Ако  $g_{\theta}(x)$  е диференцируема по параметъра, уравненията на оценката по градиента дават само вътрешни стационарни кандидати в тази положително правдоподобна област:

$$\frac{\partial \ln L(\theta; \vec{x})}{\partial \theta} = 0$$

Границата на параметърното пространство и точките с нулево правдоподобие трябва да се проверят отделно.

▷ **Пример 12.2 (Равномерно разпределение  $U(0, \theta)$ ).** Допускаме, че  $X$  е равномерно разпределена в интервала  $(0, \theta)$ , т.е.  $X \sim U(0, \theta)$ . Параметърът  $\theta > 0$ . За да се получи достигащ се максимум, тук изрично използваме коригиращата конвенция за затворен десен край  $(0, \theta]$ :

$$f_X(x; \theta) = \frac{1}{\theta} \mathbf{1}_{(0, \theta]}(x)$$

Функцията на правдоподобие за  $n$  наблюдения е:

$$L(\theta; \vec{x}) = \prod_{j=1}^n \frac{1}{\theta} \mathbf{1}_{(0, \theta]}(x_j) = \frac{1}{\theta^n} \mathbf{1}_{\{\min_j x_j > 0\}} \mathbf{1}_{(0, \theta]}(x^*) = \begin{cases} \frac{1}{\theta^n} & \text{ако } \min_j x_j > 0 \text{ и } x^* \leq \theta, \\ 0 & \text{иначе.} \end{cases}$$


където  $x^* = \max_{j \leq n} (x_j)$  е максималната стойност сред наблюденията. При данни от модела долният индикатор е равен на 1 почти сигурно и тогава може да се потисне само в последващото оптимизиране.<sup>a</sup>

Търсим  $\hat{\theta}$ , което максимизира  $L(\theta; \vec{x})$  за фиксирани наблюдавани данни:

$$L(\hat{\theta}; \vec{x}) = \sup_{\theta > 0} L(\theta; \vec{x})$$

Тъй като функцията  $\frac{1}{\theta^n}$  е строго намаляваща по  $\theta$ , нейната максимална стойност се достига в най-малката възможна точка за  $\theta$ , при която функцията не е нула. За данни с  $\min_j x_j > 0$  според индикатора трябва  $\theta \geq x^*$ . Следователно най-голямата стойност се постига, когато:

$$\hat{\theta}_1 = X^* = \max_{j \leq n} (X_j)$$



**Фигура 1:** Функцията на правдоподобие при  $U(0, \theta)$ . За  $\theta < X^*$  поне едно наблюдение пада извън носителя и  $L$  е нула; за  $\theta \geq X^*$  функцията е  $\theta^{-n}$  и намалява. Максимумът е в самата точка  $X^*$  — тук не помага диференциране, а самата форма на функцията. Затова и дясният край на индикатора трябва да е включен: при отворен интервал стойността в  $X^*$  би била нула и максимум изобщо нямаше да се достига.

<sup>a</sup>Записът с  $(0, \theta]$  е изрично коригираща редакторска конвенция: на дъската/в записе е използван отворен десен край  $(0, \theta)$ . При отворен интервал супремумът при  $\theta = x^*$  не се достига. Тъй като  $\mathbb{P}(X = \theta) = 0$ , двете конвенции имат едно и също разпределение на наблюдението.

Ако например сме получили наблюденията 1, 2, 3, 4 и 5, максимално правдоподобната оценка за  $\theta$  би била просто най-голямата стойност — 5.

► **Пример 12.3 (Нормално разпределение  $N(\mu, \sigma^2)$ ).** Нека  $X \sim N(\mu, \sigma^2)$ , където  $\mu \in \mathbb{R}$  и  $\sigma^2 > 0$ . Имаме два параметъра за оценяване:  $\theta = (\mu, \sigma^2)$ . Плътността на нормалното разпределение за едно наблюдение е:

$$f_X(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Съставяме функцията на правдоподобие за извадката  $\vec{X}$ :

$$L(\theta; \vec{X}) = \left( \frac{1}{\sqrt{2\pi}} \right)^n (\sigma^2)^{-n/2} e^{-\sum_{j=1}^n \frac{(X_j - \mu)^2}{2\sigma^2}}$$

Логаритмуваме я, за да превърнем произведението в сума, което значително улеснява диференцирането:

$$\ln L(\theta; \vec{X}) = n \ln \frac{1}{\sqrt{2\pi}} - \frac{n}{2} \ln \sigma^2 - \sum_{j=1}^n \frac{(X_j - \mu)^2}{2\sigma^2}$$

Намираме частната производна спрямо  $\mu$  и я приравняваме на нула:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{j=1}^n (X_j - \mu) = 0$$

$$\sum_{j=1}^n X_j - n\mu = 0 \implies \hat{\mu} = \frac{1}{n} \sum_{j=1}^n X_j = \bar{X}_n$$

Оценката за  $\mu$  е средното аритметично на наблюденията. Забележете, че тя не зависи от това дали познаваме  $\sigma^2$  или не.

Сега намираме частната производна спрямо  $\sigma^2$  и я приравняваме на нула:

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{j=1}^n (X_j - \mu)^2 = 0$$

Ако параметърът  $\mu$  ни е предварително известен, решението директно ни дава:

$$\hat{\sigma}_\mu^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \mu)^2$$

Ако  $\mu$  е неизвестен, заместваме неговата оценка  $\hat{\mu} = \bar{X}_n$  в уравнението, откъдето получаваме:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X}_n)^2$$

Двете формули са оценки на един и същ параметър, но в два различни модела, затова ги различаваме с индекс:  $\hat{\sigma}_\mu^2$  използва известното  $\mu$ , докато  $\hat{\sigma}^2$  разчита само на извадката. Навсякъде по-нататък  $\hat{\sigma}^2$  означава втората. При неизвестни  $\mu$  и  $\sigma^2$  тази стационарна точка е МПО само ако

$$\text{RSS} = \sum_{j=1}^n (X_j - \bar{X}_n)^2 > 0.$$

Това е изпълнено например при  $n \geq 2$  и наблюдения, които не са всички равни. Ако  $n = 1$  или всички наблюдения са равни, правдоподобие то става неограничено при  $\sigma^2 \downarrow 0$  и МПО не съществува в модела  $\sigma^2 > 0$ ; стойността  $\hat{\sigma}^2 = 0$  е само граничен кандидат извън параметърното пространство. Аналогично, при известно  $\mu$  е нужно  $\sum_j (X_j - \mu)^2 > 0$ .

## 12.4 Метод на моментите (ММО)

Методът на моментите почива на Закона за големите числа, според който при н.е.р.с.в. извадка и крайни абсолютни моменти от нужните редове емпиричните (извадкови) моменти се сходят почти сигурно към теоретичните моменти на разпределението при увеличаване на обема на извадката.

Нека въведем емпиричния момент от ред  $j$ :

$$\bar{X}_n^{(j)} = \frac{1}{n} \sum_{k=1}^n X_k^j, \quad j \geq 1$$

Това е средното аритметично от наблюденията, повдигнати на  $j$ -та степен. (При  $j = 1$  получаваме обикновеното средно аритметично  $\bar{X}_n$ ).

**Дефиниция 12.4 (ММО).** Нека  $X$  е случайна величина с функция на разпределение  $F_X(x; \theta)$ , където параметърът е  $s$ -мерен вектор  $\theta = (\theta_1, \dots, \theta_s)$ . При н.е.р.с.в. извадка и условия  $\mathbb{E}|X|^j < \infty$  за  $1 \leq j \leq s$ , оценката по метода на моментите се определя като предварително избрано измеримо решение  $\hat{\theta} \in \Theta$  на системата:

$$\mu^{(j)}(\theta) = \bar{X}_n^{(j)}, \quad 1 \leq j \leq s$$

където  $\mu^{(j)}(\theta) = \mathbb{E}[X^j]$  са теоретичните моменти на случайната величина като функция на параметъра  $\theta$ .

Ако системата няма решение в параметърното пространство или има повече от едно, това не определя еднозначна оценка: трябва да се посочи правило за избор (или оценката да се обяви за недефинирана). При инективно моментно отображение  $\theta \mapsto (\mu^{(1)}(\theta), \dots, \mu^{(s)}(\theta))$  решението е единствено; непрекъснатостта на обратното отображение (например локална обратимост) е условието, което позволява да се пренесе сходимостта на моментите към състоятелност на оценката.

Идеята е да приравним първите  $s$  на брой теоретични момента към съответните извадкови моменти и да решим получената система спрямо неизвестните параметри. Тъй като  $\bar{X}_n^{(j)} \rightarrow \mathbb{E}[X^j]$  при  $n \rightarrow \infty$  при тези хипотези, методът дава оценки, които при условията за съществуване, избор и обратимост на моментното отображение клонят към истинските стойности на параметрите.

▷ **Пример 12.5 (Равномерно разпределение  $U(0, \theta)$  (ММО)).** Разглеждаме отново случая  $X \sim U(0, \theta)$ . Тъй като имаме само един параметър, се нуждаем от едно уравнение — за първия момент. Теоретичното очакване на  $X$  е:

$$\mathbb{E}[X] = \frac{\theta}{2}$$

Емпиричният първи момент е средното аритметично  $\bar{X}_n$ . Приравняваме ги:

$$\frac{\theta}{2} = \bar{X}_n$$

Оттук директно изразяваме оценката по ММО за  $\theta$ :

$$\hat{\theta}_2 = 2\bar{X}_n$$

Виждаме, че за равномерното разпределение двата метода (МПО и ММО) дават коренно различни оценки ( $\hat{\theta}_1 = \max(X_j)$  срещу  $\hat{\theta}_2 = 2\bar{X}_n$ ).

▷ **Пример 12.6 (Нормално разпределение  $N(\mu, \sigma^2)$  (ММО)).** Нека  $X \sim N(\mu, \sigma^2)$ . Имаме два параметъра ( $\mu$  и  $\sigma^2$ ), затова ни трябва първите два момента. Теоретичните моменти са:

$$\mathbb{E}[X] = \mu$$

$$\mathbb{E}[X^2] = \mathbb{D}(X) + (\mathbb{E}[X])^2 = \sigma^2 + \mu^2$$

Съставяме системата от уравнения, приравнявайки ги към емпиричните моменти:

$$\begin{aligned} \mu &= \bar{X}_n^{(1)} \\ \sigma^2 + \mu^2 &= \bar{X}_n^{(2)} \end{aligned}$$

От първото уравнение веднага получаваме:

$$\hat{\mu} = \overline{X}_n^{(1)} = \frac{1}{n} \sum_{j=1}^n X_j$$

Замествайки  $\hat{\mu}$  във второто уравнение, получаваме оценката за дисперсията:

$$\hat{\sigma}^2 = \overline{X}_n^{(2)} - \left(\overline{X}_n^{(1)}\right)^2 = \frac{1}{n} \sum_{j=1}^n X_j^2 - \left(\frac{1}{n} \sum_{j=1}^n X_j\right)^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \overline{X}_n)^2$$

В случая на нормалното разпределение, оценките по метода на моментите (ММО) и по метода на максималното правдоподобие (МПО) съвпадат напълно.

## 12.5 Свойства на точковите оценки

За да определим коя от получените оценки е по-добра, изследваме техните статистически свойства, като *неизместеност* (unbiasedness) и *състоятелност* (consistency).

**Дефиниция 12.7** (неизместена оценка). Една оценка  $\hat{\theta}$  се нарича *неизместена*, ако нейното математическо очакване съвпада с истинската стойност на параметъра:

$$\mathbb{E}[\hat{\theta}] = \theta.$$

**Дефиниция 12.8** (асимптотично неизместена оценка). Оценката  $\hat{\theta} = \hat{\theta}_n$  (която зависи от броя наблюдения  $n$ ) се нарича *асимптотично неизместена*, ако

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\theta}_n] = \theta.$$

Неизместеността е свойство „в средно“: тя гарантира, че няма системна грешка, но не казва нищо за това какво се случва при повече наблюдения. Когато оценяваме  $\mu$  при нормално разпределение, средното аритметично е неизместено дори при две наблюдения — а очевидно две наблюдения не дават добра оценка. Затова ни трябва второ свойство.

★ **Дефиниция 12.9 (състоятелност).** Оценката  $\hat{\theta}_n$  се нарича *състоятелна* за  $\theta$ , ако се сходя да към  $\theta$  по вероятност:

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta, \quad \text{тоест} \quad \mathbb{P}(|\hat{\theta}_n - \theta| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0 \quad \forall \varepsilon > 0.$$

Ако сходимостта е почти сигурна,  $\hat{\theta}_n \xrightarrow{\text{п.с.}} \theta$ , оценката се нарича *силно състоятелна*.

Състоятелността е гаранцията, че увеличаването на извадката приближава истинската стойност.

† **Допълнение 12.10 (Състоятелност на извадковите моменти (авторско допълнение)).**

Нека  $k$  е положително цяло число и нека  $(X_j)_{j \geq 1}$  са н.е.р.с.в. с  $\mathbb{E}|X_1|^k < \infty$ . Тогава извадковият момент  $\overline{X}_n^{(k)} = \frac{1}{n} \sum_{j=1}^n X_j^k$  е силно състоятелна оценка за теоретичния момент  $\mathbb{E}[X_1^k]$ .

Изискването за краен момент не е формалност: без него твърдението е невярно. Ако  $X_1$  е с разпределение на Коши (допълнението към лекция 9), то  $\mathbb{E}|X_1|$  не съществува и  $\bar{X}_n$  не се сходя към нищо.

*Доказателство.* Полагаме  $Y_j = X_j^k$ . Величините  $Y_j$  са независими и еднакво разпределени, и  $\mathbb{E}|Y_1| = \mathbb{E}|X_1|^k < \infty$  по условие, така че усиленият закон е приложим. А  $\bar{X}_n^{(k)} = \frac{1}{n} \sum_{j=1}^n Y_j$ . По усиления закон за големите числа (теорема ??) тази средна аритметична се сходя почти сигурно към  $\mathbb{E}[Y_1] = \mathbb{E}[X_1^k]$ .  $\square$

В частност при  $k = 1$  получаваме, че  $\bar{X}_n$  е силно състоятелна оценка за  $\mu$  — и това не зависи по никакъв начин от  $\sigma^2$ . Допълнение 12.10 е и оправданието за метода на моментите: приравнявайки теоретични към извадкови моменти, ние приравняваме нещо неизвестно към нещо, което сигурно се приближава до него.

† **Допълнение 12.11 (оценка с минимална дисперсия; ефективна оценка).** Неизместената оценка  $\hat{\theta}$  се нарича *оценка с минимална дисперсия*, ако за всяка друга неизместена оценка  $\tilde{\theta}$  е изпълнено  $\mathbb{D}\hat{\theta} \leq \mathbb{D}\tilde{\theta}$ . Неизместена оценка с минимална дисперсия се нарича *ефективна*. Ако за даден параметър съществува ефективна оценка, тя е единствена.

† **Допълнение 12.12 (Неравенство на Крамер–Рао (авторско допълнение)).** Дефиниция 12.11 казва кога една оценка е ефективна, но не дава начин да се провери. Това прави неравенството на Крамер–Рао, което поставя долна граница за дисперсията на всяка неизместена оценка. За скаларен параметър в отворено параметърно множество, при параметър-независим носител, диференцируемост на правдоподобие с доминираща интегрируема мажоранта, оправдана смяна на диференциране и интегриране, неизместена оценка и крайна положителна информация на Фишер, е в сила

$$\mathbb{D}\hat{\theta} \geq \frac{1}{n I(\theta)}, \quad I(\theta) = \mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \ln g_{\theta}(X) \right)^2 \right],$$

където  $I(\theta)$  се нарича *информация на Фишер*. Оценка, за която тази граница се достига с равенство, е ефективна. Така въпросът „може ли да се направи по-добре?“ получава проверим отговор: ако дисперсията на нашата оценка съвпада с дясната страна, по-добра неизместена оценка няма. Моделът  $U(0, \theta)$  е нерегулярен, защото носителът зависи от  $\theta$ ; следователно тази форма на границата не може да се прилага към него (например чрез вътрешния резултат за  $I(\theta)$ ).

### 12.5.1 Свойства на оценките при $U(0, \theta)$

Сравняваме двете получени оценки:  $\hat{\theta}_1 = X^*$  (от МПО) и  $\hat{\theta}_2 = 2\bar{X}_n$  (от ММО).

За оценката по метода на моментите  $\hat{\theta}_2$ :

$$\mathbb{E}[\hat{\theta}_2] = \mathbb{E}[2\bar{X}_n] = \frac{2}{n} \sum_{j=1}^n \mathbb{E}[X_j] = \frac{2}{n} \cdot n \cdot \frac{\theta}{2} = \theta$$

Тъй като  $\mathbb{E}[\hat{\theta}_2] = \theta$ , оценката  $\hat{\theta}_2$  е **неизместена** по смисъла на дефиниция 12.7. Освен това, благодарение на Закона за големите числа,  $\bar{X}_n \xrightarrow{\text{п.с.}} \frac{\theta}{2}$ , следователно  $\hat{\theta}_2$  е и **силно състоятелна** оценка.



За оценката по метода на максималното правдоподобие  $\hat{\theta}_1 = X^*$ : За да намерим очакването на  $X^*$ , първо намираме нейната функция на разпределение  $F_{X^*}(x)$  за  $x \in (0, \theta)$ :

$$F_{X^*}(x) = \mathbb{P}(X^* \leq x) = \mathbb{P}\left(\bigcap_{j=1}^n \{X_j \leq x\}\right)$$

Тъй като наблюденията са независими и еднакво разпределени, вероятността от сечението се разпада в произведение от вероятностите:

$$F_{X^*}(x) \stackrel{\text{незав.}}{=} \prod_{j=1}^n \mathbb{P}(X_j \leq x) = (\mathbb{P}(X_1 \leq x))^n = \left(\frac{x}{\theta}\right)^n, \quad x \in (0, \theta)$$

Плътността се получава чрез диференциране:

$$f_{X^*}(x) = n \frac{x^{n-1}}{\theta^n}, \quad x \in (0, \theta)$$

Сега пресмятаме математическото очакване на  $X^*$ :

$$\mathbb{E}[X^*] = \int_0^\theta x \cdot n \frac{x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \left[ \frac{x^{n+1}}{n+1} \right]_0^\theta = \frac{n}{n+1} \theta$$

Тъй като  $\mathbb{E}[\hat{\theta}_1] = \frac{n}{n+1} \theta \neq \theta$ , оценката по метода на максималното правдоподобие не изпълнява дефиниция 12.7 и е **изместена**. Това е интуитивно логично — максималната стойност в извадката винаги ще бъде малко по-малка от същинската горна граница  $\theta$ . С увеличаването на извадката обаче, този максимум се доближава все повече до истинското  $\theta$  (оценката е асимптотично неизместена). Ако желаем строго неизместена оценка, базирана на  $X^*$ , можем да я конструираме като:

$$\tilde{\theta}_1 = \frac{n+1}{n} X^*$$

Въпреки че  $X^*$  е изместена, тя все пак е **състоятелна**. Понеже  $X^* \leq \theta$  почти сигурно, за  $0 < \varepsilon < \theta$  събитието  $\{|X^* - \theta| > \varepsilon\}$  съвпада (с вероятност 1) със събитието  $\{X^* < \theta - \varepsilon\}$ . Тогава:

$$\mathbb{P}(|X^* - \theta| > \varepsilon) = \mathbb{P}(X^* < \theta - \varepsilon) = \left(\frac{\theta - \varepsilon}{\theta}\right)^n, \quad 0 < \varepsilon < \theta.$$

За  $\varepsilon \geq \theta$  лявата вероятност е нула, тъй като  $X^* > 0$  почти сигурно и  $X^* \leq \theta$ . При  $n \rightarrow \infty$  първият израз клони към 0, което показва, че  $X^*$  се сходя по вероятност към  $\theta$ .

## 12.5.2 Изместеност на дисперсията при Нормално разпределение

Нека обърнем внимание и на получената оценка за дисперсията при  $N(\mu, \sigma^2)$ :

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X}_n)^2$$

**Твърдение 12.13** (Изместеност на  $\hat{\sigma}^2$ ).

$$\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2.$$

*Доказателство.* Без загуба на общност центрираме: заместваме  $X_j$  с  $X_j - \mu$ , което не променя нито  $\hat{\sigma}^2$ , нито  $\sigma^2$ , така че можем да приемем  $\mathbb{E}X_j = 0$  и  $\mathbb{E}X_j^2 = \sigma^2$ . Разкриваме квадрата:

$$\begin{aligned}\hat{\sigma}^2 &= \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X}_n)^2 = \frac{1}{n} \sum_{j=1}^n X_j^2 - 2\bar{X}_n \cdot \frac{1}{n} \sum_{j=1}^n X_j + \bar{X}_n^2 \\ &= \frac{1}{n} \sum_{j=1}^n X_j^2 - \bar{X}_n^2.\end{aligned}$$

Взимаме очакване на двете събираеми. За първото, понеже величините са еднакво разпределени,  $\mathbb{E}[\frac{1}{n} \sum_j X_j^2] = \mathbb{E}X_1^2 = \sigma^2$ . За второто:

$$\mathbb{E}[\bar{X}_n^2] = \frac{1}{n^2} \mathbb{E}\left[\sum_{j=1}^n X_j\right]^2 = \frac{1}{n^2} \left(\sum_{j=1}^n \mathbb{E}X_j^2 + \sum_{i \neq j} \mathbb{E}[X_i X_j]\right).$$

Величините са независими и центрирани, затова  $\mathbb{E}[X_i X_j] = \mathbb{E}X_i \mathbb{E}X_j = 0$  за  $i \neq j$ , и остава само диагоналят:

$$\mathbb{E}[\bar{X}_n^2] = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

Следователно

$$\mathbb{E}[\hat{\sigma}^2] = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2.$$

□

*Забележка 12.14* (Загубената степен на свобода). Ако  $\mu$  е известно и в дефиницията на  $\hat{\sigma}^2$  използваме него вместо  $\bar{X}_n$ , то  $\mathbb{E}[\frac{1}{n} \sum_j (X_j - \mu)^2] = \sigma^2$  точно — оценката е неизместена. Измествеността се появява именно защото сме заменили  $\mu$  с оценка, получена от същите данни. Евристично: от  $n$  наблюдения сте използвали едно, за да оцените  $\mu$ , и са ви останали  $n - 1$  степени на свобода. Това обяснява защо нормиращият множител е  $\frac{1}{n-1}$ , а не  $\frac{1}{n}$ .

Тоест, получената по методите МПО и ММО оценка  $\hat{\sigma}^2$  е изместена (тя систематично подценява истинската дисперсия, понеже използва емпиричното средно вместо истинското). За  $n \geq 2$  се дефинира *коригираната извадкова дисперсия*:

$$S^2 = \frac{n}{n-1} \hat{\sigma}^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}_n)^2$$

За нея вече е в сила:

$$\mathbb{E}[S^2] = \frac{n}{n-1} \mathbb{E}[\hat{\sigma}^2] = \frac{n}{n-1} \frac{n-1}{n} \sigma^2 = \sigma^2$$

което я прави неизместена оценка за параметъра  $\sigma^2$ .

## 12.6 Задачи (редакторско допълнение)

1. За нормалния модел от пример 12.3, при  $n \geq 2$  и наблюдения, които не са всички равни, пресметнете частните производни на  $\ln L(\vec{X}; \mu, \sigma^2)$  по  $\mu$  и по  $\sigma^2$ , приравнете ги на нула и решете получената система. Отбележете защо при  $n = 1$  или при еднакви наблюдения МПО не съществува.

2. Нека  $X_1, \dots, X_n$  са независими и равномерно разпределени в  $(0, \theta)$  и  $X^* = \max_{j \leq n} X_j$ . Проверете състоятелността на оценката  $\hat{\theta}_1 = X^*$ , като разгледате отделно  $0 < \varepsilon < \theta$  и  $\varepsilon \geq \theta$  и пресметнете

$$\mathbb{P}(X^* < \theta - \varepsilon)$$

и изследвайте границата при  $n \rightarrow \infty$ .