

Лекция 13. Доверителни интервали и проверка на хипотези

1 Доверителни интервали

1.1 Постановка на задачата

Нека имаме някаква случайна величина X с функция на разпределение $F_X(x, \theta)$, която е от някакъв клас разпределения, параметризиран чрез параметъра θ , където $\theta \in \mathbb{R}$. В тази лекция ще разглеждаме само едномерни модели, тоест параметърът, от който зависи разпределението, е едномерно число.

Разполагаме с извадка $\vec{X} = (X_1, \dots, X_n)$ от наблюдения. На базата на данните от тази извадка ние можем да конструираме точкова оценка $\hat{\theta} = \hat{\theta}(\vec{X})$, която е функция на наблюденията. За точковата оценка $\hat{\theta}$ вече знаем от предишни лекции какви свойства може да притежава: състоятелност, неизместеност, как е добита (по метода на максималното правдоподобие или по метода на моментите) и в какъв смисъл е оптимална.

Доверителният интервал се опитва да реши един друг проблем. Ако имаме някаква извадка, чрез точковата оценка ще получим някакво конкретно число, например 1,2546, може би и с още знаци след десетичната запетая. Възниква въпросът: колко близо е това число до истинското θ ? Искаме да имаме някаква хубава гаранция, че с голяма вероятност това число е близо до истинския параметър, който стои зад модела.

Следователно, целта ни е въз основа на извадката $\vec{X}$ да дефинираме един интервал с две граници – лява граница $I_1 = I_1(\vec{X})$ и дясна граница $I_2 = I_2(\vec{X})$, така че вероятността истинският параметър θ да попадне между тях да бъде поне γ .

Дефиниция 1.1 (доверителен интервал и ниво на доверие). Интервалът (I_1, I_2) , за който

$$\mathbb{P}(I_1 \leq \theta \leq I_2) \geq \gamma,$$

се нарича *доверителен интервал* за θ с *ниво на доверие* γ .

Често използвани стойности за γ са 0,95, 0,99 или 0,90, в зависимост от конкретния проблем, който решаваме.

Много е важно да се отбележи къде точно се крие стохастичността (случайността) в това неравенство. Истинското θ не е случайно – то е някакъв фиксиран, обективно съществуващ параметър на модела, който ние искаме да открием. Случайни са границите I_1 и I_2 , които се определят от извадката. Концептуално те са случайни величини, а при конкретна реализация на извадката (когато измерим данните), те ще бъдат просто две числа.

1.2 Централна статистика

Как можем да намерим такива доверителни интервали? Ще ги дефинираме строго посредством така наречената *централна статистика*.

Дефиниция 1.2 (централна статистика). Нека $T = T(\vec{X}, \theta)$ е функция, която зависи както от данните $\vec{X}$, така и от неизвестния параметър θ . Казваме, че T е *централна статистика*, ако са изпълнени следните две свойства:

- А) Като функция на θ , T е монотонна (разглеждаме само едномерни модели, където $\theta \in \mathbb{R}$).
- Б) Функцията на разпределение на T , която ще означим с $H(x) = \mathbb{P}(T < x)$, не зависи от параметъра θ .

Тоест, въпреки че самата функция T зависи от две променливи (вектора от наблюдения $\vec{X}$ и параметъра θ), разпределението ѝ не зависи от θ .

1.3 Конструирание на интервала

Как тази централна статистика ни позволява да конструираме доверителен интервал с ниво на доверие γ ?

Нека приемем за момента, че функцията на разпределение $H(x)$ има плътност $h(x) = H'(x)$, за да можем да си представим нещата нагледно. Целта ни е да подберем две квантилни стойности q_1 и q_2 , такива че вероятностната маса между тях да е точно γ :

$$H(q_2) - H(q_1) = \gamma$$

Тъй като търсим само разликата да е γ , имаме два свободни параметъра q_1 и q_2 и много голямо разнообразие от начини, по които да ги изберем. Можем да изместваме q_1 и q_2 наляво или надясно, стига площта под графиката на плътността между тях да остава γ .

Най-често q_1 и q_2 се избират така, че грешката да е симетрична – тоест остатъкът от вероятността $1 - \gamma$ да се раздели поравно в двата края (в двете „опашки“ на разпределението). Така в лявата опашка оставяме маса $\frac{1-\gamma}{2}$, а в дясната опашка оставяме също $\frac{1-\gamma}{2}$:

$$H(q_1) = \frac{1-\gamma}{2}$$

$$H(q_2) = 1 - \frac{1-\gamma}{2} = \frac{1+\gamma}{2}$$

Това означава, че ако бъркаме, ще бъркаме еднакво и от ляво, и от дясно. Разбира се, има ситуации (в зависимост от модела), при които може да сложим $q_1 = -\infty$ и да оставим цялата маса $1 - \gamma$ в дясната опашка. Ние обаче ще се фокусираме върху симетричния случай.

Ако разпределението на централната статистика е симетрично около нулата (както ще видим при нормалното разпределение), тогава можем да изберем $q_1 = -q$ и $q_2 = q$, където $q = q_{\frac{1+\gamma}{2}}$ е съответният квантил. Така двете граници се отличават само по знак.

След като сме избрали q_1 и q_2 , имаме:

$$\mathbb{P}(q_1 < T(\vec{X}, \theta) < q_2) = \gamma$$

Тъй като T е монотонна функция по θ (нека допуснем, че е монотонно намаляваща), можем да обърнем неравенствата спрямо θ и да получим:

$$I_1(\vec{X}) < \theta < I_2(\vec{X})$$

където I_1 и I_2 са търсените граници на доверителния интервал.

2 Примери за доверителни интервали

2.1 Известна дисперсия

Нека имаме извадка от n независими и еднакво разпределени наблюдения $\vec{X} = (X_1, \dots, X_n)$ от нормално разпределение:

$$X \sim N(\mu, \sigma^2)$$

В този първи пример предполагаме, че дисперсията σ^2 е **известна**. Неизвестният параметър, за който искаме да конструираме доверителен интервал с ниво на доверие $\gamma = 0,95$, е математическото очакване μ .

Знаем, че точковата оценка за μ , която е оптимална (както по метода на максималното правдоподобие, така и по метода на моментите), е средното аритметично на извадката:

$$\bar{X}_n^{(1)} = \frac{1}{n} \sum_{j=1}^n X_j$$

Тъй като сума от нормални случайни величини е отново нормална случайна величина, разпределението на средното аритметично е:

$$\bar{X}_n^{(1)} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

За да конструираме централна статистика, центрираме $\bar{X}_n^{(1)}$ като извадим средното μ и нормираме, като разделим на стандартното отклонение $\sigma/\sqrt{n}$:

$$T = \frac{\bar{X}_n^{(1)} - \mu}{\sigma/\sqrt{n}} \sim \underline{\underline{N(0, 1)}}$$

Статистиката T е изключително удобна. Тя е монотонно намаляваща по μ (това е линейна функция на μ с отрицателен коефициент) и разпределението ѝ е стандартно нормално $N(0, 1)$, което изобщо не зависи от μ . Следователно T е централна статистика, а нейната функция на разпределение $H(x) = \Phi(x)$ е добре позната.

Тъй като $N(0, 1)$ е симетрично разпределение, можем да вземем квантили $q_1 = -q$ и $q_2 = q$. За ниво на доверие $\gamma = 0,95$, търсим q такава, че:

$$\gamma = 0,95 = \mathbb{P}(-q < T < q) = \mathbb{P}\left(-q < \frac{\bar{X}_n^{(1)} - \mu}{\sigma/\sqrt{n}} < q\right)$$

Това означава, че в двете опашки извън интервала $[-q, q]$ трябва да остане общо вероятност 0,05, или по 0,025 във всяка. От таблиците за стандартното нормално разпределение знаем, че квантилят, съответстващ на площ 0,975 вляво от него, е точно $q = 1,96$.

Решаваме неравенствата вътре във вероятността спрямо μ :

$$\begin{aligned} -q \frac{\sigma}{\sqrt{n}} < \bar{X}_n^{(1)} - \mu < q \frac{\sigma}{\sqrt{n}} \\ \mathbb{P}\left(\underbrace{\bar{X}_n^{(1)} - \frac{q\sigma}{\sqrt{n}}}_{T_1} < \mu < \underbrace{\bar{X}_n^{(1)} + \frac{q\sigma}{\sqrt{n}}}_{T_2}\right) = \gamma \end{aligned}$$

Получихме явния вид на левия и десния край на доверителния интервал:

$$T_1 = \bar{X}_n^{(1)} - \frac{q\sigma}{\sqrt{n}}$$

$$T_2 = \bar{X}_n^{(1)} + \frac{q\sigma}{\sqrt{n}}$$

Тези граници зависят от извадката единствено чрез нейното средно аритметично $\bar{X}_n^{(1)}$.

Дължината на този доверителен интервал е:

$$T_2 - T_1 = \frac{2q\sigma}{\sqrt{n}}$$

Тук ясно се вижда едно съвсем естествено и желателно свойство: когато размерът на извадката n нараства (когато имаме повече наблюдения), интервалът се свива. Оценката ни става все по-точна и по-близка до истинското μ .

2.2 Неизвестна дисперсия. Разпределение на Стюдент

Ситуацията става малко по-сложна, ако дисперсията σ^2 е **неизвестна**. Имаме един параметър μ , който ни интересува и за който искаме да конструираме доверителен интервал (например с $\gamma = 0,95$), но имаме и втори неизвестен параметър σ^2 .

Точковите оценки за двата параметъра са:

$$\hat{\mu} = \bar{X}_n$$

$$\hat{\sigma}^2 = \frac{\sum_{j=1}^n (X_j - \bar{X}_n)^2}{n} = \frac{n-1}{n} S^2$$

където $S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}_n)^2$ е неизместената точкова оценка за дисперсията.

Как можем да конструираме централна статистика за μ на базата на S^2 , без да знаем истинското σ^2 ? Ключът към решаването на тази задача се крие в следното много интересно и нетривиално твърдение:

Твърдение 2.1. Средното аритметично $\hat{\mu} = \bar{X}_n$ е **независимо** от извадковата дисперсия S^2 :

$$\hat{\mu} \perp\!\!\!\perp S^2$$

и освен това:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Това е дълбок факт, защото $\bar{X}_n$ участва директно във формулата за S^2 , и въпреки това те са независими случайни величини.

Интуитивно обяснение на разпределението на S^2 : Нека разгледаме стандартизираните случайни величини $Z_j = \frac{X_j - \mu}{\sigma} \sim N(0, 1)$. Сумата от техните квадрати дава разпределение хи-квадрат (χ^2) с n степени на свобода:

$$\sum_{j=1}^n Z_j^2 = \sum_{j=1}^n \left(\frac{X_j - \mu}{\sigma} \right)^2 =: U \sim \chi^2(n)$$

След чисто алгебрични преобразувания, прибавяйки и изваждайки $\bar{X}_n$ в числителя, изразът U може да бъде разбит на две части:

$$U = (n-1) \frac{\sum_{j=1}^n (X_j - \bar{X}_n)^2}{\sigma^2(n-1)} + n \frac{(\bar{X}_n - \mu)^2}{\sigma^2}$$

Кое то може да се запише чрез S^2 :

$$U = \underbrace{\frac{(n-1)S^2}{\sigma^2}}_{U_n} + \underbrace{\frac{n(\bar{X}_n - \mu)^2}{\sigma^2}}_{Z_n^2}$$

Вече знаем, че $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ е стандартно нормално $N(0, 1)$, следователно квадратът му Z_n^2 е хи-квадрат разпределен с 1 степен на свобода, $\chi^2(1)$. Цялата сума U е с n степени на свобода. Благодарение на факта, че двете събираеми са независими, техните степени на свобода се сумират: $n-1$ степени от U_n плюс 1 степен от Z_n^2 дават общо n .

Да се върнем на конструирането на централната статистика. Ние искаме да използваме точковата оценка $\bar{X}_n$, да я центрираме изваждайки μ , но тъй като не знаем σ , ще я разделим на нейната оценка $S/\sqrt{n}$:

$$T_n = \frac{\bar{X}_n - \mu}{S/\sqrt{n}}$$

За да намерим разпределението на T_n , можем да извършим следната еквилибристика – да умножим и разделим едновременно на неизвестното σ :

$$T_n = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\frac{S}{\sigma}} = \frac{Z_n}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{Z_n}{\sqrt{\frac{U_n}{n-1}}}$$

В числителя имаме $Z_n \sim N(0, 1)$, а в знаменателя имаме корен квадратен от $U_n \sim \chi^2(n-1)$, разделено на неговите степени на свобода. Тъй като $\bar{X}_n$ и S^2 са независими, Z_n и U_n също са независими. По дефиниция, такова отношение дефинира **разпределение на Стюдент** (или t-разпределение) с $n-1$ степени на свобода:

$$T_n = \frac{Z_n}{\sqrt{\frac{U_n}{n-1}}} = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t(n-1)$$

Получихме красив резултат: T_n е монотонно намаляваща функция по μ , а нейното разпределение $t(n-1)$ не зависи от μ и не съдържа неизвестното σ . Следователно, T_n е централна статистика за μ .

Тъй като t-разпределението също е симетрично (подобно на нормалното, но с малко по-тежки опашки), за да намерим доверителен интервал с ниво на доверие γ , избираме симетрични квантили $-q$ и q , където $q = q_{\frac{1+\gamma}{2}}$ е квантилът на $t(n-1)$ разпределението.

$$\gamma = \mathbb{P}(I_1 < \mu < I_2) = \mathbb{P}(-q < T_n < q)$$

По същия начин както в раздел 2.1, решаваме спрямо μ и получаваме доверителния интервал:

$$I_1 = \bar{X}_n - q \frac{S}{\sqrt{n}}, \quad I_2 = \bar{X}_n + q \frac{S}{\sqrt{n}}$$

2.3 Връзка с Централната гранична теорема (ЦГТ)

Един важен коментар за разпределението на Стюдент: когато обемът на извадката n е достатъчно голям (в практиката често се приема $n \geq 30$), T_n може да се приближи много добре чрез стандартно нормално разпределение:

$$T_n \approx Z_n \sim N(0, 1)$$

Това е така, защото по Закона за големите числа, знаменателят $\sqrt{\frac{U_n}{n-1}} \sim 1$, което означава, че за голямо n той почти не влияе на статистиката. Квантилите на t-разпределението при големи степени на свобода на практика съвпадат с квантилите на нормалното разпределение, което значително улеснява пресмятанията.

Но по-важното следствие е във връзка с **Централната гранична теорема (ЦГТ)**. Ако имате извадка от произволна случайна величина X (не задължително нормална), която има някакво математическо очакване $EX = \mu$ и дисперсия $DX = \sigma^2$, то при голямо n , статистиката $T_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ е приблизително разпределена като $N(0, 1)$. Това е силата на математиката – не е нужно да знаем точното разпределение на данните (дали е експоненциално, поасоново или някакво друго), стига да разполагаме с достатъчно голяма извадка (обикновено $n \geq 30$ е достатъчно), за да третираме T_n като стандартно нормално разпределение и да конструираме доверителни интервали за μ . Дори когато σ е неизвестно, можем да го заместим с оценката S , и за голямо n приближението продължава да работи отлично.

3 Проверка на хипотези

3.1 Основни понятия

При проверката на статистически хипотези формулираме твърдения относно неизвестните параметри на изследвания модел. Разглеждаме две съревноваващи се хипотези:

- Нулева хипотеза $H_0 : \theta = \theta_0$
- Алтернативна хипотеза $H_1 : \theta = \theta_1$

Дефиниция 3.1 (критична област). Подмножеството на пространството на извадките $W \subseteq \mathbb{R}^n$, чрез което вземаме решение коя хипотеза да приемем на базата на извадката $\vec{X}$, наричаме **критична област**.

Правилото за вземане на решение е следното:

- Ако реализацията на извадката попадне в критичната област, $\vec{X} \in W$, ние **отхвърляме** нулевата хипотеза H_0 и приемаме алтернативата H_1 .
- Ако реализацията не попадне в критичната област, $\vec{X} \notin W$, ние **приемаме** (по-точно, не можем да отхвърлим) нулевата хипотеза H_0 .

Тъй като данните са случайни, винаги има риск да вземем грешно решение. Възможни са два вида грешки:

Дефиниция 3.2 (грешки от I-ви и II-ри род). • *Грешка от I-ви род*: да отхвърлим H_0 , въпреки че тя е вярна. Вероятността за тази грешка бележим с α и наричаме *ниво на значимост*:

$$\mathbb{P}(\vec{X} \in W \mid H_0) = \alpha_W = \alpha$$

• *Грешка от II-ри род*: да приемем H_0 , въпреки че тя е грешна (т.е. вярна е H_1). Вероятността за тази грешка бележим с β :

$$\mathbb{P}(\vec{X} \notin W \mid H_1) = \beta_W = \beta$$

Целта в теорията на проверката на хипотези е да фиксираме нивото на значимост α (например на 0,05 или 0,01) и при това фиксирано ограничение да изберем такава критична област, която минимизира вероятността за грешка от втори род β_W .

Дефиниция 3.3 (най-мощна критична област). Критичната област W^* се нарича *най-мощна* (н.м.о.), или *оптимална* (о.к.о.), при фиксирано $\alpha = \alpha_{W^*}$, ако за всяка друга критична област W със същата грешка от първи род ($\alpha_W = \alpha_{W^*} = \alpha$) е изпълнено:

$$\beta_{W^*} = \min_{\alpha_W = \alpha_{W^*} = \alpha} \beta_W.$$

Това е еквивалентно на максимизиране на мощността на критерия $1 - \beta_W = \mathbb{P}(\vec{X} \in W \mid H_1)$.

3.2 Лема на Нейман-Пийърсън

Тази лема ни дава мощен инструмент за намиране на най-мощната критична област при проверка на две прости хипотези.

Нека имаме случайна величина X с плътност $f_X(x; \theta)$. Тогава съвместната плътност (функцията на правдоподобие) за извадката $\vec{X}$ е $L(\vec{x}, \theta)$. Означаваме функцията на правдоподобие при вярна нулева хипотеза с $L_0(\vec{x}) = L(\vec{x}, \theta_0)$, а при вярна алтернативна хипотеза с $L_1(\vec{x}) = L(\vec{x}, \theta_1)$.

Лема 3.4 (Нейман-Пийърсън). Ако съществуват константа $k > 0$ и критична област $W^* \subseteq \mathbb{R}^n$ с грешка от първи род α , такива че

$$W^* \subseteq \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq kL_0(\vec{x})\}$$

и за нейното допълнение

$$(W^*)^c \subseteq \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \leq kL_0(\vec{x})\},$$

то W^* е най-мощната критична област (н.м.о.) за проверка на хипотезата H_0 срещу алтернативата H_1 на ниво на значимост α .

3.3 Пример: Тест за средното на нормално разпределение

Ще приложим лемата на Нейман-Пийърсън в един класически пример. Нека имаме извадка $\vec{X} = (X_1, \dots, X_n)$ от нормално разпределение $X \sim N(\mu, \sigma^2)$, при което дисперсията σ^2 е **известна**.

Искаме да проверим нулевата хипотеза, че средното μ е равно на някаква стойност μ_0 , срещу алтернативата, че е равно на по-голяма стойност μ_1 :

- $H_0 : \mu = \mu_0$
- $H_1 : \mu = \mu_1$ (като приемаме, че $\mu_1 > \mu_0$)

Нивото на значимост (грешката от първи род) е фиксирано, например $\alpha = 0,05$.

Започваме като запишем функциите на правдоподобие за двете хипотези:

$$L_0(\vec{x}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \frac{1}{\sigma^n} \prod_{j=1}^n e^{-\frac{(x_j - \mu_0)^2}{2\sigma^2}}$$

$$L_1(\vec{x}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \frac{1}{\sigma^n} \prod_{j=1}^n e^{-\frac{(x_j - \mu_1)^2}{2\sigma^2}}$$

По лемата на Нейман-Пиърсън, ние търсим критична област от вида $W^* = \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq k L_0(\vec{x})\}$. Да видим какво представлява това неравенство, като заместим функциите на правдоподобие. Константите пред произведението се съкращават и неравенството придобива вида:

$$W^* = \left\{ \vec{x} \in \mathbb{R}^n : e^{-\frac{\sum_{j=1}^n (x_j - \mu_1)^2}{2\sigma^2}} \geq k e^{-\frac{\sum_{j=1}^n (x_j - \mu_0)^2}{2\sigma^2}} \right\}$$

Тъй като експоненциалната функция е монотонна, логаритмуваме двете страни:

$$-\frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu_1)^2 \geq \ln k - \frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu_0)^2$$

Умножаваме по $2\sigma^2$:

$$-\sum_{j=1}^n (x_j - \mu_1)^2 \geq 2\sigma^2 \ln k - \sum_{j=1}^n (x_j - \mu_0)^2$$

Разкриваме скобите във всяка от сумите:

$$-\sum_{j=1}^n x_j^2 + 2\mu_1 \sum_{j=1}^n x_j - n\mu_1^2 \geq 2\sigma^2 \ln k - \sum_{j=1}^n x_j^2 + 2\mu_0 \sum_{j=1}^n x_j - n\mu_0^2$$

Членовете $-\sum_{j=1}^n x_j^2$ от двете страни се съкращават. Групираме членовете, които съдържат $\sum_{j=1}^n x_j$ отляво, а останалите константи прехвърляме отясно:

$$2(\mu_1 - \mu_0) \sum_{j=1}^n x_j \geq 2\sigma^2 \ln k + n\mu_1^2 - n\mu_0^2$$

От условието $\mu_1 > \mu_0$ знаем, че $2(\mu_1 - \mu_0) > 0$. Следователно, можем да разделим на този израз, без да се обръща знакът на неравенството:

$$\sum_{j=1}^n x_j \geq \frac{2\sigma^2 \ln k + n\mu_1^2 - n\mu_0^2}{2(\mu_1 - \mu_0)}$$

Цялата дясна страна на това неравенство е просто някаква нова константа, тъй като всички величини в нея ($\sigma, \mu_0, \mu_1, n, k$) са фиксирани числа. Нека я означим с $\tilde{K}$. Така, формата на най-мощната критична област значително се опростява:

$$W^* = \left\{ \vec{x} \in \mathbb{R}^n : \sum_{j=1}^n x_j \geq \underbrace{\frac{2\sigma^2 \ln K + n\mu_1^2 - n\mu_0^2}{2(\mu_1 - \mu_0)}}_{\tilde{K}} \right\}$$

Това правило е много интуитивно: отхвърляме хипотезата за по-малкото средно μ_0 в полза на по-голямото средно μ_1 , когато сумата от наблюденията надвиши определен праг $\tilde{K}$.

Остава единствено да определим стойността на константата $\tilde{K}$. Тя се намира от условието вероятността за грешка от първи род да бъде точно α :

$$\alpha = \mathbb{P}(\vec{X} \in W^* \mid H_0) = \mathbb{P}\left(\sum_{j=1}^n X_j \geq \tilde{K} \mid H_0\right)$$

Тъй като пресмятаме вероятността при условие, че H_0 е вярна, ние знаем, че всяко $X_j \sim N(\mu_0, \sigma^2)$. Следователно можем да центрираме и нормираме сумата, за да получим стандартно нормално разпределение:

$$\mathbb{P}\left(\frac{\sum_{j=1}^n X_j - n\mu_0}{\sigma\sqrt{n}} \geq \frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}} \mid H_0\right) = \alpha$$

Лявата страна в неравенството вече е стандартна нормална величина $Z \sim N(0, 1)$. Нека означим дясната страна с $q_{1-\alpha}$, което е квантилът на нормалното разпределение, оставящ площ α в дясната опашка (или $1 - \alpha$ в лявата). Имаме:

$$\mathbb{P}\left(Z \geq \frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}}\right) = \alpha$$

Следователно приравняваме границата на квантила:

$$\frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}} = q_{1-\alpha}$$

Квантилът $q_{1-\alpha}$ (например за $\alpha = 0,05$ от таблиците се намира стойността му) може да бъде намерен от статистическите таблици. От това уравнение еднозначно се намира константата $\tilde{K}$, с което най-мощната критична област W^* е напълно определена.