

## Лекция 13. Доверителни интервали и проверка на хипотези

### 13.1 Доверителни интервали

#### 13.1.1 Постановка на задачата

Нека имаме някаква случайна величина  $X$  с функция на разпределение  $F_X(x, \theta)$ , която е от някакъв клас разпределения, параметризиран чрез параметъра  $\theta$ , където  $\theta \in \mathbb{R}$ . В тази лекция ще разглеждаме само едномерни модели, тоест параметърът, от който зависи разпределението, е едномерно число.

Разполагаме с извадка  $\vec{X} = (X_1, \dots, X_n)$  от наблюдения. На базата на данните от тази извадка ние можем да конструираме точкова оценка  $\hat{\theta} = \hat{\theta}(\vec{X})$ , която е функция на наблюденията. За точковата оценка  $\hat{\theta}$  вече знаем от предишни лекции какви свойства може да притежава: състоятелност, неизместеност, как е добита (по метода на максималното правдоподобие или по метода на моментите) и в какъв смисъл е оптимална.

Доверителният интервал се опитва да реши един друг проблем. Ако имаме някаква извадка, чрез точковата оценка ще получим някакво конкретно число, например 1,2546, може би и с още знаци след десетичната запетая. Възниква въпросът: колко близо е това число до истинското  $\theta$ ? Искаме да имаме някаква хубава гаранция, че с голяма вероятност това число е близо до истинския параметър, който стои зад модела.

Следователно, целта ни е въз основа на извадката  $\vec{X}$  да дефинираме един интервал с две граници — лява граница  $I_1 = I_1(\vec{X})$  и дясна граница  $I_2 = I_2(\vec{X})$ , така че вероятността истинският параметър  $\theta$  да попадне между тях да бъде поне  $\gamma$ .

★ **Дефиниция 13.1 (доверителен интервал и ниво на доверие).** Интервалът  $(I_1, I_2)$ , за който

$$\mathbb{P}(I_1 < \theta < I_2) \geq \gamma,$$

се нарича *доверителен интервал* за  $\theta$  с *ниво на доверие*  $\gamma$ .

Навсякъде по-нататък централните статистики са с непрекъснати разпределения, така че  $\mathbb{P}(T = q) = 0$  и няма значение дали неравенствата са строги или не. Затова в пресмятанията ще ги пишем както е по-удобно.

Често използвани стойности за  $\gamma$  са 0,95, 0,99 или 0,90, в зависимост от конкретния проблем, който решаваме.

Много е важно да се отбележи къде точно се крие стохастичността (случайността) в това неравенство. Истинското  $\theta$  не е случайно — то е някакъв фиксиран, обективно съществуващ параметър на модела, който ние искаме да открием. Случайни са границите  $I_1$  и  $I_2$ , които се определят от извадката. Концептуално те са случайни величини, а при конкретна реализация на извадката (когато измерим данните), те ще бъдат просто две числа.

#### 13.1.2 Централна статистика

Как можем да намерим такива доверителни интервали? Ще ги дефинираме строго посредством така наречената *централна статистика*.

**Дефиниция 13.2** (централна статистика). Нека  $T = T(\vec{X}, \theta)$  е функция, която зависи както от данните  $\vec{X}$ , така и от неизвестния параметър  $\theta$ . Казваме, че  $T$  е *централна статистика*, ако са изпълнени следните две свойства:

- А) Като функция на  $\theta$ ,  $T$  е монотонна (разглеждаме само едномерни модели, където  $\theta \in \mathbb{R}$ ).
- Б) Функцията на разпределение на  $T$ , която ще означим с  $H(x) = \mathbb{P}(T < x)$ , не зависи от параметъра  $\theta$ .

Тоест, въпреки че самата функция  $T$  зависи от две променливи (вектора от наблюдения  $\vec{X}$  и параметъра  $\theta$ ), разпределението ѝ не зависи от  $\theta$ .

### 13.1.3 Конструирание на интервала

Как централната статистика от дефиниция 13.2 ни позволява да конструираме доверителен интервал с ниво на доверие  $\gamma$  по дефиниция 13.1?

Нека приемем за момента, че функцията на разпределение  $H(x)$  има плътност  $h(x) = H'(x)$ , за да можем да си представим нещата нагледно. Целта ни е да подберем две квантилни стойности  $q_1$  и  $q_2$ , такива че вероятностната маса между тях да е точно  $\gamma$ :


$$H(q_2) - H(q_1) = \gamma$$

Тъй като търсим само разликата да е  $\gamma$ , имаме два свободни параметъра  $q_1$  и  $q_2$  и много голямо разнообразие от начини, по които да ги изберем. Можем да изместваме  $q_1$  и  $q_2$  наляво или надясно, стига площта под графиката на плътността между тях да остане  $\gamma$ .

Най-често  $q_1$  и  $q_2$  се избират така, че грешката да е симетрична — тоест остатъкът от вероятността  $1 - \gamma$  да се раздели поравно в двата края (в двете „опашки“ на разпределението). Така в лявата опашка оставяме маса  $\frac{1-\gamma}{2}$ , а в дясната опашка оставяме също  $\frac{1-\gamma}{2}$ :

$$H(q_1) = \frac{1-\gamma}{2}$$

$$H(q_2) = 1 - \frac{1-\gamma}{2} = \frac{1+\gamma}{2}$$



**Фигура 1:** Симетричен избор на квантилите. Заштрихованата площ между  $q_1$  и  $q_2$  е нивото на доверие  $\gamma$ ; в двете опашки остава по  $\frac{1-\gamma}{2}$ . При симетрично около нулата разпределение  $q_1 = -q$  и  $q_2 = q$ .

Това означава, че ако бъркаме, ще бъркаме еднакво и от ляво, и от дясно. Разбира се, има ситуации (в зависимост от модела), при които може да сложим  $q_1 = -\infty$  и да оставим цялата маса  $1 - \gamma$  в дясната опашка. Ние обаче ще се фокусираме върху симетричния случай.

Досега говорихме за  $q_1$  и  $q_2$  като за „точки, между които остава маса  $\gamma$ “. Нека дадем на това име.

**Дефиниция 13.3** (Квантил). Нека  $F$  е функция на разпределение и  $\gamma \in (0, 1)$ .  $\gamma$ -квантилът  $q_\gamma$  е числото, за което

$$\mathbb{P}(X \leq q_\gamma) = \gamma, \quad X \sim F,$$

тоест точката, вляво от която остава вероятностна маса  $\gamma$ . При строго растяща непрекъсната  $F$  такова число съществува и е единствено:  $q_\gamma = F^{-1}(\gamma)$ .

Записът  $q_\gamma$  винаги се отнася към конкретно разпределение, което се уточнява от контекста:  $q_{0,975} = 1,96$  за  $N(0, 1)$ , но  $q_{0,975} = 2,776$  за  $t(4)$ . Числените стойности са дадени в приложението със статистическите таблици.

Ако разпределението на централната статистика е симетрично около нулата (както ще видим при нормалното разпределение), тогава можем да изберем  $q_1 = -q$  и  $q_2 = q$ , където  $q = q_{\frac{1+\gamma}{2}}$  е съответният квантил. Така двете граници се отличават само по знак.

След като сме избрали  $q_1$  и  $q_2$ , имаме:

$$\mathbb{P}(q_1 < T(\vec{X}, \theta) < q_2) = \gamma$$

Тъй като  $T$  е монотонна функция по  $\theta$  (нека допуснем, че е монотонно намаляваща), можем да обърнем неравенствата спрямо  $\theta$  и да получим:

$$I_1(\vec{X}) < \theta < I_2(\vec{X})$$

където  $I_1$  и  $I_2$  са търсените граници на доверителния интервал.

## 13.2 Примери за доверителни интервали

### 13.2.1 Известна дисперсия

Нека имаме извадка от  $n$  независими и еднакво разпределени наблюдения  $\vec{X} = (X_1, \dots, X_n)$  от нормално разпределение:

$$X \sim N(\mu, \sigma^2)$$

В този първи пример предполагаме, че дисперсията  $\sigma^2$  е **известна**. Неизвестният параметър, за който искаме да конструираме доверителен интервал с ниво на доверие  $\gamma = 0,95$ , е математическото очакване  $\mu$ .

Знаем, че точковата оценка за  $\mu$ , която е оптимална (както по метода на максималното правдоподобие, така и по метода на моментите), е средното аритметично на извадката:

$$\bar{X}_n = \frac{1}{n} \sum_{j=1}^n X_j$$

Тъй като сума от нормални случайни величини е отново нормална случайна величина, разпределението на средното аритметично е:

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

За да конструираме централна статистика, центрираме  $\bar{X}_n$  като извадим средното  $\mu$  и нормираме, като разделим на стандартното отклонение  $\sigma/\sqrt{n}$ :

$$T = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \underline{\underline{N(0, 1)}}$$

Статистиката  $T$  е изключително удобна. Тя е монотонно намаляваща по  $\mu$  (това е линейна функция на  $\mu$  с отрицателен коефициент) и разпределението ѝ е стандартно нормално  $N(0, 1)$ , което изобщо не зависи от  $\mu$ . Следователно  $T$  е централна статистика, а нейната функция на разпределение  $H(x) = \Phi(x)$  е добре позната.

Тъй като  $N(0, 1)$  е симетрично разпределение, можем да вземем квантили  $q_1 = -q$  и  $q_2 = q$ . За ниво на доверие  $\gamma = 0,95$ , търсим  $q$  такава, че:

$$\gamma = 0,95 = \mathbb{P}(-q < T < q) = \mathbb{P}\left(-q < \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} < q\right)$$

Това означава, че в двете опашки извън интервала  $[-q, q]$  трябва да остане общо вероятност 0,05, или по 0,025 във всяка. От таблиците за стандартното нормално разпределение знаем, че квантилът, съответстващ на площ 0,975 вляво от него, е точно  $q = 1,96$ .

Решаваме неравенствата вътре във вероятността спрямо  $\mu$ :

$$\begin{aligned} -q \frac{\sigma}{\sqrt{n}} < \bar{X}_n - \mu < q \frac{\sigma}{\sqrt{n}} \\ \mathbb{P}\left(\underbrace{\bar{X}_n - \frac{q\sigma}{\sqrt{n}}}_{T_1} < \mu < \underbrace{\bar{X}_n + \frac{q\sigma}{\sqrt{n}}}_{T_2}\right) = \gamma \end{aligned}$$

Получихме явния вид на левия и десния край на доверителния интервал:

$$\begin{aligned} T_1 &= \bar{X}_n - \frac{q\sigma}{\sqrt{n}} \\ T_2 &= \bar{X}_n + \frac{q\sigma}{\sqrt{n}} \end{aligned}$$

Тези граници зависят от извадката единствено чрез нейното средно аритметично  $\bar{X}_n$ .

Дължината на този доверителен интервал е:

$$T_2 - T_1 = \frac{2q\sigma}{\sqrt{n}}$$

Тук ясно се вижда едно съвсем естествено и желателно свойство: когато размерът на извадката  $n$  нараства (когато имаме повече наблюдения), интервалът се свива. Оценката ни става все по-точна и по-близка до истинското  $\mu$ .

### 13.2.2 Доверителен интервал за дисперсията при известно $\mu$

Ако  $X \sim N(\mu, \sigma^2)$  и средното  $\mu$  е известно, а търсим интервал за  $\sigma^2$ , за централна статистика служи

$$V_n = \frac{n\hat{\sigma}_\mu^2}{\sigma^2} = \sum_{j=1}^n \left(\frac{X_j - \mu}{\sigma}\right)^2 \sim \chi^2(n),$$

където  $\hat{\sigma}_\mu^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \mu)^2$ . Всяко събираемо е квадрат на стандартно нормална величина, а събираемите са независими, откъдето и разпределението  $\chi^2(n)$ . Разпределението не зависи от  $\sigma^2$ , а  $V_n$  е монотонна по  $\sigma^2$  — следователно  $V_n$  е централна статистика по дефиниция 13.2 и интервалът се получава по същата схема като по-горе.<sup>1</sup>

<sup>1</sup>Този раздел е възстановен от записа на дъската (кадър в 61-ата минута); аудиозаписът на лекцията прекъсва по-рано.

### 13.2.3 Неизвестна дисперсия. Разпределение на Стюдент

Ситуацията става малко по-сложна, ако дисперсията  $\sigma^2$  е **неизвестна**. Имаме един параметър  $\mu$ , който ни интересува и за който искаме да конструираме доверителен интервал (например с  $\gamma = 0,95$ ), но имаме и втори неизвестен параметър  $\sigma^2$ .

Точковите оценки за двата параметъра са:

$$\hat{\mu} = \bar{X}_n$$

$$\hat{\sigma}^2 = \frac{\sum_{j=1}^n (X_j - \bar{X}_n)^2}{n} = \frac{n-1}{n} S^2$$

където  $S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}_n)^2$  е неизместената точкова оценка за дисперсията.

Как можем да конструираме централна статистика за  $\mu$  на базата на  $S^2$ , без да знаем истинското  $\sigma^2$ ? Ключът към решаването на тази задача се крие в следното много интересно и нетривиално твърдение:

**Твърдение 13.4.** Нека  $X_1, \dots, X_n$  са независими и **нормално** разпределени,  $X_j \sim N(\mu, \sigma^2)$ . Тогава средното аритметично  $\hat{\mu} = \bar{X}_n$  е **независимо** от извадковата дисперсия  $S^2$ :

$$\hat{\mu} \perp\!\!\!\perp S^2$$

и освен това:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Това е дълбок факт, защото  $\bar{X}_n$  участва директно във формулата за  $S^2$ , и въпреки това те са независими случайни величини.

Нормалността тук е съществена, а не удобно допълнително предположение: може да се докаже, че  $\bar{X}_n$  и  $S^2$  са независими *само* при нормално разпределение. Затова цялата конструкция по-долу — и разпределението на Стюдент, което следва от нея — важи за нормални извадки, а за други разпределения е в най-добрия случай приближение.

*Интуитивно обяснение на разпределението на  $S^2$ :* Нека разгледаме стандартизираните случайни величини  $Z_j = \frac{X_j - \mu}{\sigma} \sim N(0, 1)$ . Сумата от техните квадрати дава разпределение хи-квадрат ( $\chi^2$ ) с  $n$  степени на свобода:

$$\sum_{j=1}^n Z_j^2 = \sum_{j=1}^n \left( \frac{X_j - \mu}{\sigma} \right)^2 =: U \sim \chi^2(n)$$

След чисто алгебрични преобразувания, прибавяйки и изваждайки  $\bar{X}_n$  в числителя, изразът  $U$  може да бъде разбит на две части:

$$U = (n-1) \frac{\sum_{j=1}^n (X_j - \bar{X}_n)^2}{\sigma^2(n-1)} + n \frac{(\bar{X}_n - \mu)^2}{\sigma^2}$$

Кое то може да се запише чрез  $S^2$ :

$$U = \underbrace{\frac{(n-1)S^2}{\sigma^2}}_{U_n} + \underbrace{\frac{n(\bar{X}_n - \mu)^2}{\sigma^2}}_{Z_n^2}$$

Вече знаем, че  $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$  е стандартно нормално  $N(0, 1)$ , следователно квадратът му  $Z_n^2$  е хи-квадрат разпределен с 1 степен на свобода,  $\chi^2(1)$ . Цялата сума  $U$  е с  $n$  степени на свобода. Бла-

годарение на факта, че двете събираеми са независими, техните степени на свобода се сумират:  $n - 1$  степени от  $U_n$  плюс 1 степен от  $Z_n^2$  дават общо  $n$ .

Да се върнем на конструирането на централната статистика. Ние искаме да използваме точковата оценка  $\bar{X}_n$ , да я центрираме изваждайки  $\mu$ , но тъй като не знаем  $\sigma$ , ще я разделим на нейната оценка  $S/\sqrt{n}$ :

$$T_n = \frac{\bar{X}_n - \mu}{S/\sqrt{n}}$$

За да намерим разпределението на  $T_n$ , можем да извършим следната еквилибристика — да умножим и разделим едновременно на неизвестното  $\sigma$ :

$$T_n = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\frac{S}{\sigma}} = \frac{Z_n}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{Z_n}{\sqrt{\frac{U_n}{n-1}}}$$

В числителя имаме  $Z_n \sim N(0, 1)$ , а в знаменателя имаме корен квадратен от  $U_n \sim \chi^2(n - 1)$ , разделено на неговите степени на свобода. Тъй като  $\bar{X}_n$  и  $S^2$  са независими,  $Z_n$  и  $U_n$  също са независими. По дефиниция, такова отношение дефинира **разпределение на Стюдънт** (или **t-разпределение**) с  $n - 1$  степени на свобода:

$$T_n = \frac{Z_n}{\sqrt{\frac{U_n}{n-1}}} = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t(n - 1)$$

Получихме красив резултат:  $T_n$  е монотонно намаляваща функция по  $\mu$ , а нейното разпределение  $t(n - 1)$  не зависи от  $\mu$  и не съдържа неизвестното  $\sigma$ . Следователно,  $T_n$  е централна статистика за  $\mu$ .

Тъй като **t-разпределението** също е симетрично (подобно на нормалното, но с малко по-тежки опашки), за да намерим доверителен интервал с ниво на доверие  $\gamma$ , избираме симетрични квантили  $-q$  и  $q$ , където  $q = q_{\frac{1+\gamma}{2}}$  е квантилът на  $t(n - 1)$  разпределението.

$$\gamma = \mathbb{P}(I_1 < \mu < I_2) = \mathbb{P}(-q < T_n < q)$$

По същия начин както в раздел 13.2.1, решаваме спрямо  $\mu$  и получаваме доверителния интервал:

$$I_1 = \bar{X}_n - q \frac{S}{\sqrt{n}}, \quad I_2 = \bar{X}_n + q \frac{S}{\sqrt{n}}$$

### 13.2.4 Връзка с Централната гранична теорема (ЦГТ)

Един важен коментар за разпределението на Стюдънт: когато обемът на извадката  $n$  е достатъчно голям (в практиката често се приема  $n \geq 30$ ),  $T_n$  може да се приближи много добре чрез стандартно нормално разпределение:

$$T_n \approx Z_n \sim N(0, 1)$$

Това е така, защото по Закона за големите числа, знаменателят  $\sqrt{\frac{U_n}{n-1}} \approx 1$ , което означава, че за голямо  $n$  той почти не влияе на статистиката. Квантилите на **t-разпределението** при големи степени на свобода на практика съвпадат с квантилите на нормалното разпределение, което значително улеснява пресмятанията.

Но по-важното следствие е във връзка с **Централната гранична теорема (ЦГТ)**. Ако имате извадка от произволна случайна величина  $X$  (не задължително нормална), която има някакво математическо очакване  $\mathbb{E}X = \mu$  и дисперсия  $\mathbb{D}X = \sigma^2$ , то при голямо  $n$ , статистиката  $T_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$  е

приблизително разпределена като  $N(0, 1)$ . Това е силата на математиката — не е нужно да знаем точното разпределение на данните (дали е експоненциално, поасоново или някакво друго), стига да разполагаме с достатъчно голяма извадка (обикновено  $n \geq 30$  е достатъчно), за да третираме  $T_n$  като стандартно нормално разпределение и да конструираме доверителни интервали за  $\mu$ . Дори когато  $\sigma$  е неизвестно, можем да го заместим с оценката  $S$ , и за голямо  $n$  приближението продължава да работи отлично.

## 13.3 Проверка на хипотези

### 13.3.1 Основни понятия

При проверката на статистически хипотези формулираме твърдения относно неизвестните параметри на изследвания модел. Разглеждаме две съревноваващи се хипотези:

- **Нулева хипотеза**  $H_0 : \theta = \theta_0$
- **Алтернативна хипотеза**  $H_1 : \theta = \theta_1$

**Дефиниция 13.5** (критична област). Подмножеството на пространството на извадките  $W \subseteq \mathbb{R}^n$ , чрез което вземаме решение коя хипотеза да приемем на базата на извадката  $\vec{X}$ , наричаме *критична област*.

Правилото за вземане на решение е следното:

- Ако реализацията на извадката попадне в критичната област,  $\vec{X} \in W$ , ние **отхвърляме** нулевата хипотеза  $H_0$  и приемаме алтернативата  $H_1$ .
- Ако реализацията не попадне в критичната област,  $\vec{X} \notin W$ , ние **приемаме** (по-точно, не можем да отхвърлим) нулевата хипотеза  $H_0$ .

Тъй като данните са случайни, винаги има риск да вземем грешно решение. Възможни са два вида грешки:

**Дефиниция 13.6** (грешки от първи и втори род). <sup>a</sup>

- *Грешка от първи род*: да отхвърлим  $H_0$ , въпреки че тя е вярна. Вероятността за тази грешка бележим с  $\alpha$  и наричаме *ниво на значимост*:

$$\mathbb{P}(\vec{X} \in W \mid H_0) = \alpha_W = \alpha$$

- *Грешка от втори род*: да приемем  $H_0$ , въпреки че тя е грешна (т.е. вярна е  $H_1$ ). Вероятността за тази грешка бележим с  $\beta$ :

$$\mathbb{P}(\vec{X} \notin W \mid H_1) = \beta_W = \beta$$

<sup>a</sup>Лекторът въведе двете грешки устно и подчерта, че са „много важно“, но добави: „аз няма да го пиша като дефиниция“ (72-ата минута). Оформени са като дефиниция тук заради по-нататъшните препратки; съдържанието е неговото.

Целта в теорията на проверката на хипотези е да фиксираме грешката от първи род от дефиниция 13.6, тоест нивото на значимост  $\alpha$  (например на 0,05 или 0,01), и при това фиксирано ограничение да изберем критична област по дефиниция 13.5, която минимизира вероятността за грешка от втори род  $\beta_W$ .

**Дефиниция 13.7** (най-мощна критична област). Критичната област  $W^*$  се нарича *оптимална критична област* (о.к.о.), или *най-мощна* (н.м.о.), при фиксирано  $\alpha = \alpha_{W^*}$ , ако за всяка друга критична област  $W$  със същата грешка от първи род ( $\alpha_W = \alpha_{W^*} = \alpha$ ) е изпълнено:

$$\beta_{W^*} = \min_{\alpha_W = \alpha_{W^*} = \alpha} \beta_W.$$

Това е еквивалентно на максимизиране на мощността на критерия  $1 - \beta_W = \mathbb{P}(\vec{X} \in W \mid H_1)$ .

### 13.3.2 Лема на Нейман-Пиърсън

Тази лема ни дава мощен инструмент за намиране на най-мощната критична област по дефиниция 13.7 при проверка на две прости хипотези.

Нека имаме случайна величина  $X$  с плътност  $f_X(x; \theta)$ . Тогава съвместната плътност (функцията на правдоподобие) за извадката  $\vec{X}$  е  $L(\vec{x}, \theta)$ . Означаваме функцията на правдоподобие при вярна нулева хипотеза с  $L_0(\vec{x}) = L(\vec{x}, \theta_0)$ , а при вярна алтернативна хипотеза с  $L_1(\vec{x}) = L(\vec{x}, \theta_1)$ .

★ **Лема 13.8 (Нейман—Пиърсън).** Ако съществуват константа  $k > 0$  и критична област  $W^* \subseteq \mathbb{R}^n$  с грешка от първи род  $\alpha$ , такива че

$$W^* \subseteq \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq kL_0(\vec{x})\}$$

и за нейното допълнение

$$(W^*)^c \subseteq \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \leq kL_0(\vec{x})\},$$

то  $W^*$  е най-мощната критична област (н.м.о.) за проверка на хипотезата  $H_0$  срещу алтернативата  $H_1$  на ниво на значимост  $\alpha$ .

Доказателство не се дава. Лекторът го отложи изрично — „да не се затрудняваме сега с доказателството, ще го оставим следващия път; по-добре е да видим конкретното приложение“ (89-ата минута) — а следващата лекция е посветена на линейната регресия, така че то не беше изнесено. Липсата му тук не е пропуск на записките.

▷ **Пример 13.9 (Тест за средното на нормално разпределение).** Ще приложим лема 13.8 в един класически пример. Нека имаме извадка  $\vec{X} = (X_1, \dots, X_n)$  от нормално разпределение  $X \sim N(\mu, \sigma^2)$ , при което дисперсията  $\sigma^2$  е известна.

Искаме да проверим нулевата хипотеза, че средното  $\mu$  е равно на някаква стойност  $\mu_0$ , срещу алтернативата, че е равно на по-голяма стойност  $\mu_1$ :

- $H_0 : \mu = \mu_0$
- $H_1 : \mu = \mu_1$  (като приемаме, че  $\mu_1 > \mu_0$ )

Нивото на значимост (грешката от първи род) е фиксирано, например  $\alpha = 0,05$ .



Започваме като запишем функциите на правдоподобие за двете хипотези:

$$L_0(\vec{x}) = \left( \frac{1}{\sqrt{2\pi}} \right)^n \frac{1}{\sigma^n} \prod_{j=1}^n e^{-\frac{(x_j - \mu_0)^2}{2\sigma^2}}$$

$$L_1(\vec{x}) = \left( \frac{1}{\sqrt{2\pi}} \right)^n \frac{1}{\sigma^n} \prod_{j=1}^n e^{-\frac{(x_j - \mu_1)^2}{2\sigma^2}}$$

По лема 13.8 търсим критична област от вида  $W^* = \{\vec{x} \in \mathbb{R}^n : L_1(\vec{x}) \geq kL_0(\vec{x})\}$ . Да видим какво представлява това неравенство, като заместим функциите на правдоподобие. Константите пред произведението се съкращават и неравенството придобива вида:

$$W^* = \left\{ \vec{x} \in \mathbb{R}^n : e^{-\frac{\sum_{j=1}^n (x_j - \mu_1)^2}{2\sigma^2}} \geq k e^{-\frac{\sum_{j=1}^n (x_j - \mu_0)^2}{2\sigma^2}} \right\}$$

Тъй като експоненциалната функция е монотонна, логаритмуваме двете страни:

$$-\frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu_1)^2 \geq \ln k - \frac{1}{2\sigma^2} \sum_{j=1}^n (x_j - \mu_0)^2$$

Умножаваме по  $2\sigma^2$ :

$$-\sum_{j=1}^n (x_j - \mu_1)^2 \geq 2\sigma^2 \ln k - \sum_{j=1}^n (x_j - \mu_0)^2$$

Разкриваме скобите във всяка от сумите:

$$-\sum_{j=1}^n x_j^2 + 2\mu_1 \sum_{j=1}^n x_j - n\mu_1^2 \geq 2\sigma^2 \ln k - \sum_{j=1}^n x_j^2 + 2\mu_0 \sum_{j=1}^n x_j - n\mu_0^2$$

Членовете  $-\sum_{j=1}^n x_j^2$  от двете страни се съкращават. Групираме членовете, които съдържат  $\sum_{j=1}^n x_j$  отляво, а останалите константи прехвърляме отдясно:

$$2(\mu_1 - \mu_0) \sum_{j=1}^n x_j \geq 2\sigma^2 \ln k + n\mu_1^2 - n\mu_0^2$$

От условието  $\mu_1 > \mu_0$  знаем, че  $2(\mu_1 - \mu_0) > 0$ . Следователно, можем да разделим на този израз, без да се обръща знакът на неравенството:

$$\sum_{j=1}^n x_j \geq \frac{2\sigma^2 \ln k + n\mu_1^2 - n\mu_0^2}{2(\mu_1 - \mu_0)}$$

Цялата дясна страна на това неравенство е просто някаква нова константа, тъй като всички величини в нея ( $\sigma, \mu_0, \mu_1, n, k$ ) са фиксирани числа. Нека я означим с  $\tilde{K}$ . Така, формата на най-мощната критична област значително се опростява:

$$W^* = \left\{ \vec{x} \in \mathbb{R}^n : \sum_{j=1}^n x_j \geq \underbrace{\frac{2\sigma^2 \ln k + n\mu_1^2 - n\mu_0^2}{2(\mu_1 - \mu_0)}}_{\tilde{K}} \right\}$$

Това правило е много интуитивно: отхвърляме хипотезата за по-малкото средно  $\mu_0$  в полза на по-голямото средно  $\mu_1$ , когато сумата от наблюденията надвиши определен праг  $\tilde{K}$ .

Остава единствено да определим стойността на константата  $\tilde{K}$ . Тя се намира от условието вероятността за грешка от първи род да бъде точно  $\alpha$ :

$$\alpha = \mathbb{P}(\vec{X} \in W^* \mid H_0) = \mathbb{P}\left(\sum_{j=1}^n X_j \geq \tilde{K} \mid H_0\right)$$

Тъй като пресмятаме вероятността при условие, че  $H_0$  е вярна, ние знаем, че всяко  $X_j \sim N(\mu_0, \sigma^2)$ . Следователно можем да центрираме и нормираме сумата, за да получим стандартно нормално разпределение:


$$\mathbb{P}\left(\frac{\sum_{j=1}^n X_j - n\mu_0}{\sigma\sqrt{n}} \geq \frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}} \mid H_0\right) = \alpha$$

Лявата страна в неравенството вече е стандартна нормална величина  $Z \sim N(0, 1)$ . Нека означим дясната страна с  $q_{1-\alpha}$ , което е квантилят на нормалното разпределение, оставящ площ  $\alpha$  в дясната опашка (или  $1 - \alpha$  в лявата). Имаме:

$$\mathbb{P}\left(Z \geq \frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}}\right) = \alpha$$

Следователно приравняваме границата на квантила:

$$\frac{\tilde{K} - n\mu_0}{\sigma\sqrt{n}} = q_{1-\alpha}$$



**Фигура 2:** Двете хипотези и решението между тях. Под  $H_0$  средното е  $\mu_0$ , под  $H_1$  е  $\mu_1 > \mu_0$ ; наблюденията се сравняват с прага  $\mu_0 + \frac{\sigma}{\sqrt{n}} q_{1-\alpha}$ . Вдясно от прага отхвърляме  $H_0$ . Заштрихованата площ под лявата крива е  $\alpha$  — вероятността да отхвърлим вярна  $H_0$ ; площта под дясната крива *вляво* от прага е  $\beta$ . Прагът не може да свие двете едновременно: избутването му надясно намалява  $\alpha$  и увеличава  $\beta$ .

Квантилят  $q_{1-\alpha}$  (например за  $\alpha = 0,05$  от таблиците се намира стойността му) може да бъде намерен от статистическите таблици. От това уравнение еднозначно се намира константата  $\tilde{K}$ , с което най-мощната критична област  $W^*$  е напълно определена.

## 13.4 Задачи

1. При неизвестна дисперсия използвайте централната статистика

$$T_n = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t(n-1)$$

и квантила  $q = q_{(1+\gamma)/2}$ , за да решите неравенството

$$-q < T_n < q$$

спрямо  $\mu$  и да получите границите  $I_1$  и  $I_2$  на доверителния интервал с ниво на доверие  $\gamma$ .