

Лекция 14. Линейна регресия

14.1 Въведение в линейната регресия

В тази лекция ще се запознаем с линейната регресия. Тя е един от най-основните инструменти в статистиката. Линейната регресия стои зад много съвременни инструменти и технологии, въпреки че често пъти е скрита вътре в самия модел, като например в невронните мрежи, рейтинговите системи и други.

Разбира се, както при всеки модел, ако предпоставките или допусканията не са изпълнени, лесно можете да стигнете до грешни изводи. Създаването на модели е изкуство, което изисква познаване на теорията и се овладява най-вече чрез практиката.

14.1.1 Исторически контекст: регрес към средното

Началото на линейната регресия е свързано с Франсис Галтън, който се опитал да изучи зависимостта между ръста на бащите и ръста на техните синове. В своето изследване Галтън се опитал да предскаже височината на сина като функция на ръста на бащата. Забелязал е, че един добър модел може да се запише във вида:

$$\text{Ръст на сина} = \text{Среден ръст} + \beta(\text{Ръст на бащата} - \text{Среден ръст}) + \varepsilon$$

В изчисленията на Галтън коефициентът β е бил приблизително 0,6. Ако бащата е с 10 см по-висок от средния ръст за популацията, моделът предвижда отклонение

$$0,6 \cdot 10 \text{ см} = 6 \text{ см}$$

за сина: средно около 6 см над средния ръст, а не цели 10 см.

Това явление се нарича **регрес към средното**. То се забелязва нерядко и при други човешки характеристики, като например интелекта. Изключително умни хора имат тенденцията да имат наследници, чиито показатели са по-близо до средното ниво на популацията. Името „регресия“ произхожда именно от това „връщане“ към средната стойност.

Най-общо, един такъв модел може да се запише като:

$$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k$$


където X_k е предикторът (например ръстът на бащата или дозата на дадено лекарство), Y_k е откликът (ръстът на сина или реакцията към лекарството), β_0 и β_1 са линейни коефициенти, а ε_k е стохастична грешка.

14.2 Детерминистичен модел. Метод на най-малките квадрати

Нека разгледаме детерминистичната оптимизационна задача, която стои зад линейната регресия. Имаме дадени n на брой наблюдения, представляващи точки в равнината (X_k, Y_k) за $k = 1, \dots, n$. Търсим права линия с уравнение $y_k = b_0 + b_1 X_k$, която да моделира данните по възможно най-добрия начин. Грешката за дадено наблюдение k е разликата между истинската стойност Y_k и предвидената стойност от нашата права $\hat{Y}_k = b_0 + b_1 X_k$.

Дефиниция 14.1 (метод на най-малките квадрати). *Оценки по метода на най-малките квадрати* наричаме онези стойности на b_0 и b_1 , които минимизират сумата от квадратите на грешките:

$$\sum_{k=1}^n \varepsilon_k^2 = \sum_{k=1}^n (Y_k - b_0 - b_1 X_k)^2 \rightarrow \min.$$



Фигура 1: Методът на най-малките квадрати. Точките са наблюденията (X_k, Y_k) , правата е $b_0 + b_1 x$, а вертикалните отсечки са грешките $\varepsilon_k = Y_k - b_0 - b_1 X_k$. Минимизира се сумата от техните *квадрати*. Отсечките са вертикални, а не перпендикулярни на правата: моделът обяснява Y чрез X , затова се мерят отклоненията само по Y .

Изборът на квадрата на грешката (вместо модул) исторически е бил мотивиран от изчислително удобство, тъй като функцията е гладка и лесно се диференцира, а също така съответства на Евклидовото разстояние. Освен това, от статистическа гледна точка, този подход води до добри оценки.

14.2.1 Намиране на коефициентите

За да минимизираме функцията, намираме нейните частни производни спрямо b_0 и b_1 и ги приравняваме на нула. Ще използваме стандартните означения $\bar{X} = \frac{1}{n} \sum X_k$ и $\bar{Y} = \frac{1}{n} \sum Y_k$ за средните аритметични стойности. *Локална регресионна конвенция:* в тази лекция $\bar{X}$ и $\bar{Y}$ винаги са тези аритметични средни; ако в друга лекция $\bar{X}$ е използвано за стандартизирана случайна величина, това е отделна конвенция. Тук стандартизираните грешки ще означаваме с Z_k .

Диференцирайки по b_0 и разделяйки на -2 , получаваме първото уравнение (нормално уравнение):

$$\begin{aligned} \sum_{k=1}^n (Y_k - b_0 - b_1 X_k) &= 0 \\ \sum_{k=1}^n Y_k - n b_0 - b_1 \sum_{k=1}^n X_k &= 0 \end{aligned}$$

Изразявайки сумите чрез средните аритметични ($n\bar{Y} - n b_0 - b_1 n\bar{X} = 0$), след съкращаване на n стигаме до връзката за b_0 :

$$b_0 = \bar{Y} - b_1 \bar{X}$$

Диференцирайки по b_1 , получаваме второто уравнение:

$$\sum_{k=1}^n X_k (Y_k - b_0 - b_1 X_k) = 0$$

$$\sum_{k=1}^n X_k Y_k - b_0 n \bar{X} - b_1 \sum_{k=1}^n X_k^2 = 0$$

Ако заместим b_0 във второто уравнение и извършим алгебричните преобразувания, можем да изведем явна формула за наклона b_1 . Оттук нататък за явните оценки и всички последващи резултати приемаме $n \geq 2$ и $A > 0$, т.е. фиксираният дизайн е с пълен ранг (предикторите X_k не са всички равни). При $A = 0$ наклонът и пресечната точка не се идентифицират поотделно и формулите с деление на A не са дефинирани. Формулата може да се запише в няколко еквивалентни и много полезни вида:

$$b_1 = \frac{\sum_{k=1}^n X_k Y_k - n \bar{X} \bar{Y}}{\sum_{k=1}^n X_k^2 - n \bar{X}^2} = \frac{\sum_{k=1}^n (X_k - \bar{X})(Y_k - \bar{Y})}{\sum_{k=1}^n (X_k - \bar{X})^2}$$

Забележете, че горните изрази изключително много приличат на формулата за ковариация и дисперсия, откъдето идва и връзката с коефициента на корелация.

14.2.2 Удобен запис за статистическия анализ

За да изследваме свойствата на b_0 и b_1 по-лесно, ще въведем следното означение. Нека A е сумата от квадратите на отклоненията на предикторите от тяхното средно:

$$A = \sum_{k=1}^n (X_k - \bar{X})^2$$

Въвеждаме и теглата c_k :

$$c_k = \frac{X_k - \bar{X}}{A}$$

Тогава оценката b_1 може елегантно да се запише като линейна комбинация на отклиците Y_k :

$$\hat{\beta}_1 = b_1 = \sum_{k=1}^n c_k Y_k$$

Оценката $\hat{\beta}_0$ може да се запише по аналогичен начин, замествайки b_1 в $b_0 = \bar{Y} - b_1 \bar{X}$:

$$\hat{\beta}_0 = b_0 = \sum_{k=1}^n \left(\frac{1}{n} - \bar{X} c_k \right) Y_k$$

Много важно свойство на константите c_k , което ще използваме често, е, че сумата им е нула:

$$\sum_{k=1}^n c_k = \frac{\sum_{k=1}^n (X_k - \bar{X})}{A} = \frac{n\bar{X} - n\bar{X}}{A} = 0$$

14.3 Стохастичен модел

Дотук разглеждахме задачата детерминистично. По-общо, моделът се разглежда статистически. Предикторите X_k се считат за детерминистични величини (например дозата от дадено лекарство, която ние контролираме и избираме), докато отклиците Y_k са случайни величини. Стохастиката в Y_k идва единствено от случайната грешка ε_k .

★ **Дефиниция 14.2 (стохастичен модел на простата линейна регресия).** Истинският модел е

$$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k,$$

При фиксиран дизайн $X_1, \dots, X_n$ приемаме, че грешките са независими и еднакво разпределени (iid) като $N(0, \sigma^2)$ със строго положителна дисперсия $\sigma^2 > 0$, т.е. със следните допускания за грешките ε_k :

1. **Независимост:** случайните величини $(\varepsilon_1, \dots, \varepsilon_n)$ са взаимно независими.
2. **Липса на систематична грешка:** $\mathbb{E}[\varepsilon_k] = 0$ за всяко k , откъдето $\mathbb{E}[Y_k] = \beta_0 + \beta_1 X_k$.
3. **Хомоскедастичност (еднаква дисперсия):** $\mathbb{D}(\varepsilon_k) = \sigma^2$ за всяко k .
4. **Нормалност:** грешките са нормално разпределени, $\varepsilon_k \sim N(0, \sigma^2)$.

Тези допускания са силни. Второто означава, че средно моделът е точен; третото — че грешката има еднаква вариативност, независимо от стойността на предиктора X_k .

Забележка относно допусканията: Обобщения на този модел има в най-различни посоки (напр. хетероскедастичност). Винаги обаче трябва да наложите някаква структура на грешката, за да можете да правите изводи. Ако човек просто използва модела без да проверява дали тези допускания са валидни (както се е случвало често в практиката преди финансовата криза от 2008-2009 г.), той може да получи напълно погрешни и катастрофални резултати, защото моделът ще върне число, но то може да е напълно невалидно.

При допусканията на модела от дефиниция 14.2 се оказва, че оценките $\hat{\beta}_0 = b_0$ и $\hat{\beta}_1 = b_1$, получени по метода от дефиниция 14.1, съвпадат с **максимално правдоподобните оценки (MLE)**.

14.4 Свойства на оценките

Използвайки допусканията, ще изследваме свойствата на нашите оценки. Тъй като b_1 и b_0 са линейни комбинации на нормално разпределени случайни величини (Y_k), то самите те също ще имат нормално разпределение. Трябва само да намерим тяхното математическо очакване и дисперсия.

14.4.1 Оценка на наклона $\hat{\beta}_1$ (b_1)

Проверяваме дали оценката b_1 е неизместена (unbiased). Математическото очакване е:

$$\mathbb{E}[b_1] = \mathbb{E}\left[\sum_{k=1}^n c_k Y_k\right] = \sum_{k=1}^n c_k \mathbb{E}[Y_k] = \sum_{k=1}^n c_k (\beta_0 + \beta_1 X_k)$$

Тъй като $\sum_{k=1}^n c_k = 0$, членът с β_0 отпада:

$$\mathbb{E}[b_1] = \beta_1 \sum_{k=1}^n c_k X_k$$

Сега нека пресметнем сумата $\sum c_k X_k$. Тъй като можем да добавим $-\bar{X}$ (което е константа) без да променим стойността на сумата (защото $\bar{X} \sum c_k = 0$):

$$\sum_{k=1}^n c_k X_k = \sum_{k=1}^n \frac{X_k - \bar{X}}{A} X_k = \sum_{k=1}^n \frac{X_k - \bar{X}}{A} (X_k - \bar{X}) = \frac{\sum (X_k - \bar{X})^2}{A} = \frac{A}{A} = 1$$

Следователно $\mathbb{E}[b_1] = \beta_1$, което доказва, че оценката е **неизместена**.

Дисперсията на b_1 намираме използвайки факта, че Y_k са независими (тъй като ε_k са независими) и всяко има дисперсия σ^2 :

$$\mathbb{D}(b_1) = \mathbb{D}\left(\sum_{k=1}^n c_k Y_k\right) = \sum_{k=1}^n \mathbb{D}(c_k Y_k) = \sum_{k=1}^n c_k^2 \mathbb{D}(Y_k) = \sum_{k=1}^n c_k^2 \sigma^2$$

Заместваме c_k :

$$\mathbb{D}(b_1) = \sigma^2 \sum_{k=1}^n \left(\frac{X_k - \bar{X}}{A}\right)^2 = \sigma^2 \frac{\sum (X_k - \bar{X})^2}{A^2} = \frac{\sigma^2 A}{A^2} = \frac{\sigma^2}{A}$$

В крайна сметка получаваме, че b_1 има следното нормално разпределение:

$$b_1 \sim N\left(\beta_1, \frac{\sigma^2}{A}\right)$$

14.4.2 Оценка на пресечната точка $\hat{\beta}_0(b_0)$

Аналогично пресмятаме очакването на b_0 :

$$\mathbb{E}[b_0] = \sum_{k=1}^n \left(\frac{1}{n} - \bar{X} c_k\right) \mathbb{E}[Y_k] = \sum_{k=1}^n \left(\frac{1}{n} - \bar{X} c_k\right) (\beta_0 + \beta_1 X_k)$$

Ако се разкрият скобите и се използват вече доказаните свойства ($\sum c_k = 0$ и $\sum c_k X_k = 1$), се получава, че $\mathbb{E}[b_0] = \beta_0$. Оценката b_0 също е неизместена.

Дисперсията на b_0 е:

$$\mathbb{D}(b_0) = \sum_{k=1}^n \left(\frac{1}{n} - \bar{X} c_k\right)^2 \mathbb{D}(Y_k) = \sigma^2 \sum_{k=1}^n \left(\frac{1}{n} - \bar{X} c_k\right)^2$$

След алгебрични преработки, които ще спестим за краткост, се получава:

$$\mathbb{D}(b_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{A}\right)$$

Следователно, разпределението на b_0 е:

$$b_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{A}\right)\right)$$

14.5 Оценяване на дисперсията σ^2

Ако дисперсията σ^2 на грешките ни е предварително известна, то тогава можем веднага да използваме горните разпределения. Често пъти обаче σ^2 не е известна и следва да я оценим от данните. Резултатите за регресионната дисперсия по-долу са при $A > 0$; резултатите с остатъчна дисперсия и t -пивот допълнително изискват $n \geq 3$, така че остатъчните степени на свобода $n - 2$ да са положителни.

Нека разгледаме стандартизираните грешки:

$$Z_k = \frac{Y_k - \beta_0 - \beta_1 X_k}{\sigma} \sim N(0, 1)$$

Тъй като тези величини са независими стандартни нормални, сумата от техните квадрати има хи-квадрат разпределение с n степени на свобода:

$$\sum_{k=1}^n Z_k^2 = \frac{1}{\sigma^2} \sum_{k=1}^n (Y_k - \beta_0 - \beta_1 X_k)^2 \sim \chi^2(n)$$

Проблемът е, че ние не знаем истинските параметри β_0 и β_1 . Можем да ги заместим с техните оценки b_0 и b_1 , които сме пресметнали. При пълен ранг $A > 0$ и $n \geq 3$ използваме две оценки (губим две степени на свобода), затова разпределението на остатъчната сума се променя на $\chi^2(n-2)$:

$$\frac{1}{\sigma^2} \sum_{k=1}^n (Y_k - b_0 - b_1 X_k)^2 \sim \chi^2(n-2)$$

Според Закона за големите числа (ЗГЧ), ако разделим случайна величина с $\chi^2(n-2)$ разпределение на нейните степени на свобода, то при $n \rightarrow \infty$ тази дроб клони към 1 (математическото очакване на Z_1^2). Това ни подсказва, че можем да конструираме **неизместена и състоятелна оценка** за дисперсията σ^2 :

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{k=1}^n (Y_k - b_0 - b_1 X_k)^2$$

В ситуации, в които σ^2 е неизвестна, просто я заместваме с $\hat{\sigma}^2$ във всички по-нататъшни разсъждения, при вече посочените $A > 0$ и $n \geq 3$. Тогава $\hat{\sigma}^2 > 0$ почти сигурно при $\sigma^2 > 0$. Да се отбележи, че в тази лекция $\hat{\sigma}^2$ означава дисперсията на *грешките* в регресионния модел и се дели на $n-2$ (два оценени параметъра, b_0 и b_1), за разлика от извадковата дисперсия в лекции 12 и 13.

14.6 Проверка на хипотези

Често се налага да проверяваме хипотези относно линейните коефициенти. Най-често нулевата хипотеза е, че предикторът не влияе на отклика, т.е. че наклонът β_1 е нула: $H_0 : \beta_1 = 0$. По-общо, можем да тестваме дали параметърът приема конкретна стойност $H_0 : \beta_1 = \beta$, срещу алтернативата $H_1 : \beta_1 \neq \beta$.

14.6.1 Случай на известна дисперсия σ^2 : Z -пивот

Когато σ^2 е известно (а регресионният параметър β_1 остава неизвестен), използваме факта, че $b_1 \sim N(\beta_1, \sigma^2/A)$. При валидност на нулевата хипотеза $H_0 : \beta_1 = \beta$, статистиката Z е стандартно нормално разпределена:

$$Z = \frac{b_1 - \beta}{\sqrt{\frac{\sigma^2}{A}}} \sim N(0, 1)$$

Ако изберем ниво на значимост (грешка от първи род) α , критичната област W , в която отхвърляме нулевата хипотеза, е симетрична:

$$W = \left\{ |Z| \geq q_{1-\frac{\alpha}{2}} \right\}$$

където $q_{1-\frac{\alpha}{2}}$ е квантилът на стандартното нормално разпределение. Оттук лесно можем да построим и доверителен интервал за β_1 с вероятност $1 - \alpha$; неговите крайни точки (при $A > 0$ и $\sigma^2 > 0$) са:

$$\beta_1 \in \left[b_1 - q_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{A}}, b_1 + q_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{A}} \right]$$

14.6.2 Случай на неизвестна дисперсия σ^2 : t -пивот

Когато σ^2 не е известно, но $A > 0$ и $n \geq 3$, ние заместваме σ^2 с нейната оценка $\hat{\sigma}^2$. Разпределението на тестовата статистика се променя от нормално на **t -разпределение на Стюдънт** с положителните $n - 2$ степени на свобода:

$$T = \frac{b_1 - \beta}{\sqrt{\frac{\hat{\sigma}^2}{A}}} \sim t(n - 2)$$

Тук се използва — както и при извадката в лекция 13 — че оценката на наклона и оценката на дисперсията са *независими*: $b_1 \perp \hat{\sigma}^2$. Само тогава частното на нормална величина и корен от независима χ^2 , поделена на степените си на свобода, дава разпределение на Стюдънт. Както и там, това е следствие от нормалността на грешките ε_k . При конструиране на критична област и доверителни интервали, вместо квантилите на нормалното разпределение $q_{1-\alpha/2}$, трябва да използваме квантилите на t -разпределението $t_{1-\alpha/2, n-2}$, които имат по-тежки опашки. По-специално, точният двустранен интервал за β_1 има крайни точки

$$\beta_1 \in \left[b_1 - t_{1-\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{A}}, b_1 + t_{1-\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{A}} \right].$$

Важна бележка: При голям брой степени на свобода $n - 2$, t -разпределението се доближава до стандартното нормално разпределение $N(0, 1)$. Правилото $n \geq 32$ (тоест $n - 2 \geq 30$) понякога служи като ориентир за замяна на t -квантилите с нормални, но не е универсална гаранция за желана числена точност; подходящата апроксимация трябва да се провери за използваното ниво α .

14.6.3 Тестване на пресечната точка β_0

Абсолютно същата логика може да се приложи и за тестване на хипотеза за пресечната точка: $H_0 : \beta_0 = \beta^*$. При известно σ^2 статистиката е (при $A > 0$):

$$Z = \frac{b_0 - \beta^*}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{A} \right)}} \sim N(0, 1)$$

Ако σ^2 не е известно, при $A > 0$ и $n \geq 3$ отново използваме T -статистика с $\hat{\sigma}^2$ и t -разпределение с $n - 2$ степени на свобода (и съответните t -квантили за краищата на интервала).

Организационна бележка

Изискванията за изпита, независимо дали е онлайн или присъствен, не са твърде високи, но се очаква базова грамотност: да не се допускат груби грешки като отрицателни дисперсии и непознаване на основни понятия като математическо очакване и плътност. Консултация преди изпита ще бъде организирана, ако е възможно.