

1 Гранични теореми и приближения

1.1 Теорема на Поасон (Поасоново приближение)

Досега разглеждахме Поасоновата случайна величина като модел, дефиниран чрез своите вероятности. За разлика от биномното разпределение, при което имаме ясен експериментален модел (хвърляне на монета или повтаряеми опити с два изхода), Поасоновото разпределение често възниква като граничен случай или като добро приближение на други разпределения.

Преди да формулираме основната теорема, нека припомним едно много полезно твърдение, свързано с пораждащите функции. Нека имаме редица от целочислени неотрицателни случайни величини X_n и съответните им пораждащи функции $G_{X_n}(s)$. Нека X е също целочислена неотрицателна случайна величина с пораждаща функция $G_X(s)$. Ако за всяко s от дефиниционното множество имаме сходимост на пораждащите функции $\lim_{n \rightarrow \infty} G_{X_n}(s) = G_X(s)$, то за всяко цяло $k \geq 0$ е изпълнено и сходимост на самите вероятности:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \mathbb{P}(X = k)$$

Това твърдение ни позволява чрез граница на функции да идентифицираме граница на вероятности, което много често е технически значително по-лесно от директното доказване на сходимост на самите вероятности.

Ще използваме този факт, за да докажем една от важните ранни теореми в теорията на вероятностите, а именно Теоремата на Поасон. Тя илюстрира как един теоретичен резултат може да ни даде основание за полезни практически приближения.

Теорема (на Поасон): Нека за всяко $n \geq 1$ е дадена случайна величина X_n , която има биномно разпределение $X_n \sim \text{Bin}(n, p_n)$. Т.е. имаме редица от биномни случайни величини с нарастващ брой експерименти n и променяща се вероятност за успех p_n . Нека освен това границата на произведението np_n е положително число:

$$\lim_{n \rightarrow \infty} np_n = \lambda > 0$$

Тогава за всяко $k \geq 0$, границата на вероятностите X_n да е равно на k е равна на вероятността Поасонова случайна величина с параметър λ да е равна на k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

Грубо казано, ако броят експерименти по вероятността за успех се стабилизира до някакво число λ , сложните биномни вероятности се сходят към много по-лесно изчислимите Поасоновы вероятности.

Доказателство (за частен случай): Няма да доказваме теоремата в пълната ѝ общност. За да предадем основната интуиция, ще разгледаме по-простия случай, при който не просто границата е λ , а самото произведение е точно равно на λ за всяко n . Т.е. нека $\lambda = np_n$, откъдето $p_n = \frac{\lambda}{n}$.

Пораждащата функция на биномната случайна величина X_n е:

$$G_{X_n}(s) = (1 - p_n + p_n s)^n$$

Замествайки $p_n = \frac{\lambda}{n}$, получаваме:

$$G_{X_n}(s) = \left(1 - \frac{\lambda}{n} + \frac{\lambda}{n}s\right)^n = \left(1 + \frac{\lambda(s-1)}{n}\right)^n$$

Като използваме основното свойство на експоненциалната функция като граница, намираме:

$$\lim_{n \rightarrow \infty} G_{X_n}(s) = \lim_{n \rightarrow \infty} \left(1 + \frac{\lambda(s-1)}{n}\right)^n = e^{\lambda(s-1)}$$

Получената граница $e^{\lambda(s-1)}$ е точно пораждащата функция на Поасонова случайна величина $X \sim \text{Po}(\lambda)$. Благодарение на споменатото по-горе твърдение, това доказва, че $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}$.

Практическо приложение (Приближение на Поасон): В практиката тази теорема не се използва толкова като строга граница (понеже на практика разполагаме с едно конкретно n), колкото като рецепта за приближение. Сложният израз за биомната вероятност $\binom{n}{k} p^k (1-p)^{n-k}$ изисква пресмятането на големи факториели и високи степени.

Ако разполагаме със случайна величина $Y \sim \text{Bin}(n, p)$, където n е достатъчно голямо, а p е достатъчно малко, можем да използваме приближението:

$$\mathbb{P}(Y = k) \approx \frac{\lambda^k}{k!} e^{-\lambda}, \quad \text{където } \lambda = np$$

Рецепта: Приближението работи добре и може спокойно да се използва в случаите, когато $n \geq 100$ и $np \leq 20$. Тогава, дори и да не знаем ”границите”, твърдим, че биомните вероятности са изключително близки до Поасоновите с параметър $\lambda = np$.

2 Хипергеометрично разпределение

Последното конкретно разпределение от фундаменталните дискретни случайни величини, което ще разгледаме, е хипергеометричното разпределение. За разлика от Поасоновото, то е директно обвързано с един много ясен физически и комбинаторен модел на извличане без връщане.

Дефиниция на модела: Казваме, че X има хипергеометрично разпределение с параметри N , M и n (записваме $X \sim \text{HG}(N, M, n)$), ако X описва следния процес: Имаме общо N на брой обекта (например продукти в партида). От тях точно M са ”маркирани” (или ”дефектни”), а останалите $N - M$ са немаркирани (или здрави). Ние изтегляме случайно n на брой обекта от тези N без връщане. Случайната величина X представлява *броят на изтеглените маркирани обекти* измежду тези n обекта.

Естествените параметрични ограничения са $N \geq M$ и $N \geq n$. Това разпределение намира огромно приложение в качествения контрол, където искаме да оценим каква пропорция от огромна партида стоки са дефектни, използвайки само малка извадка от тях.

Твърдение: Нека $X \sim \text{HG}(N, M, n)$. Тогава:

а) Вероятностното разпределение на X се задава с:

$$\mathbb{P}(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

където k удовлетворява естествените ограничения $0 \vee (n - N + M) \leq k \leq M \wedge n$.

б) Математическото очакване е:

$$\mathbb{E}X = n \frac{M}{N}$$

в) Дисперсията е:

$$\mathbb{D}X = n \frac{M}{N} \frac{N-M}{N} \frac{N-n}{N-1}$$

Доказателство на твърдението: За а): Формулата следва от класическата вероятност. Всички възможни начини да изтеглим n обекта от N са $\binom{N}{n}$. За да изтеглим точно k маркирани, трябва да изберем k обекта от наличните M маркирани (това става по $\binom{M}{k}$ начина) и останалите $n - k$ обекта да изберем от наличните $N - M$ немаркирани (това става по $\binom{N-M}{n-k}$ начина). Границите за k гарантират, че не избираме повече маркирани, отколкото съществуват или отколкото теглим ($k \leq \min(M, n)$), както и че няма как да изтеглим отрицателен брой обекти или повече немаркирани, отколкото съществуват.

За б): Това свойство има скрита линейна структура, която изключително улеснява пресмятането на очакването. Дефинираме индикаторни случайни величини X_j за всяко $j \in \{1, \dots, n\}$ по следния начин:

$$X_j = \begin{cases} 1, & \text{ако } j\text{-тият изтеглен обект е маркиран} \\ 0, & \text{ако не е маркиран} \end{cases}$$

Ясно е, че общият брой маркирани обекти X е просто сумата на тези индикатори:

$$X = \sum_{j=1}^n X_j$$

Тъй като математическото очакване винаги е линейно (независимо дали събираемите са независими или не), можем да запишем:

$$\mathbb{E}X = \mathbb{E} \left(\sum_{j=1}^n X_j \right) = \sum_{j=1}^n \mathbb{E}X_j$$

Всяко X_j е Бернулиева случайна величина $X_j \sim \text{Ber}(p_j)$, където p_j е вероятността j -тият изтеглен обект да е маркиран. Поради пълната симетрия на модела (няма значение дали теглите първи или j -ти, преди да сте видели резултатите от останалите

тегления, вероятността е една и съща), вероятността на коя да е позиция да се падне маркиран обект е точно пропорцията на маркираните обекти в началото, а именно $p_j = \frac{M}{N}$. Следователно, $\mathbb{E}X_j = p_j = \frac{M}{N}$. Замествайки обратно в сумата, получаваме:

$$\mathbb{E}X = \sum_{j=1}^n \frac{M}{N} = n \frac{M}{N}$$

За *в*): Доказателството на дисперсията е чисто техническо. Основната трудност идва от факта, че случайните величини X_j не са независими (изтеглянето на маркиран обект на първо теглене променя вероятностите за следващите тегления, тъй като тегленето е без връщане). Затова дисперсията на сумата не е просто сума от дисперсиите, а включва и ковариационните членове. Формулата се дава наготово.

Пример: Имаме 8 маркера, от които 4 са цветни и 4 са черни. Т.е. $N = 8$, $M = 4$. Теглим $n = 3$ маркера на случаен принцип. Броят цветни маркери, които сме изтеглили сред тези три, се описва с хипергеометричната случайна величина $X \sim \text{HG}(8, 4, 3)$.

3 Съвместни разпределения

Досега разглеждахме случайните величини изолирано. Често пъти обаче искаме да описваме сложни модели с повече от една случайна характеристика. Например, искаме да изследваме както разхода на един клиент в магазина, така и неговия пол. Затова трябва да въведем понятия за съвместна работа с две или повече случайни величини. За удобство на записа ще разглеждаме двойки (X, Y) , но концепциите се обобщават за произволен краен брой.

3.1 Съвместни дискретни разпределения

Дефиниция: Нека X и Y са две дискретни случайни величини, дефинирани върху едно и също вероятностно пространство. Под **съвместно разпределение** на X и Y разбираме съвкупността от всички вероятности:

$$p_{i,j} = \mathbb{P}(X = x_i, Y = y_j)$$

за всички възможни стойности x_i на X и y_j на Y . Обикновено това се представя във формата на таблица, където редовете отговарят на възможните стойности на X , а колоните – на възможните стойности на Y . Всяка клетка (i, j) съдържа вероятността двете събития да настъпят едновременно. Сумата на всички числа (клетки) в тази таблица е равна на 1.

Маргинални разпределения: Ако съберем всички вероятности по даден ред (фиксирайки $X = x_i$ и сумирайки по всички възможни стойности на Y), по формулата за пълната вероятност получаваме *маргиналното разпределение* на X :

$$\mathbb{P}(X = x_i) = \sum_j \mathbb{P}(X = x_i, Y = y_j) = \sum_j p_{i,j}$$

Това е просто индивидуалното разпределение на X , такова каквото би било, ако въобще не се интересувахме от Y . Аналогично, сумирайки по колони, получаваме маргинално разпределение на Y :

$$\mathbb{P}(Y = y_j) = \sum_i \mathbb{P}(X = x_i, Y = y_j) = \sum_i p_{i,j}$$

Пример: Хвърляме два стандартни зара (номерирани от 1 до 6). Дефинираме две случайни величини: - X : броят на хвърлените шестци (възможни стойности: 0, 1, 2) - Y : броят на хвърлените единици (възможни стойности: 0, 1, 2)

Нека попълним таблицата на съвместното им разпределение. Общият брой възможни изходи при хвърляне на два зара е $6 \times 6 = 36$.

- $\mathbb{P}(X = 0, Y = 0)$: Търсим вероятността да няма нито една шестца и нито една единица. Значи и двата зара трябва да покажат числа между 2 и 5 (общо 4 възможности за всеки зар). Вероятността е $\frac{4 \times 4}{36} = \frac{16}{36}$.
- $\mathbb{P}(X = 1, Y = 0)$: Търсим една шестца и нула единици. За първия зар имаме шестца, а за втория число от 2 до 5 (4 възможности). Или обратното. Общо $2 \times 4 = 8$ възможности. Вероятността е $\frac{8}{36}$.
- $\mathbb{P}(X = 0, Y = 1)$: По симетрия (една единица и нула шестци), вероятността също е $\frac{8}{36}$.
- $\mathbb{P}(X = 1, Y = 1)$: Една шестца и една единица. Вариантите са (6,1) и (1,6). Вероятността е $\frac{2}{36}$.
- $\mathbb{P}(X = 2, Y = 0)$: Две шестци, вероятност $\frac{1}{36}$.
- $\mathbb{P}(X = 0, Y = 2)$: Две единици, вероятност $\frac{1}{36}$.
- Всички останали комбинации (напр. $X = 2, Y = 1$) са невъзможни (не може да имаме общо повече от 2 зара), така че вероятността им е 0.

Сумата от всички вероятности в таблицата е $\frac{16+8+8+2+1+1}{36} = \frac{36}{36} = 1$.

Ако изчислим маргинално разпределение на X чрез сумиране по редовете, получаваме:

$$\mathbb{P}(X = 0) = \frac{16 + 8 + 1}{36} = \frac{25}{36}$$

$$\mathbb{P}(X = 1) = \frac{8 + 2}{36} = \frac{10}{36}$$

$$\mathbb{P}(X = 2) = \frac{1}{36}$$

Което е точно очакваното биномно разпределение за броя на успехите (падане на шестца, $p = 1/6$) при 2 опита.

3.2 Съвместна функция на разпределение (Joint CDF)

Дефиниция: Нека X и Y са две произволни случайни величини (дискретни или непрекъснати). Тогава **съвместна функция на разпределение** (или кумулативна функция) на X и Y е функцията $F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$, зададена като:

$$F_{X,Y}(x, y) := \mathbb{P}(X < x, Y < y) \quad \forall (x, y) \in \mathbb{R}^2$$

Геометрично, ако разглеждаме стойностите на X и Y като координати на двумерен вектор в равнината, $F_{X,Y}(x, y)$ е вероятността този случаен вектор да попадне в безкрайния правоъгълник на югозапад от точката (x, y) (строго по-малко от x по хоризонтала и строго по-малко от y по вертикала).

Свойства: От съвместната функция на разпределение можем лесно да възстановим маргиналните функции на разпределение $F_X(x)$ и $F_Y(y)$, като заместим съответно другата координата с безкрайност. Понеже събитието $\{Y < \infty\}$ е достоверно (вероятност 1), то сечението на $\{X < x\}$ с достоверно събитие не променя вероятността:

$$F_{X,Y}(x, \infty) = \mathbb{P}(X < x, Y < \infty) = \mathbb{P}(X < x) = F_X(x)$$

Аналогично:

$$F_{X,Y}(\infty, y) = F_Y(y)$$

Очевидно е също, че $F_{X,Y}(\infty, \infty) = \mathbb{P}(X < \infty, Y < \infty) = 1$.

Критерий за независимост: Две случайни величини X и Y са независими тогава и само тогава, когато съвместната им функция на разпределение се разпада на произведение от маргиналните им функции на разпределение за всяка точка (x, y) :

$$F_{X,Y}(x, y) = F_X(x)F_Y(y) \quad \forall (x, y) \in \mathbb{R}^2$$

Това е най-общият критерий за независимост. За дискретни разпределения обикновено се ползва еквивалентният и по-интуитивен критерий с вероятности в конкретни точки: $\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$.

4 Ковариация и корелация

След като дефинирахме какво означава две случайни величини да са независими във вероятностен смисъл, преминаваме към изследването на конкретни видове зависимости. Понякога знаем, че две величини са зависими, но искаме да измерим силата и посоката на тяхната *линейна* зависимост. Търсим да отговорим на въпроса доколко Y може да се представи като линейна функция на X , т.е. $Y \approx aX + b$.

4.1 Ковариация

Първата стъпка към дефиниране на такава мярка е ковариацията. За да изолираме отместванията на разпределенията по реалната права, ние първо ги центрираме, като изваждаме техните математически очаквания. Ако дефинираме центрирани случайни величини $\tilde{X} = X - \mathbb{E}X$ и $\tilde{Y} = Y - \mathbb{E}Y$, то е очевидно, че тяхното очакване е 0 ($\mathbb{E}\tilde{X} = 0$).

Дефиниция: Ковариация на X и Y се нарича математическото очакване на произведението на техните центрирани версии (ако това очакване съществува):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}[\tilde{X}\tilde{Y}]$$

Ковариацията може да се изчислява и по алтернативна формула, която се извежда директно чрез разкриване на скобите и използване на линейността на математическото очакване:

$$\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}X\mathbb{E}Y$$

Следствие: Ако X и Y са независими (най-силното свойство на липса на зависимост), то математическото очакване на произведението им се разпада на произведение от очакванията им ($\mathbb{E}[XY] = \mathbb{E}X\mathbb{E}Y$). Следователно, при независими случайни величини ковариацията е точно 0. Важно е да се отбележи, че обратното не е вярно – нулева ковариация означава само липса на линейна зависимост, но величините може да са свързани чрез по-сложна, нелинейна функция.

Недостатък на ковариацията: Ако умножим случайните величини по константа, например 10 пъти, тяхната ковариация ще се увеличи 100 пъти: $\text{cov}(10X, 10Y) = 100\text{cov}(X, Y)$. Това математическо мащабиране променя стойността на мярката, въпреки че линейната структура на зависимостта между величините реално не се е променила.

4.2 Коефициент на корелация

За да компенсирате ефекта от мащабирането, ние не само центрираме случайните величини, но ги и *нормираме*, разделяйки ги на корен квадратен от техните дисперсии (т.е. на стандартните им отклонения).

Дефиниция: Коефициент на корелация $\rho(X, Y)$ между две случайни величини с крайни дисперсии $\mathbb{D}X$ и $\mathbb{D}Y$ се дефинира като:

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\mathbb{D}X}\sqrt{\mathbb{D}Y}}$$

Ако дефинираме центрираните и нормирани случайни величини като:

$$\bar{X} = \frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}}, \quad \bar{Y} = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}}$$

може лесно да се провери, че $\mathbb{E}\bar{X} = 0$ и $\mathbb{D}\bar{X} = 1$. В тези термини, коефициентът на корелация е просто очакването на тяхното произведение:

$$\rho(X, Y) = \mathbb{E}[\bar{X}\bar{Y}]$$

Коефициентът на корелация е безразмерна величина. Ако пресметнем корелацията на $(10X, 10Y)$, множителят 100 се появява както в числителя (ковариацията), така и в знаменателя (от корените на дисперсиите), и се съкращава. Следователно мащабирането не променя корелацията.

Теорема (Граници на корелацията): За произволни случайни величини с крайни дисперсии е вярно, че:

$$|\rho(X, Y)| \leq 1$$

Доказателство: Ще използваме очевидния факт, че квадратът на всяка случайна величина е неотрицателен, следователно и очакването му е неотрицателно:

$$0 \leq \mathbb{E}[(\bar{X} \pm \bar{Y})^2]$$

Разкриваме скобите, ползвайки линейността на очакването:

$$0 \leq \mathbb{E}[\bar{X}^2 \pm 2\bar{X}\bar{Y} + \bar{Y}^2] = \mathbb{E}\bar{X}^2 \pm 2\mathbb{E}[\bar{X}\bar{Y}] + \mathbb{E}\bar{Y}^2$$

Тъй като $\bar{X}$ и $\bar{Y}$ имат нулеви очаквания, техните дисперсии съвпадат с очакването на квадратите им: $\mathbb{E}\bar{X}^2 = \mathbb{D}\bar{X} = 1$ и $\mathbb{E}\bar{Y}^2 = \mathbb{D}\bar{Y} = 1$. Заместваме това заедно с дефиницията за $\rho(X, Y) = \mathbb{E}[\bar{X}\bar{Y}]$ и получаваме:

$$0 \leq 1 \pm 2\rho(X, Y) + 1 = 2 \pm 2\rho(X, Y)$$

Следователно $1 \pm \rho(X, Y) \geq 0$, откъдето правим извода, че $|\rho(X, Y)| \leq 1$.

Следващата теорема обяснява точно какво ни казва коефициентът на корелация и кога той достига своите екстремални стойности ± 1 .

Теорема (Критерий за линейна зависимост): Нека X и Y са случайни величини с крайни дисперсии. Тогава между тях има строго линейна зависимост от вида $Y = aX + b$ (за някакви константи $a \neq 0$ и b) тогава и само тогава, когато $|\rho(X, Y)| = 1$.

Доказателство ($\implies$): Нека е дадено, че $Y = aX + b$. Ще изразим връзката между нормираните величини $\bar{Y}$ и $\bar{X}$.

$$\bar{Y} = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}} = \frac{aX + b - (a\mathbb{E}X + b)}{\sqrt{\mathbb{D}Y}} = \frac{a}{\sqrt{\mathbb{D}Y}}(X - \mathbb{E}X)$$

Тъй като $\sqrt{\mathbb{D}X} = \frac{\sqrt{\mathbb{D}Y}}{|a|}$, следва че:

$$\bar{Y} = \frac{a}{|a|} \frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}} = v\bar{X}$$

където $v = \text{sgn}(a) = \pm 1$. Така получихме връзката $\bar{Y} = \pm \bar{X}$. Сега пресмятаме коефициента на корелация:

$$\rho(X, Y) = \mathbb{E}[\bar{X}\bar{Y}] = \mathbb{E}[\bar{X}(\pm \bar{X})] = \pm \mathbb{E}\bar{X}^2 = \pm 1$$

Тъй като $\mathbb{E}\bar{X}^2 = \mathbb{D}\bar{X} = 1$. Това показва, че $|\rho(X, Y)| = 1$.

Доказателство ($\impliedby$): Нека сега е дадено, че $|\rho(X, Y)| = 1$. Ще разгледаме случая $\rho(X, Y) = 1$ (доказателството за $\rho = -1$ е аналогично). От предишното доказателство знаем, че:

$$\mathbb{E}[(\bar{X} - \bar{Y})^2] = 2 - 2\rho(X, Y)$$

При $\rho(X, Y) = 1$, получаваме $\mathbb{E}[(\bar{X} - \bar{Y})^2] = 0$. Тъй като интегрираме (търсим математическо очакване) на строго неотрицателна случайна величина и получаваме 0, това означава, че самата случайна величина е тъждествено равна на нула (с вероятност 1):

$$(\bar{X} - \bar{Y})^2 = 0 \implies \bar{X} = \bar{Y}$$

Заместваме дефинициите за центрирани и нормирани величини:

$$\frac{X - \mathbb{E}X}{\sqrt{\mathbb{D}X}} = \frac{Y - \mathbb{E}Y}{\sqrt{\mathbb{D}Y}}$$

От това уравнение лесно можем да изразим Y като линейна функция на X :

$$Y = \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}} X - \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}} \mathbb{E}X + \mathbb{E}Y$$

Кое е точно от вида $Y = aX + b$, където $a = \frac{\sqrt{\mathbb{D}Y}}{\sqrt{\mathbb{D}X}}$ и $b = \mathbb{E}Y - a\mathbb{E}X$. С това теоремата е доказана.

В заключение, коефициент на корелация близо до 1 (или -1) индикира силна права (или обратна) линейна зависимост между величините. Коефициент близо до 0 означава липса на линейна зависимост.