

Лекционни записки по Вероятности и Статистика

Класове непрекъснати случайни величини и съвместни разпределения

1 Класове непрекъснати случайни величини

В тази част от лекцията ще разгледаме три основни класа непрекъснати случайни величини (равномерно, нормално и експоненциално разпределение), които имат важна роля в теорията на вероятностите, и ще покажем как структурно могат да бъдат свързани със своите стандартизирани версии чрез подходящи трансформации. Тази техника значително улеснява пресмятанията на техните моменти.

1.1 Равномерно разпределение

Казваме, че случайната величина X има равномерно разпределение в интервала $[a, b]$, и записваме $X \sim U(a, b)$, където $-\infty < a < b < \infty$, ако нейната плътност се задава с:

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{за } x \in [a, b] \\ 0, & \text{иначе} \end{cases}$$

Една от важните роли на равномерното разпределение е, че когато знаем, че възможните стойности на даден експеримент лежат в интервала $[a, b]$, но нямаме допълнителна информация, то избирайки това разпределение ние внасяме най-малко субективизъм (принцип на максималната ентропия). Всеки подинтервал с една и съща дължина има една и съща вероятност.

Функцията на разпределение $F_X(x)$ е:

$$F_X(x) = \begin{cases} 0, & \text{за } x \leq a \\ \frac{x-a}{b-a}, & \text{за } a < x < b \\ 1, & \text{за } x \geq b \end{cases}$$

Очакваната стойност се пресмята стандартно като център на тежестта:

$$\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} dx = \frac{a+b}{2}$$

Структурна връзка със стандартно равномерно разпределение: Вместо да пресмятаме сложни интеграли за всяко конкретно a и b , можем да сведем X до стандартното равномерно разпределение $Y \sim U(0, 1)$. Ако разгледаме трансформацията $y = g(x) = \frac{x-a}{b-a}$, която е строго монотонно растяща, то обратната ѝ функция е $x = g^{-1}(y) = a + (b-a)y$.

Ако дефинираме $Z = g(X) = \frac{X-a}{b-a}$, по теоремата за смяна на променливите плътността на Z се дава от:

$$f_Z(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| = f_X(a + (b-a)y) \cdot (b-a)$$

Понеже $y \in [0, 1] \implies a + (b-a)y \in [a, b]$, в този интервал $f_X \in \frac{1}{b-a}$. Следователно:

$$f_Z(y) = \frac{1}{b-a} \cdot (b-a) = 1 \quad \text{за } y \in [0, 1]$$

Това доказва, че $Z \sim U(0, 1)$.

Чрез обратната връзка $X = a + (b-a)Z$ можем лесно да изчислим моментите на X . Очакваното е:

$$\mathbb{E}[X] = \mathbb{E}[a + (b-a)Z] = a + (b-a)\mathbb{E}[Z] = a + (b-a)\frac{1}{2} = \frac{a+b}{2}$$

Дисперсията е:

$$\text{Var}(X) = \text{Var}(a + (b - a)Z) = (b - a)^2 \text{Var}(Z)$$

За $Z \sim U(0, 1)$, вторият момент е $\mathbb{E}[Z^2] = \int_0^1 z^2 \cdot 1 dz = \frac{1}{3}$. Тогава $\text{Var}(Z) = \frac{1}{3} - \left(\frac{1}{2}\right)^2 = \frac{1}{12}$. Оттук получаваме:

$$\text{Var}(X) = \frac{(b - a)^2}{12}$$

1.2 Нормално разпределение (Гаусово)

Случайната величина X има нормално разпределение с параметри μ (средно) и σ^2 (дисперсия, $\sigma > 0$), което се записва като $X \sim N(\mu, \sigma^2)$, ако нейната плътност е:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \forall x \in \mathbb{R}$$

Тази крива, известна като камбанка (bell-shaped curve), има огромно значение в природата и се появява естествено благодарение на Централната гранична теорема (ЦГТ). Интегралът от тази плътност над цялата реална ос е равен на 1.

Специалният случай, когато $\mu = 0$ и $\sigma^2 = 1$, се нарича **стандартно нормално разпределение** и се бележи със $Z \sim N(0, 1)$. Неговата плътност е:

$$f_Z(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Функцията на разпределение на стандартното нормално разпределение няма затворена форма чрез елементарни функции и традиционно се означава с главната буква $\Phi(x)$:

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy$$

Стандартизиране на нормална случайна величина: Нека $X \sim N(\mu, \sigma^2)$. Въвеждаме трансформацията $Y = g(X) = \frac{X - \mu}{\sigma}$. Обратната функция е $x = g^{-1}(y) = \sigma y + \mu$ с производна σ . Плътността на Y е:

$$f_Y(y) = f_X(\sigma y + \mu) \cdot \sigma = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\sigma y + \mu - \mu)^2}{2\sigma^2}} \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

Това съвпада с плътността на Z , следователно $\frac{X - \mu}{\sigma} \sim N(0, 1)$. Обратната връзка е $X = \sigma Z + \mu$.

Тази структурна връзка позволява лесно изчисляване на моментите. Очакването е:

$$\mathbb{E}[X] = \sigma \mathbb{E}[Z] + \mu$$

Тъй като подинтегралната функция $y e^{-y^2/2}$ за очакването на Z е нечетна и се интегрира в симетрични граници $(-\infty, \infty)$, следва че $\mathbb{E}[Z] = 0$. Следователно $\mathbb{E}[X] = \mu$.

За дисперсията имаме $\text{Var}(X) = \sigma^2 \text{Var}(Z) = \sigma^2 \mathbb{E}[Z^2]$. За да пресметнем втория момент $\mathbb{E}[Z^2]$, ще използваме елегантен метод на Ричард Файнман — диференциране под знака на интеграла по параметър. Знаем, че интегралът от общата нормална плътност е 1, т.е.:

$$\sqrt{2\pi}\sigma = \int_{-\infty}^{\infty} e^{-\frac{y^2}{2\sigma^2}} dy$$

Диференцираме двете страни по параметъра σ :

$$\sqrt{2\pi} = \int_{-\infty}^{\infty} \frac{\partial}{\partial \sigma} \left(e^{-\frac{y^2}{2\sigma^2}} \right) dy = \int_{-\infty}^{\infty} e^{-\frac{y^2}{2\sigma^2}} \left(-\frac{y^2}{2} \right) \left(-\frac{2}{\sigma^3} \right) dy$$

Оттук получаваме равенството:

$$\sqrt{2\pi}\sigma^3 = \int_{-\infty}^{\infty} y^2 e^{-\frac{y^2}{2\sigma^2}} dy$$

Като заместим $\sigma = 1$, намираме втория момент на стандартното нормално разпределение:

$$\sqrt{2\pi} = \int_{-\infty}^{\infty} y^2 e^{-\frac{y^2}{2}} dy \implies \mathbb{E}[Z^2] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-\frac{y^2}{2}} dy = \frac{\sqrt{2\pi}}{\sqrt{2\pi}} = 1$$

Следователно $\text{Var}(Z) = 1$, а дисперсията на първоначалната величина е $\text{Var}(X) = \sigma^2$.
За пресмятане на вероятности с общо нормално разпределение, свеждаме до $\Phi(x)$:

$$\mathbb{P}(X < x) = \mathbb{P}\left(\frac{X - \mu}{\sigma} < \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

Например, $\Phi(0) = \frac{1}{2}$ поради симетрията. Също така класическа стойност е $\Phi(1.96) \approx 0.975$, което означава, че 95% от вероятностната маса е в интервала $[-1.96, 1.96]$.

1.3 Експоненциално разпределение

Казваме, че X е експоненциално разпределена с параметър $\lambda > 0$, записвано $X \sim \text{Exp}(\lambda)$, ако нейната плътност е:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{за } x \geq 0 \\ 0, & \text{иначе} \end{cases}$$

Функцията на разпределение е:

$$F_X(x) = \int_0^x \lambda e^{-\lambda y} dy = 1 - e^{-\lambda x}$$

Често е по-удобно да се работи с опашката на разпределението (tail probability), която се бележи с $\bar{F}_X(x)$:

$$\bar{F}_X(x) = \mathbb{P}(X \geq x) = 1 - F_X(x) = e^{-\lambda x}$$

Този клас разпределения е фундаментален заради **свойството си на безпаметност (memorylessness)**. То отразява феномена, при който ако един процес/компонент е работил x време, вероятността да продължи да работи още y време е същата, сякаш е започнал да работи отначало (чисто нов). Формално:

$$\mathbb{P}(X \geq x + y \mid X \geq x) = \frac{\mathbb{P}(X \geq x + y \text{ и } X \geq x)}{\mathbb{P}(X \geq x)} = \frac{\mathbb{P}(X \geq x + y)}{\mathbb{P}(X \geq x)} = \frac{e^{-\lambda(x+y)}}{e^{-\lambda x}} = e^{-\lambda y} = \mathbb{P}(X \geq y)$$

Обратно, ако търсим функция $\bar{F}$, която да удовлетворява функционалното уравнение за безпаметност $\bar{F}(x + y) = \bar{F}(x)\bar{F}(y)$, и изискваме отговарящото ѝ разпределение да притежава плътност, единственото възможно решение е експоненциалната функция $\bar{F}(x) = e^{-\lambda x}$.

Структурната връзка тук се изразява чрез факта, че ако $X \sim \text{Exp}(\lambda)$, то мащабираната величина $Y = \lambda X \sim \text{Exp}(1)$. Проверката е директна:

$$\mathbb{P}(Y \leq x) = \mathbb{P}(\lambda X \leq x) = \mathbb{P}\left(X \leq \frac{x}{\lambda}\right) = 1 - e^{-\lambda(\frac{x}{\lambda})} = 1 - e^{-x} = F_Y(x)$$

Тъй като Y е с параметър 1, нейните моменти са $\mathbb{E}[Y] = 1$ и $\text{Var}(Y) = 1$. Чрез линейните свойства на очакването намираме за X :

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E}\left[\frac{Y}{\lambda}\right] = \frac{1}{\lambda}\mathbb{E}[Y] = \frac{1}{\lambda} \\ \text{Var}(X) &= \text{Var}\left(\frac{Y}{\lambda}\right) = \frac{1}{\lambda^2}\text{Var}(Y) = \frac{1}{\lambda^2} \end{aligned}$$

2 Непрекъснати съвместни разпределения

В практиката най-често се работи със съвкупност от случайни величини, които може да имат сложни зависимости помежду си. Ето защо въвеждаме случайни вектори.

Дефиниция: Векторът $X = (X_1, \dots, X_n)$ е непрекъснат вектор от случайни величини, ако съществува функция $f_X : \mathbb{R}^n \rightarrow [0, \infty)$, наречена **съвместна плътност** (joint probability density function), такава че: 1. $f_X(x) \geq 0 \quad \forall x \in \mathbb{R}^n$ 2. $\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_X(x_1, \dots, x_n) dx_1 \dots dx_n = 1$ 3. За всяко подмножество $D \subseteq \mathbb{R}^n$:

$$\mathbb{P}(X \in D) = \int \dots \int_D f_X(x) dx$$

Множеството, върху което съвместната плътност е строго положителна, се нарича дефиниционно множество:

$$\mathcal{D}(f_X) = \{x \in \mathbb{R}^n : f_X(x) > 0\}$$

Ако знаем съвместната плътност на целия вектор, можем да възстановим плътността на всеки индивидуален компонент X_j . Тя се нарича **маргинална плътност** и се получава чрез ”дезинтегриране” по всички останали променливи:

$$f_{X_j}(x_j) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_X(x_1, \dots, x_n) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_n$$

Съвместна функция на разпределение: Тя се дефинира общо (не само за непрекъснати величини) като:

$$F_X(x) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_X(y_1, \dots, y_n) dy_1 \dots dy_n$$

От функцията на разпределение може да се възстанови плътността чрез n -кратна смесена производна:

$$f_X(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \dots \partial x_n} F_X(x_1, \dots, x_n)$$

Независимост: Две случайни величини X_1 и X_2 са независими ($X_1 \perp\!\!\!\perp X_2$), тогава и само тогава, когато съвместната им функция на разпределение се разпада на произведение от индивидуалните:

$$F_X(x_1, x_2) = F_{X_1}(x_1)F_{X_2}(x_2)$$

В случая на непрекъснат вектор, това е еквивалентно на разпадане на съвместната плътност:

$$f_X(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$$

Случайните величини $X_1, \dots, X_n$ са **независими в съвкупност**, ако за всяко k ($2 \leq k \leq n$) и за всеки избор на k различни индекса $j_1, \dots, j_k$, съвместната плътност на съответния подвектор е произведение от маргиналните плътности:

$$f_Y(y_{j_1}, \dots, y_{j_k}) = \prod_{i=1}^k f_{X_{j_i}}(y_{j_i})$$

В частност, плътността на целия вектор е $f_X(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$.

Свойства на очакването: Ако X е непрекъснат вектор и g е функция, то математическото очакване на $g(X)$ се задава като:

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

Очакването е винаги линеен оператор. Ако $X = (X_1, X_2)$, то за функцията $g(X_1, X_2) = X_1 + X_2$:

$$\mathbb{E}[X_1 + X_2] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_1 + x_2) f_X(x_1, x_2) dx_1 dx_2$$

Можем да разделим интеграла на две части. Като интегрираме първата част по x_2 , получаваме маргиналната плътност на X_1 :

$$\int_{-\infty}^{\infty} x_1 \left(\int_{-\infty}^{\infty} f_X(x_1, x_2) dx_2 \right) dx_1 = \int_{-\infty}^{\infty} x_1 f_{X_1}(x_1) dx_1 = \mathbb{E}[X_1]$$

Аналогично, втората част е $\mathbb{E}[X_2]$. Следователно $\mathbb{E}[X_1 + X_2] = \mathbb{E}[X_1] + \mathbb{E}[X_2]$.

Ако допълнително X_1 и X_2 са независими, то тогава:

$$\mathbb{E}[X_1 X_2] = \mathbb{E}[X_1] \mathbb{E}[X_2]$$

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2)$$

3 Смяна на променливите при случайни вектори

Често се налага да намерим разпределението на нов случаен вектор Y , който е функция от познат вектор X .

Теорема (Смяна на променливите): Нека $X = (X_1, X_2)$ е непрекъснат вектор със съвместна плътност f_X и дефиниционна област $\mathcal{D}(f_X)$. Нека $g : \mathcal{D}(f_X) \rightarrow \mathbb{R}^2$ е взаимно еднозначно изображение, т.е. $Y = g(X) = (g_1(X), g_2(X))$. Обратната функция бележим с $X = g^{-1}(Y) = h(Y) = (h_1(Y), h_2(Y))$. Нека g

и h са непрекъснати и диференцируеми в съответните си области $\mathcal{D}(f_X)$ и $g(\mathcal{D}(f_X))$. Тогава съвместната плътност на Y съществува и е равна на:

$$f_Y(y) = f_X(h(y))|J(y)|, \quad \forall y \in g(\mathcal{D}(f_X))$$

където $J(y)$ е якобианата (детерминантата на матрицата от производни):

$$J(y) = \det \begin{pmatrix} \frac{\partial h_1}{\partial y_1} & \frac{\partial h_1}{\partial y_2} \\ \frac{\partial h_2}{\partial y_1} & \frac{\partial h_2}{\partial y_2} \end{pmatrix}$$

Доказателството стъпва директно върху теоремата за смяна на променливите при двукратни интеграли от математическия анализ, като се запише вероятността $\mathbb{P}(Y \in A) = \mathbb{P}(X \in h(A))$.

Обща схема за сума на независими случайни величини: Нека X_1 и X_2 са независими, откъдето $f_X(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$. Интересуваме се от плътността на сумата $Y_2 = X_1 + X_2$. За да приложим теоремата, допълваме с тривиална променлива $Y_1 = X_1$:

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = \begin{pmatrix} X_1 \\ X_1 + X_2 \end{pmatrix} = g(X)$$

Обратната трансформация е лесна: $X_1 = Y_1$ и $X_2 = Y_2 - Y_1$. Следователно:

$$X = h(Y) = \begin{pmatrix} Y_1 \\ Y_2 - Y_1 \end{pmatrix}$$

Якобианата е $J(y) = \det \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} = 1$. Съвместната плътност на Y става:

$$f_Y(y_1, y_2) = f_X(h(y_1, y_2)) \cdot 1 = f_{X_1}(y_1)f_{X_2}(y_2 - y_1)$$

За да намерим търсената маргинална плътност на сумата Y_2 , интегрираме по y_1 :

$$f_{Y_2}(y_2) = \int f_{X_1}(y_1)f_{X_2}(y_2 - y_1)dy_1$$

Тази формула се нарича **конволюция**. Тънкоста при прилагането ѝ е правилното определяне на границите на интеграла, тъй като те зависят от дефиниционните области на изходните величини (виж следващия пример).

4 Гама разпределение и Хи-квадрат разпределение

4.1 Гама разпределение

Казваме, че X има Гама разпределение с параметри $\alpha > 0$ и $\beta > 0$, записвано $X \sim \Gamma(\alpha, \beta)$, ако плътността ѝ е:

$$f_X(x) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & \text{за } x \geq 0 \\ 0, & \text{иначе} \end{cases}$$

където $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$ е добре познатата Гама функция. Важни нейни стойности са $\Gamma(1) = 1$ и $\Gamma(n+1) = n!$.

Забележете връзката с експоненциалното разпределение: ако фиксираме $\alpha = 1$, плътността става $f_X(x) = \frac{\beta^1}{1} x^0 e^{-\beta x} = \beta e^{-\beta x}$. Това означава, че $\Gamma(1, \beta) \equiv \text{Exp}(\beta)$.

Твърдение (Сума на Гама величини): Нека $X_1, \dots, X_n$ са независими в съвкупност случайни величини, като $X_i \sim \Gamma(\alpha_i, \beta)$ (имат общ мащабен параметър β). Тогава тяхната сума също има Гама разпределение:

$$Y = \sum_{j=1}^n X_j \sim \Gamma\left(\sum_{i=1}^n \alpha_i, \beta\right)$$

Доказателство (за $n = 2$): Използваме конволюционната схема от предишния раздел. Търсим плътността на $Y_2 = X_1 + X_2$. Тъй като $X_1 \geq 0$ и $X_2 \geq 0$, то $y_1 \geq 0$ и $y_2 - y_1 \geq 0 \implies 0 \leq y_1 \leq y_2$. Границите на интеграла са от 0 до y_2 :

$$f_{Y_2}(y_2) = \int_0^{y_2} f_{X_1}(y_1)f_{X_2}(y_2 - y_1)dy_1$$

Заместваме плътностите на двете Гама разпределения:

$$f_{Y_2}(y_2) = \int_0^{y_2} \left(\frac{\beta^{\alpha_1}}{\Gamma(\alpha_1)} y_1^{\alpha_1-1} e^{-\beta y_1} \right) \left(\frac{\beta^{\alpha_2}}{\Gamma(\alpha_2)} (y_2 - y_1)^{\alpha_2-1} e^{-\beta(y_2-y_1)} \right) dy_1$$

Експоненциалните членове се опростяват: $e^{-\beta y_1} e^{-\beta y_2 + \beta y_1} = e^{-\beta y_2}$, което не зависи от y_1 и излиза пред интеграла. Остава да се реши:

$$f_{Y_2}(y_2) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta y_2} \int_0^{y_2} y_1^{\alpha_1-1} (y_2 - y_1)^{\alpha_2-1} dy_1$$

С помощта на субституцията $y_1 = uy_2$, интегралът се свежда до Бета функцията $B(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1+\alpha_2)}$ и крайният резултат е точно плътността на $\Gamma(\alpha_1 + \alpha_2, \beta)$:

$$f_{Y_2}(y_2) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1 + \alpha_2)} y_2^{\alpha_1+\alpha_2-1} e^{-\beta y_2}$$

От това следва, че Гама разпределението е **безгранично делимо**. Например $\Gamma(3.5, \beta)$ може да се представи като сума от 7 независими $\Gamma(0.5, \beta)$ величини.

4.2 Хи-квадрат разпределение (χ^2)

Твърдение: Нека $Z_1, \dots, Z_n$ са независими в съвкупност стандартно нормални случайни величини ($Z_i \sim N(0, 1)$). Тогава сумата от техните квадрати има χ^2 разпределение с n степени на свобода, което е еквивалентно на Гама разпределение:

$$Y = \sum_{j=1}^n Z_j^2 \sim \chi^2(n) \equiv \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$$

Доказателство: Ще покажем, че квадратът на една стандартно нормална величина $T_1 = Z_1^2$ има разпределение $\chi^2(1) \equiv \Gamma(1/2, 1/2)$. Започваме с функцията на разпределение за $t > 0$:

$$F_{T_1}(t) = \mathbb{P}(T_1 < t) = \mathbb{P}(Z_1^2 < t) = \mathbb{P}(-\sqrt{t} < Z_1 < \sqrt{t}) = \frac{1}{\sqrt{2\pi}} \int_{-\sqrt{t}}^{\sqrt{t}} e^{-\frac{y^2}{2}} dy$$

Поради четността на функцията, това е:

$$F_{T_1}(t) = 2 \cdot \frac{1}{\sqrt{2\pi}} \int_0^{\sqrt{t}} e^{-\frac{y^2}{2}} dy$$

Диференцираме по t , за да намерим плътността (използвайки правилото за диференциране на интеграл с променлива горна граница $\sqrt{t}$, чиято производна е $\frac{1}{2\sqrt{t}}$):

$$f_{T_1}(t) = \frac{d}{dt} F_{T_1}(t) = \frac{2}{\sqrt{2\pi}} e^{-\frac{(\sqrt{t})^2}{2}} \cdot \frac{1}{2\sqrt{t}} = \frac{1}{\sqrt{2\pi}} t^{-1/2} e^{-t/2}$$

Сега ще сравним този резултат с плътността на Гама разпределението при параметри $\alpha = 1/2$ и $\beta = 1/2$:

$$f_{\Gamma}(t) = \frac{(1/2)^{1/2}}{\Gamma(1/2)} t^{(1/2)-1} e^{-t/2} = \frac{1}{\sqrt{2}\Gamma(1/2)} t^{-1/2} e^{-t/2}$$

Тъй като и двата израза представляват плътност (и следователно интегралите им са 1), константите отпред трябва да са равни. От равенството $\frac{1}{\sqrt{2\pi}} = \frac{1}{\sqrt{2}\Gamma(1/2)}$ можем пътем да изчислим красивия факт, че $\Gamma(1/2) = \sqrt{\pi}$. Най-важното е, че двете плътности съвпадат. Следователно $Z_1^2 \sim \Gamma(1/2, 1/2)$.

Тъй като $Y = \sum_{j=1}^n Z_j^2$ е сума на n независими Гама величини с еднакъв мащабен параметър $\beta = 1/2$ и формов параметър $\alpha_j = 1/2$, от предходното твърдение следва директно, че:

$$Y \sim \Gamma\left(\sum_{j=1}^n \frac{1}{2}, \frac{1}{2}\right) = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right) \equiv \chi^2(n)$$

С това доказателството е завършено.